

Colección de Problemas y Ejercicios

Algunos de los problemas y ejercicios incluidos en este boletín pertenecen a exámenes de convocatorias anteriores.

Índice

1. Optimización	2
2. Regresión	3
2.1. k -NN	3
2.2. Regresión ML	4
2.3. Regresión ML y MAP	10
2.4. Regresión bayesiana. Modelos gaussianos	14
2.5. Regresión bayesiana. Modelos no gaussianos	22
2.6. kNN y regresión paramétrica	26
3. Clasificación	27
3.1. k -NN	27
3.2. Regresión logística	33
3.3. k -NN y regresión logística	34
3.4. Clasificación ML	35
3.5. Clasificación ML y MAP	38
3.6. SVM	42
3.7. MLP	43
4. Aprendizaje No Supervisado	49
4.1. Análisis por Componentes Principales	49
4.2. Agrupamiento	51
5. Procesamiento de Lenguaje Natural	57
5.1. Modelos de Tópicos	57
5.2. Modelos de Lenguaje	59

1. Optimización

Ejercicio OP1

El coste a minimizar por el método de mínimos cuadrados está dado por

$$C(\mathbf{w}) = \frac{1}{2} \sum_{k=0}^{K-1} [s_k - \hat{s}_k]^2 = \frac{1}{2} \|\mathbf{s} - \hat{\mathbf{s}}\|^2 = \frac{1}{2} \|\mathbf{s} - \mathbf{Z}\mathbf{w}\|^2$$

donde $\mathbf{w}$ es el vector de parámetros a ajustar, $\mathbf{s}$ el vector objetivo y $\mathbf{Z}$ la matriz de datos de entrada.

- (a) Proporcione la regla del algoritmo de descenso por gradiente para la minimización de $C(\mathbf{w})$.
- (b) Proporcione la regla del algoritmo de descenso por gradiente estocástico para la minimización de $C(\mathbf{w})$.
- (c) ¿Cuántas iteraciones requeriría el algoritmo de Newton para converger en este problema utilizando un paso de adaptación igual a uno?

Solution:

- (a) $\mathbf{w}_{n+1} = \mathbf{w}_n + \rho_n \mathbf{Z}^T (\mathbf{s} - \mathbf{Z}\mathbf{w}_n)$
- (b) $\mathbf{w}_{n+1} = \mathbf{w}_n + \rho_n (s_{i_n} - \mathbf{z}_{i_n}^T \mathbf{w}_n) \mathbf{z}_{i_n}$. El índice i_n va entre 1 y el número K de datos, cíclicamente.
- (c) One single iteration.

2. Regresión

2.1. k -NN

Ejercicio R1

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{x_k, s_k\}_{k=0}^4$ para un problema de regresión unidimensional

k	0	1	2	3	4
x_k	-2	-1	0	1	2
s_k	8.2	3.6	1.8	3.8	7.6

- Represente la curva de regresión obtenida mediante la aplicación del procedimiento del vecino más próximo (1-NN).
- Represente la curva de regresión obtenida por el método 2-NN.

Solution:

(a)

$$\hat{s} = \begin{cases} 8.2, & x < -1.5 \\ 3.6, & -1.5 < x < -0.5 \\ 1.8, & -0.5 < x < 0.5 \\ 3.8, & 0.5 < x < 1.5 \\ 7.6, & 1.5 < x \end{cases}$$

(b)

$$\hat{s} = \begin{cases} 5.9, & x < -1 \\ 2.7, & -1 < x < 0 \\ 2.8, & 0 < x < 1 \\ 5.7, & 1 < x \end{cases}$$

Ejercicio R2

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{x_k, s_k\}_{k=0}^5$ para un problema de regresión unidimensional

k	0	1	2	3	4	5
x_k	1	2	4	8	16	32
s_k	4	3	1	5	9	7

- Represente gráficamente la función de regresión obtenida por el algoritmo del vecino más próximo (1-NN).
- Para evaluar las prestaciones del algoritmo, se desea aplicar validación cruzada por Leave-One-Out (LOO) sobre estos datos. Determine el error cuadrático promedio de validación por este procedimiento.

Solution:

(a)

$$\hat{s} = \begin{cases} 4, & x < 1.5 \\ 3, & 1.5 < x < 3 \\ 1, & 3 < x < 6 \\ 5, & 6 < x < 12 \\ 9, & 12 < x < 24 \\ 7, & 24 < x \end{cases}$$

(b) $\text{MSE} = 7.0$

2.2. Regresión ML

Ejercicio R3

Considere que el conjunto $\mathcal{D} = \{(x_k, s_k), k = 0, \dots, K-1\}$ contiene muestras i.i.d. provenientes de una distribución con pdf a posteriori

$$p(s|x, w) = wx \exp(-wxs), \quad s \geq 0, x \geq 0, w \geq 0$$

- Obtenga una expresión para la función de verosimilitud
- Determine el coeficiente de máxima verosimilitud w_{ML} . (*Observación: si le resulta conveniente, puede maximizar el logaritmo de la función de verosimilitud para simplificar el cálculo de la derivada*)
- Calcule la media predictiva a posteriori de S dado el valor de x .

Solution:

(a)

$$p(\mathbf{s}|w, \mathbf{X}) = \prod_{k=0}^{K-1} wx_k \exp(-wx_k s_k) = w^K \left(\prod_{k=0}^{K-1} x_k \right) \exp \left(-w \sum_{k=0}^{K-1} x_k s_k \right)$$

(b) Applying the logarithm to the likelihood function we get

$$\log p(\mathbf{s}|\mathbf{w}, \mathbf{X}) = K \log w + \sum_{k=0}^{K-1} \log(x_k) - w \mathbf{X}^\top \mathbf{s}$$

Which is minimum for $w_{\text{ML}} = \frac{K}{\mathbf{X}^\top \mathbf{s}}$

(c) $\hat{s}_{\text{MSE}} = \mathbb{E}\{S|x, w\} = \frac{1}{wx}$

Ejercicio R4

Considere el conjunto de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k), 0 \leq k < K\}$ para un problema de regresión. Se sabe que la función de verosimilitud se ajusta a una distribución log-normal de la forma

$$p(s|\mathbf{x}, \mathbf{w}) = \frac{1}{s|\mathbf{w}^\top \mathbf{x}| \sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{\log(s)}{\mathbf{w}^\top \mathbf{x}} \right)^2 \right], \quad s > 0$$

- Determine el predictor MAP de s para una entrada $\mathbf{x}$, $\hat{s}_{\text{MAP}}$.
- Determine una regla de aprendizaje mediante descenso por gradiente para aproximarse iterativamente al estimador de máxima verosimilitud de $\mathbf{w}$, $\hat{\mathbf{w}}_{\text{ML}}$
- Comparando la función de verosimilitud de un vector de parámetros $\mathbf{w}$ con su opuesto $-\mathbf{w}$, discuta la unicidad del estimador de máxima verosimilitud.

Solution:

(a)

$$\begin{aligned}
\hat{s}_{\text{MAP}} &= \underset{s}{\operatorname{argmax}} \log p(s|\mathbf{x}, \mathbf{w}) = \\
&= \underset{s}{\operatorname{argmax}} \log \left(\frac{1}{s|\mathbf{w}^\top \mathbf{x}| \sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{\log(s)}{\mathbf{w}^\top \mathbf{x}} \right)^2 \right) \right) \\
&= \underset{s}{\operatorname{argmin}} \left(\log(s) + \frac{1}{2} \frac{(\log(s))^2}{(\mathbf{w}^\top \mathbf{x})^2} \right) \\
&= \exp \left(-(\mathbf{w}^\top \mathbf{x})^2 \right)
\end{aligned}$$

(b)

$$\begin{aligned}
L(\mathbf{w}) &= \log \left(\prod_{k=0}^{K-1} \frac{1}{s_k |\mathbf{w}^\top \mathbf{x}_k| \sqrt{2\pi}} \exp \left(-\frac{(\log(s_k))^2}{2(\mathbf{w}^\top \mathbf{x}_k)^2} \right) \right) \\
&= -\frac{K}{2} \log(2\pi) - \sum_{k=0}^{K-1} \log(s_k) - \sum_{k=0}^{K-1} \log(|\mathbf{w}^\top \mathbf{x}_k|) - \sum_{k=0}^{K-1} \frac{(\log(s_k))^2}{2(\mathbf{w}^\top \mathbf{x}_k)^2}
\end{aligned}$$

por tanto

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \sum_{k=0}^{K-1} \frac{\log^2(s_k) - (\mathbf{w}^\top \mathbf{x}_k)^2}{(\mathbf{w}^\top \mathbf{x}_k)^3} \mathbf{x}_k$$

y ahora aplicamos descenso del gradient a $-L(w)$:

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \rho \cdot \sum_{k=0}^{K-1} \frac{\log^2(s_k) - (\mathbf{w}^\top \mathbf{x}_k)^2}{(\mathbf{w}^\top \mathbf{x}_k)^3} \mathbf{x}_k$$

(c) El estimador ML no es único: dado que $p(s|\mathbf{x}, \mathbf{w}) = p(s|\mathbf{x}, -\mathbf{w})$, resulta $L(\mathbf{w}) = L(-\mathbf{w})$. Por tanto, si $\mathbf{w}_{\text{ML}}$ es un estimador ML, $-\mathbf{w}_{\text{ML}}$ también lo es, y es diferente ya que $\mathbf{w} = 0$ no está en el dominio.

Ejercicio R5

Considere el conjunto de entrenamiento $\mathcal{D} = \{(x_k, s_k), 0 \leq k < K-1\}$ para un problema de regresión. Se asume que la función de verosimilitud es

$$p(s|x, w) = \frac{1}{(wxs)^2} \exp \left[-\frac{1}{(wx)^2 s} \right], \quad s > 0$$

- (a) Determine el predictor MAP de s para una entrada $\mathbf{x}$, $\hat{s}_{\text{MAP}}$, supuesto conocido w .
(b) Determine una regla de aprendizaje mediante descenso por gradiente para aproximar iterativamente al estimador de máxima verosimilitud de w , $\hat{w}_{\text{ML}}$

Solution: La función de densidad $p(s|x, w) \geq 0$ es diferenciable y $\lim_{s \rightarrow 0} p(s|x, w) = 0$ así que un único punto con derivada 0 es un máximo:

(a)

$$\begin{aligned}
\hat{s}_{\text{MAP}} &= \underset{s}{\operatorname{argmax}} \log p(s|x, w) = \underset{s}{\operatorname{argmax}} \left[-2 \log(s) - \frac{1}{(wx)^2 s} \right] \\
\frac{\partial \log p(s|x, w)}{\partial s} &= -\frac{2}{s} + \frac{1}{(wx)^2 s^2}
\end{aligned}$$

$$\begin{aligned}
 \hat{s}_{\text{MAP}} &= \frac{1}{2(wx)^2} \\
 \text{(b)} \quad \text{NLL}(w) &= - \sum_{k=0}^{K-1} \log p(s_k | x_k, w) = \sum_{k=0}^{K-1} \left(2 \log(wx_k) + 2 \log s_k + \frac{1}{(wx_k)^2 s_k} \right) \\
 \frac{\partial \text{NLL}(w)}{\partial w} &= \sum_{k=0}^{K-1} \left(\frac{2}{w} - \frac{2}{w^3 x_k^2 s_k} \right) \\
 &= \frac{2K}{w} - \frac{2}{w^3} \sum_{k=0}^{K-1} \frac{1}{x_k^2 s_k} \\
 w_{n+1} &= w_n - \rho_n \frac{\partial \text{NLL}(w)}{\partial w} \Big|_{w=w_n} \\
 &= w_n - 2\rho_n \left(\frac{K}{w_n} - \frac{1}{w_n^3} \sum_{k=0}^{K-1} \frac{1}{x_k^2 s_k} \right)
 \end{aligned}$$

Ejercicio R6

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k)\}_{k=0}^{K-1}$ para un problema de regresión bidimensional.

Para ello, considere el modelo dado por la verosimilitud

$$p(s|w, \mathbf{x}) = \frac{w(ws)^{x_0}(1-ws)^{x_1}}{\beta(x_0+1, x_1+1)}, \quad 0 \leq s \leq \frac{1}{w}, \quad x_0 > 0, \quad x_1 > 0, \quad w \geq 0 \quad (1)$$

donde $\beta()$ es la función beta, que se define como

$$\beta(x, y) = \int_0^1 t^{x-1} (1-t)^{y-1} dt \quad (2)$$

- Suponiendo conocido w , determine el predictor de máximo a posteriori de s para una entrada $\mathbf{x}$ arbitraria, $\hat{s}_{\text{MAP}}$.
- Determine el predictor de mínimo error cuadrático medio, $\hat{s}_{\text{MSE}}$.
- Se pretende estimar el parámetro w siguiendo el criterio de máxima verosimilitud. Determine la función que debe optimizarse, expresándola del modo más sencillo que le sea posible (es decir, determine la función de log-verosimilitud simplificada que resulta de eliminar los términos que no afecten a la maximización).
- Determine una regla de aprendizaje por gradiente del parámetro w de máxima verosimilitud.
- Determine una regla de aprendizaje por gradiente estocástico del parámetro w de máxima verosimilitud.

Indicación: alguna de estas propiedades de la función beta puede serle de utilidad:

$$\blacksquare \quad \beta(x+1, y) = \frac{x}{x+y} \beta(x, y)$$

$$\blacksquare \beta(x, y+1) = \frac{y}{x+y} \beta(x, y)$$

Solution:

- (a) La función de densidad $p(s|x, w) \geq 0$ es diferenciable y $\lim_{s \rightarrow 0} p(s|x, w) = \lim_{s \rightarrow 1/w} p(s|x, w) = 0$ así que un único punto con derivada 0 es un máximo:

$$\begin{aligned} \hat{s}_{\text{MAP}} &= \arg \max_s \log p(s|w, \mathbf{x}) = \\ &= \arg \max_s \{x_0 \log(ws) + x_1 \log(1 - ws)\} \end{aligned} \quad (3)$$

Derivando con respecto a s

$$\frac{wx_0}{w\hat{s}_{\text{MAP}}} - \frac{wx_1}{1 - w\hat{s}_{\text{MAP}}} = 0$$

luego

$$\hat{s}_{\text{MAP}} = \frac{x_0}{w(x_0 + x_1)}$$

(b)

$$\begin{aligned} \hat{s}_{\text{MSE}} &= \int_0^{\frac{1}{w}} s \frac{w(ws)^{x_0}(1 - ws)^{x_1}}{\beta(x_0 + 1, x_1 + 1)} ds \\ &= \frac{\int_0^1 z z^{x_0}(1 - z)^{x_1} dz}{w\beta(x_0 + 1, x_1 + 1)} \\ &= \frac{\beta(x_0 + 2, x_1 + 1)}{w\beta(x_0 + 1, x_1 + 1)} \\ &= \frac{x_0 + 1}{w(x_0 + x_1 + 2)} \end{aligned} \quad (4)$$

(c)

$$\begin{aligned} L(w) &= \prod_{k=0}^{K-1} p(s_k|w, \mathbf{x}_k) \\ &= \frac{w^K \prod_{k=0}^{K-1} (ws_k)^{x_{k,0}} \prod_{k=0}^{K-1} (1 - ws_k)^{x_{k,1}}}{\prod_{k=0}^{K-1} \beta(x_{k,0} + 1, x_{k,1} + 1)} \end{aligned} \quad (5)$$

$$\begin{aligned} \tilde{L}(w) &= K \log(w) + \sum_{k=0}^{K-1} x_{k,0} \log(w) + \sum_{k=0}^{K-1} x_{k,1} \log(1 - ws_k) \\ &= \left(K + \sum_{k=0}^{K-1} x_{k,0} \right) \log(w) + \sum_{k=0}^{K-1} x_{k,1} \log(1 - ws_k) \end{aligned} \quad (6)$$

- (d) Aplicamos descenso del gradiente a $-\tilde{L}(w)$:

$$w_{n+1} = w_n + \rho \left(\frac{1}{w_n} \left(K + \sum_{k=0}^{K-1} x_{k,0} \right) - \sum_{k=0}^{K-1} \frac{x_{k,1} s_k}{1 - ws_k} \right) \quad (7)$$

(e)

$$w_{n+1} = w_n + \rho \left(1 + \frac{1}{w_n} x_{i_n,0} - \frac{x_{i_n,1} s_{i_n}}{1 - w_n s_{i_n}} \right) \quad (8)$$

El índice i_n cicla entre 0 y $K - 1$.

Ejercicio R7

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k)\}_{k=0}^{K-1}$ para un problema de regresión bidimensional.

Para ello, considere el modelo dado por la verosimilitud

$$p(s|\mathbf{w}, \mathbf{x}) = s \exp\left(-\frac{1}{2}s^2 \exp(-\mathbf{w}^\top \mathbf{x}) - \mathbf{w}^\top \mathbf{x}\right) \quad s \geq 0 \quad (9)$$

- Suponiendo conocido $\mathbf{w}$, determine el predictor de máximo a posteriori de s para una entrada $\mathbf{x}$ arbitraria, $\hat{s}_{\text{MAP}}$.
- Se pretende estimar el parámetro $\mathbf{w}$ siguiendo el criterio de máxima verosimilitud. Determine la función que debe optimizarse, expresándola del modo más sencillo que le sea posible (es decir, determine la función de log-verosimilitud simplificada que resulta de eliminar los términos que no afecten a la maximización).
- Determine una regla de descenso por gradiente para el aprendizaje del parámetro $\mathbf{w}$ de máxima verosimilitud.
- Determine una regla de aprendizaje por gradiente estocástico del parámetro $\mathbf{w}$ de máxima verosimilitud.

Solution:

- La función de densidad $p(s|x, w) \geq 0$ es diferenciable y $\lim_{s \rightarrow 0} p(s|x, w) = 0$ así que un único punto con derivada 0 es un máximo:

$$\begin{aligned} \hat{s}_{\text{MAP}} &= \arg \max_s \log p(s|\mathbf{w}, \mathbf{x}) = \\ &= \arg \max_s \left\{ \ln(s) - \frac{1}{2}s^2 \exp(-\mathbf{w}^\top \mathbf{x}) - \mathbf{w}^\top \mathbf{x} \right\} \\ &= \arg \max_s \left\{ \ln(s) - \frac{1}{2}s^2 \exp(-\mathbf{w}^\top \mathbf{x}) \right\} \\ &= \exp\left(\frac{\mathbf{w}^\top \mathbf{x}}{2}\right) \end{aligned}$$

-

$$\begin{aligned} L(w) &= \ln \left(\prod_{k=0}^{K-1} p(s^{(k)}|w, \mathbf{x}^{(k)}) \right) \\ &= \sum_{k=0}^{K-1} \left(\ln(s_k) - \frac{1}{2}s_k^2 \exp(-\mathbf{w}^\top \mathbf{x}_k) - \mathbf{w}^\top \mathbf{x}_k \right) \\ &= \sum_{k=0}^{K-1} \ln(s_k) - \frac{1}{2} \sum_{k=0}^{K-1} s_k^2 \exp(-\mathbf{w}^\top \mathbf{x}_k) - \mathbf{w}^\top \sum_{k=0}^{K-1} \mathbf{x}_k \end{aligned}$$

Luego la función a maximizar es

$$\tilde{L}(w) = -\frac{1}{2} \sum_{k=0}^{K-1} s_k^2 \exp(-\mathbf{w}^\top \mathbf{x}_k) - \mathbf{w}^\top \sum_{k=0}^{K-1} \mathbf{x}_k$$

(c) Hacemos descenso del gradient sobre $-\tilde{L}(w)$:

$$\begin{aligned} w_{n+1} &= w_n + \rho \left[\frac{1}{2} \sum_{k=0}^{K-1} s_k^2 \nabla_{\mathbf{w}} \exp(-\mathbf{w}^\top \mathbf{x}_k) - \nabla_{\mathbf{w}} \left(\mathbf{w}^\top \sum_{k=0}^{K-1} \mathbf{x}_k \right) \right]_{\mathbf{w}=\mathbf{w}_n} \\ &= w_n - \rho \left(\frac{1}{2} \sum_{k=0}^{K-1} s_k^2 \exp(-\mathbf{w}^\top \mathbf{x}_k) \mathbf{x}_k + \sum_{k=0}^{K-1} \mathbf{x}_k \right) \end{aligned}$$

(d)

$$w_{n+1} = w_n - \frac{\rho}{2} (s_n^2 \exp(-\mathbf{w}^\top \mathbf{x}_n) + 1) \mathbf{x}_{i_n}$$

El índice i_n cicla entre 0 y $K-1$.

Ejercicio R8

Considere el conjunto $\{(x_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $x_k \in \mathbb{R}$ y $s_k \in [0, 1]$. Para la resolución del problema de regresión unidimensional se asume el siguiente modelo paramétrico

$$p(s|x, w) = \exp(w \cdot x) s^{\exp(w \cdot x) - 1}, \quad w, x \in \mathbb{R}, \quad s \in [0, 1]$$

- Suponiendo conocido w , determine el estimador MMSE para este modelo, $\hat{s}_{\text{MMSE}}$.
- Represente el valor del estimador obtenido como función de $w \cdot x$.
- Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(w)$.
- Determine una regla de aprendizaje de descenso por gradiente con paso de aprendizaje μ para estimación del parámetro w de máxima verosimilitud.

Solution:

(a)

$$\hat{s}_{\text{MMSE}} = \int_0^1 s \cdot p(s|x, w) ds = \int_0^1 \exp(w \cdot x) s^{\exp(w \cdot x)} = \frac{\exp(w \cdot x)}{1 + \exp(w \cdot x)}$$

(b) Se trata de la función logística.

(c)

$$\begin{aligned} \text{NLL}(w) &= - \sum_{k=0}^{K-1} \log p(s_k|x_k, w) \\ &= - \sum_{k=0}^{K-1} w \cdot x_k + [\exp(w \cdot x_k) - 1] \log s_k \end{aligned}$$

(d) Comenzamos calculando la derivada

$$\frac{d\text{NLL}(w)}{dw} = - \sum_{k=0}^{K-1} x_k + \exp(w \cdot x_k) x_k \log s_k = - \sum_{k=0}^{K-1} x_k [1 + \exp(w \cdot x_k) \log s_k]$$

Por lo que la regla de descenso por gradiente queda

$$w_{n+1} = w_n + \mu \sum_{k=0}^{K-1} x_k [1 + \exp(w \cdot x_k) \log s_k]$$

2.3. Regresión ML y MAP

Ejercicio R9

Considere el conjunto $\{(\mathbf{x}_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^2$ y $s_k \in [0, 1]$. Para la resolución del problema de regresión unidimensional se asume el siguiente modelo paramétrico

$$p(s|\mathbf{x}, \mathbf{w}) = \exp(\mathbf{w}^\top \mathbf{x}) s^{\exp(\mathbf{w}^\top \mathbf{x})-1}, \quad \mathbf{w}, \mathbf{x} \in \mathbb{R}^2, \quad s \in [0, 1]$$

- Suponiendo conocido $\mathbf{w}$, determine el estimador MAP para este modelo, $\hat{s}_{\text{MAP}}$.
- Determine una expresión simplificada para la log-verosimilitud negativa, $\text{NLL}(\mathbf{w})$.
- Calcule la regla de gradiente estocástico que permite aproximar la solución ML.
- Determine el valor $\hat{\mathbf{w}}_{\text{MAP}}$, asumiendo que la distribución a priori de $\mathbf{w}$ es

$$P(\mathbf{w}) = \begin{cases} q, & \text{si } \mathbf{w} = [1, 0]^\top \\ 1 - q, & \text{si } \mathbf{w} = [0, 1]^\top \end{cases}$$

con $0 \leq q \leq 1$.

Solution:

- $p(s|\mathbf{x}, \mathbf{w})$ será una función creciente en s cuando el exponente de s sea positivo, y decreciente en caso contrario. Teniendo en cuenta que $s \in [0, 1]$, se tiene que

$$\hat{s}_{\text{MAP}} = \begin{cases} 1, & \text{si } \mathbf{w}^\top \mathbf{x} > 0 \\ 0, & \text{si } \mathbf{w}^\top \mathbf{x} < 0 \end{cases}$$

Para $\mathbf{w}^\top \mathbf{x} = 0$ el estimador MAP será cualquier valor del intervalo.

-

$$\begin{aligned} \text{NLL}(\mathbf{w}) &= - \sum_{k=0}^{K-1} \log p(s_k|\mathbf{x}_k, \mathbf{w}) \\ &= - \sum_{k=0}^{K-1} \mathbf{w}^\top \mathbf{x}_k + [\exp(\mathbf{w}^\top \mathbf{x}_k) - 1] \log s_k \end{aligned}$$

- Comenzamos calculando el gradiente

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = - \sum_{k=0}^{K-1} \mathbf{x}_k + \exp(\mathbf{w}^\top \mathbf{x}_k) \mathbf{x}_k \log s_k = - \sum_{k=0}^{K-1} \mathbf{x}_k [1 + \exp(\mathbf{w}^\top \mathbf{x}_k) \log s_k]$$

Por lo que la regla de descenso por gradiente queda

$$\mathbf{w}^{(n+1)} = \mathbf{w}^{(n)} + \mu \sum_{k=0}^{K-1} \mathbf{x}_k [1 + \exp(\mathbf{w}^{(n)\top} \mathbf{x}_k) \log s_k]$$

La regla de gradiente estocástico utiliza únicamente una muestra en cada iteración. Si denominamos $\{\mathbf{x}^{(n)}, s^{(n)}\}$ al par empleado en la n -ésima iteración,

$$\mathbf{w}^{(n+1)} = \mathbf{w}^{(n)} + \mu \mathbf{x}^{(n)} [1 + \exp(\mathbf{w}^{(n)\top} \mathbf{x}^{(n)}) \log s^{(n)}]$$

- (d) En este caso, $\hat{\mathbf{w}}_{\text{MAP}}$ únicamente puede tomar los dos valores permitidos por el prior, por lo que el criterio MAP puede expresarse como

$$\begin{aligned} \text{NLL}([1, 0]^\top) - \log q & \begin{matrix} \hat{\mathbf{w}}_{\text{MAP}} = [0, 1]^\top \\ \geq \\ \hat{\mathbf{w}}_{\text{MAP}} = [1, 0]^\top \end{matrix} \text{NLL}([0, 1]^\top) - \log(1 - q) \\ - \sum_{k=0}^{K-1} x_{k0} + [\exp(x_{k0}) - 1] \log s_k - \log q & \begin{matrix} \hat{\mathbf{w}}_{\text{MAP}} = [0, 1]^\top \\ \geq \\ \hat{\mathbf{w}}_{\text{MAP}} = [1, 0]^\top \end{matrix} - \sum_{k=0}^{K-1} x_{k1} + [\exp(x_{k1}) - 1] \log s_k - \log(1 - q) \end{aligned}$$

Ejercicio R10

Considere el conjunto $\{(x_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $x_k, s_k > 0$. Para la resolución del problema de regresión unidimensional se asume el siguiente modelo paramétrico

$$p(s|x, w) = \frac{(wx)^2 s \exp(-wxs)}{2}, \quad s, x, w > 0.$$

- Suponiendo conocido w , determine el estimador MAP para este modelo, $\hat{s}_{\text{MAP}}$.
- Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(w)$.
- Calcule la regla de gradiente que permite aproximar la solución ML.
- Calcule la regla de gradiente que permite aproximar la solución MAP de w asumiendo $p(w) = \exp(-w)$, $w > 0$.

Solution:

- (a) Debemos encontrar el valor de s que maximiza $p(s|x, w)$. Sabemos que $p(s|x, w) \rightarrow 0$ tanto para $s \rightarrow 0$ como $s \rightarrow \infty$. Como se trata de una función analítica positiva, el máximo debe obtenerse para un valor intermedio de s con derivada nula.

$$\frac{\partial p(s|x, w)}{\partial s} = \frac{(wx)^2}{2} (1 - swx) \exp(-wxs)$$

La solución MAP queda por tanto determinada por el único valor de s que anula la derivada anterior, i.e., $1 - \hat{s}_{\text{MAP}}wx = 0$. Por lo tanto:

$$\hat{s}_{\text{MAP}} = \frac{1}{wx}$$

- (b)

$$\text{NLL}(w) = - \sum_{k=0}^{K-1} \log p(s_k|x_k, w) = K \log 2 - \sum_{k=0}^{K-1} 2 \log(wx_k) + \log(s_k) - wx_k s_k$$

- (c)

$$w_{n+1} = w_n - \rho \frac{d\text{NLL}(w)}{dw} \Big|_{w=w_n} = w_n + \rho \left[\frac{2K}{w_n} - \sum_{k=0}^{K-1} x_k s_k \right]$$

- (d)

$$w_{n+1} = w_n - \rho \frac{d[\text{NLL}(w) + \log p(w)]}{dw} \Big|_{w=w_n} = w_n + \rho \left[1 + \frac{2K}{w_n} - \sum_{k=0}^{K-1} x_k s_k \right]$$

Ejercicio R11

Considere el conjunto $\{(\mathbf{x}_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^d$ y $s_k \in \mathbb{R}$. Para la resolución del problema de regresión se asume una distribución de tipo Cauchy:

$$p(s|\mathbf{x}, \mathbf{w}) = \frac{1}{\pi} \left[\frac{\gamma}{\gamma^2 + (s - \mathbf{w}^\top \mathbf{x})^2} \right],$$

donde $\gamma > 0$ es un parámetro de escala.

- Suponiendo conocido $\mathbf{w}$, determine el estimador MAP de s para una entrada $\mathbf{x}$, $\hat{s}_{\text{MAP}}$.
- Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(\mathbf{w})$.
- Calcule la regla de gradiente que permite aproximar la solución ML.
- Calcule la regla de gradiente que permite aproximar la solución MAP de $\mathbf{w}$ asumiendo $\mathbf{w} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{I})$.

Solution:

(a)

$$\hat{s}_{\text{MAP}} = \arg \max_s p(s|\mathbf{x}, \mathbf{w}) = \arg \min_s (s - \mathbf{w}^\top \mathbf{x})^2 = \mathbf{w}^\top \mathbf{x}$$

(b)

$$\text{NLL}(\mathbf{w}) = - \sum_{k=0}^{K-1} \log \gamma - \log \pi - \log[\gamma^2 + (s_k - \mathbf{w}^\top \mathbf{x}_k)^2]$$

$$\text{NLL}(\mathbf{w}) = -K \log \gamma + K \log \pi + \sum_{k=0}^{K-1} \log[\gamma^2 + (s_k - \mathbf{w}^\top \mathbf{x}_k)^2]$$

(c)

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \rho \sum_{k=0}^{K-1} \left[\frac{2(s_k - \mathbf{w}_n^\top \mathbf{x}_k) \mathbf{x}_k}{\gamma^2 + (s_k - \mathbf{w}_n^\top \mathbf{x}_k)^2} \right]$$

(d)

$$\mathbf{w}_{n+1} = (1 - \rho) \mathbf{w}_n + \rho \boldsymbol{\mu} + \rho \sum_{k=0}^{K-1} \left[\frac{2(s_k - \mathbf{w}_n^\top \mathbf{x}_k) \mathbf{x}_k}{\gamma^2 + (s_k - \mathbf{w}_n^\top \mathbf{x}_k)^2} \right]$$

Ejercicio R12

Considere el conjunto $\{(x_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $x_k, s_k \in \mathbb{R}$. Para la resolución del problema de regresión unidimensional se asume un modelo paramétrico de probabilidad caracterizado por la siguiente función de distribución acumulada:

$$F(s|x, w) = (1 + e^{-s})^{-(w \cdot x)^2}, \quad w, x, s \in \mathbb{R}$$

- Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(w)$.
- Determine una regla de aprendizaje de descenso por gradiente con paso de aprendizaje ρ para estimación del parámetro w de máxima verosimilitud.
- Determine el estimador de s que corresponde a la mediana de la distribución.

Solution:

(a)

$$p(s|x, w) = \frac{(w \cdot x)^2 e^{-s}}{(1 + e^{-s})^{(w \cdot x)^2 + 1}}, \quad w, x, s \in \mathbb{R}$$

$$\text{NLL}(w) = - \sum_k 2 \log(w \cdot x_k) - s_k - [(w \cdot x_k)^2 + 1] \log(1 + e^{-s_k})$$

(b)

$$w(n+1) = w(n) + \rho \sum_k \left[\frac{1}{w(n)} - w(n) \cdot x_k^2 \log(1 + e^{-s_k}) \right]$$

(c) Mediana: resolver $F(\hat{s}_{0.5} | x, w_{\text{ML}}) = \frac{1}{2}$. Sea $a = (w_{\text{ML}} x)^2 > 0$. Entonces

$$(1 + e^{-\hat{s}_{0.5}})^{-a} = \frac{1}{2} \Rightarrow \log(1 + e^{-\hat{s}_{0.5}}) = \frac{\log 2}{a} \Rightarrow e^{-\hat{s}_{0.5}} = 2^{1/a} - 1,$$

y

$$\boxed{\hat{s}_{0.5} = -\log(2^{1/a} - 1), \quad a = (w_{\text{ML}} x)^2}.$$

Ejercicio R13

Considere el conjunto de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k), 0 \leq k \leq K-1\}$ para un problema de regresión. Se sabe que la verosimilitud es una función sobre *los números no negativos* $s \geq 0$, de la forma:

$$p(s|\mathbf{x}, \mathbf{w}) = \frac{(\mathbf{w}^\top \mathbf{x})^2}{(s(\mathbf{w}^\top \mathbf{x})^2 + 1)^2(1 + e^{-1})} \exp \left[-\frac{1}{s(\mathbf{w}^\top \mathbf{x})^2 + 1} \right], \quad s \geq 0.$$

- (a) Determine el predictor MAP $\hat{s}_{\text{MAP}}$ para una entrada $\mathbf{x}$ y un vector $\mathbf{w}$.
- (b) Determine una regla de aprendizaje por descenso de gradiente para aproximar iterativamente el estimador de máxima verosimilitud de $\mathbf{w}$, $\hat{\mathbf{w}}_{\text{ML}}$.
- (c) Comparando la función de verosimilitud de un vector de parámetros $\mathbf{w}$ con su opuesto $-\mathbf{w}$, discuta la unicidad del estimador de máxima verosimilitud.

Solution:

- (a) La derivada de la log-verosimilitud es negativa para todo $s \geq 0$, por lo que el MAP es $\hat{s}_{\text{MAP}} = 0$:

$$\frac{d}{ds} \log(s|\mathbf{x}, \mathbf{w}) = -\frac{2(\mathbf{w}^\top \mathbf{x})^2}{s(\mathbf{w}^\top \mathbf{x})^2 + 1} + \frac{(\mathbf{w}^\top \mathbf{x})^2}{(s(\mathbf{w}^\top \mathbf{x})^2 + 1)^2} = \frac{(\mathbf{w}^\top \mathbf{x})^2}{s(\mathbf{w}^\top \mathbf{x})^2 + 1} \left(-2 + \frac{1}{s(\mathbf{w}^\top \mathbf{x})^2 + 1} \right) < 0.$$

Alternativamente, se podría haber calculado el único punto $s = -\frac{1}{2(\mathbf{w}^\top \mathbf{x})^2} < 0$ con derivada 0 arriba, y dado que el único punto crítico (máximo) es negativo, la función debe decrecer desde allí y el MAP sobre $s \geq 0$ es $\hat{s}_{\text{MAP}} = 0$.

(b)

$$\begin{aligned} L(\mathbf{w}) &= \log \left(\prod_{k=0}^{K-1} \frac{(\mathbf{w}^\top \mathbf{x}_k)^2}{(s(\mathbf{w}^\top \mathbf{x}_k)^2 + 1)^2(1 + e^{-1})} \exp \left[-\frac{1}{s(\mathbf{w}^\top \mathbf{x}_k)^2 + 1} \right] \right) \\ &= -\frac{K}{2} \log(1 + e^{-1}) + \sum_{k=0}^{K-1} \log((\mathbf{w}^\top \mathbf{x}_k)^2) - 2 \log(s(\mathbf{w}^\top \mathbf{x}_k)^2 + 1) - \frac{1}{s(\mathbf{w}^\top \mathbf{x}_k)^2 + 1} \end{aligned}$$

por tanto

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \sum_{k=0}^{K-1} \left(\frac{2}{(\mathbf{w}^\top \mathbf{x}_k)} - \frac{4s_k(\mathbf{w}^\top \mathbf{x}_k)}{s_k(\mathbf{w}^\top \mathbf{x}_k)^2 + 1} + \frac{2s_k(\mathbf{w}^\top \mathbf{x})}{(s_k(\mathbf{w}^\top \mathbf{x}_k)^2 + 1)^2} \right) \mathbf{x}_k$$

y ahora aplicamos descenso por gradiente a $-L(w)$:

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \rho \nabla_{\mathbf{w}} L(\mathbf{w}_n).$$

- (c) El estimador de máxima verosimilitud (ML) no es único: dado que $p(s|\mathbf{x}, \mathbf{w}) = p(s|\mathbf{x}, -\mathbf{w})$, tenemos $L(\mathbf{w}) = L(-\mathbf{w})$. Por lo tanto, si $\mathbf{w}_{\text{ML}}$ es un estimador ML, $-\mathbf{w}_{\text{ML}}$ también lo es, y es diferente ya que $\mathbf{w} = 0$ no está en el dominio.

2.4. Regresión bayesiana. Modelos gaussianos

Ejercicio R14

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{(x_k, s_k)\}_{k=0}^4$ para un problema de regresión unidimensional

k	0	1	2	3	4
x_i	-2	-1	0	1	2
s_i	8.2	3.6	1.8	3.8	7.6

- (a) Asumiendo el siguiente modelo paramétrico

$$s_k = w_0 + w_1 x_k^2,$$

proporcione los coeficientes óptimos del modelo de acuerdo con el procedimiento de mínimos cuadrados (LS).

- (b) Asuma ahora el siguiente modelo paramétrico para la generación de los datos

$$s_k = w_0 + w_1 x_k^2 + \varepsilon_k,$$

en el que las muestras de ruido ε_k , $k = 0, \dots, 4$, son realizaciones independientes entre sí e independientes de los parámetros del modelo. Asumiendo además las distribuciones a priori $\mathbf{w} = [w_0, w_1]^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ y $\varepsilon \sim \mathcal{N}(0, 1)$, indique cómo calcularía la distribución a posteriori del vector de pesos, i.e., $p(\mathbf{w}|\mathcal{D})$.

Solution:

- (a)

$$\mathbf{w} = \begin{bmatrix} 144/70 \\ 103/70 \end{bmatrix}$$

- (b)

$$\mathbf{w} = (\mathbf{Z}^\top \mathbf{Z} + \mathbf{I})^{-1} \mathbf{Z}^\top \mathbf{s} \approx \begin{bmatrix} 1.54 \\ 1.58 \end{bmatrix}$$

Ejercicio R15

Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{(x_k, s_k)\}_{k=0}^{K-1}$ para un problema de regresión unidimensional

- (a) Asuma el siguiente modelo paramétrico para la generación de los datos

$$s_k = w_0 + w_1 x_k^2 + \varepsilon_k,$$

en el que las muestras de ruido ε_k , $k = 0, \dots, K-1$, son realizaciones independientes entre sí e independientes de los parámetros del modelo. Asumiendo además las distribuciones a priori $\mathbf{w} = [w_0, w_1]^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ y $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$, indique cómo calcularía la distribución a posteriori del vector de pesos, i.e., $p(\mathbf{w}|\mathcal{D})$.

- (b) Si la varianza de ruido, σ_ε^2 , es un parámetro desconocido cuyo valor hay que ajustar, explique cómo lo haría aplicando una estrategia *leave-one-out*.

Ejercicio R16

Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k)\}_{k=0}^{K-1}$ para un problema de regresión. Las variables s_k están relacionadas con las entradas $\mathbf{x}_k$ a través del modelo

$$s_k = w_0 + w_1 x_{k,1} + w_2 x_{k,1} x_{k,2} + \varepsilon_k,$$

en el que las variables ε_k , $k = 0, \dots, K-1$, son muestras de ruido gaussiano independientes entre sí e independientes de los parámetros del modelo, con media 0 y varianza 2.

Se sabe que la distribución a priori de cada uno de los coeficientes w_i ($i = 0, 1, 2$) del modelo es gaussiana de media 0 y varianza 100, y que todos los parámetros del modelo son, a priori, independientes entre sí.

- (a) Indique la secuencia de ecuaciones que deben aplicarse para estimar la media y la varianza de la distribución a posteriori del vector de pesos $\mathbf{w} = (w_0, w_1, w_2)$ dado $\mathcal{D}$. (Puede definir, para ello, las variables intermedias que considere oportunas),
- (b) Se quiere utilizar la distribución a posteriori de $\mathbf{w}$ para estimar el valor de s asociado a una observación de test $\mathbf{x}^*$. Obtenga la distribución de s^* , $p(s^*|\mathcal{D}, \mathbf{x}^*)$.
- (c) Explique cuál es el significado de la varianza de $p(s^*|\mathcal{D}, \mathbf{x}^*)$.

Solution:

- (a) La secuencia de pasos consiste en

1. Construir matriz $\mathbf{Z}$ de filas $\mathbf{z}_k^\top = (1, x_{k,1}, x_{k,1} \cdot x_{k,2})$ y vector $\mathbf{s} = (s_0, \dots, s_{K-1})^\top$
2. Calcular varianza a posteriori,

$$\mathbf{V}_{\mathbf{w}} = \left[\frac{1}{2} \mathbf{Z}^\top \mathbf{Z} + \frac{1}{100} \mathbf{I} \right]^{-1}$$

3. Calcular media a posteriori

$$\mathbf{w}_{\text{MSE}} = \frac{1}{2} \mathbf{V}_{\mathbf{w}} \mathbf{Z}^\top \mathbf{s}$$

- (b)

$$s^* | \mathbf{s}, \mathbf{z}^* \sim \mathcal{N}(\hat{\mathbf{w}}_{\text{MSE}}^\top \mathbf{z}^*, \mathbf{z}^{*\top} \mathbf{V}_{\mathbf{w}} \mathbf{z}^* + \sigma_\varepsilon^2)$$

- (c) La varianza puede interpretarse como una medida de la incertidumbre sobre el valor de s^* , para una entrada $\mathbf{x}^*$, que persiste tras observar todo el conjunto de entrenamiento.

Ejercicio R17

Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k)\}_{k=0}^{K-1}$ para un problema de regresión. Las variables s_k están relacionadas con las entradas $\mathbf{x}_k$ a través del modelo

$$s_k = w_0 + w_1 x_{k,1} + w_2 x_{k,2} + \varepsilon_k,$$

en el que las variables ε_k , $k = 0, \dots, K-1$, son muestras de ruido independientes entre sí e independientes de los parámetros del modelo, con media 0 y varianza 2.

Se sabe que la distribución a priori de cada uno de los coeficientes w_i ($i = 0, 1, 2$) del modelo es gaussiana de media 0 y varianza 100, y que todos los parámetros del modelo son, a priori, independientes entre sí.

- Indique la secuencia de ecuaciones que deben aplicarse para estimar la media y la varianza de la distribución a posteriori del vector de pesos $\mathbf{w} = (w_0, w_1, w_2)$ dado $\mathcal{D}$. (Puede definir, para ello, las variables intermedias que considere oportunas),
- Suponga que, tras completar el cálculo de la media y la varianza a posteriori, se recibe un conjunto adicional de datos $\mathcal{D}'$ del mismo modelo. Discuta cómo podría estimar la distribución a posteriori de $\mathbf{w}$ dados $\mathcal{D}$ y $\mathcal{D}'$ sin necesidad de volver a utilizar $\mathcal{D}$.
- Finalmente, suponga que el conjunto $\mathcal{D}'$ corresponde al mismo modelo, pero las componentes de ruido del nuevo dataset tienen varianza 8. ¿Qué consecuencia tiene esto sobre el diseño del apartado anterior?

Solution:

- La secuencia de pasos consiste en

- Construir matriz $\mathbf{Z}$ de filas $\mathbf{z}_k^\top = (1, x_{k,1}, x_{k,1} \cdot x_{k,2})$ y vector $\mathbf{s} = (s_0, \dots, s_{K-1}^\top)$
- Calcular varianza a posteriori,

$$\mathbf{V}_{\mathbf{w}} = \left[\frac{1}{2} \mathbf{Z}^\top \mathbf{Z} + \frac{1}{100} \mathbf{I} \right]^{-1}$$

- Calcular media a posteriori

$$\mathbf{w}_{\text{MSE}} = \frac{1}{2} \mathbf{V}_{\mathbf{w}} \mathbf{Z}^\top \mathbf{s}$$

- la distribución a priori representa todo lo que se conoce sobre $\mathbf{w}$ antes de observar los datos.

Antes de observar $\mathcal{D}'$, lo que se conoce sobre $\mathbf{w}$ es $p(\mathbf{w}|\mathcal{D})$. Por tanto, podemos actualizar $\hat{\mathbf{w}}_{\text{MSE}}$ suponiendo que la distribución a priori es $p(\mathbf{w}|\mathcal{D})$ (gaussiana con la media $\hat{\mathbf{w}}_{\text{MSE}}$ calculada con el dataset $\mathcal{D}$ y la varianza $\mathbf{V}_{\text{MSE}}$ calculada con el dataset $\mathcal{D}$), y utilizando solamente los datos en $\mathcal{D}'$.

Matemáticamente, esto puede mostrarse escribiendo:

$$\begin{aligned} p(\mathbf{w}|\mathcal{D}, \mathcal{D}') &= \frac{p(\mathcal{D}, \mathcal{D}'|\mathbf{w}) \cdot p(\mathbf{w})}{p(\mathcal{D}, \mathcal{D}')} \\ &= \frac{p(\mathcal{D}'|\mathbf{w})}{p(\mathcal{D}'|\mathcal{D})} \cdot \frac{p(\mathcal{D}|\mathbf{w}) \cdot p(\mathbf{w})}{p(\mathcal{D})} \\ &= \frac{p(\mathcal{D}'|\mathbf{w})p(\mathbf{w}|\mathcal{D})}{p(\mathcal{D}'|\mathcal{D})} \end{aligned} \tag{10}$$

(donde, en la segunda igualdad, se ha aplicado la independencia entre $\mathcal{D}$ y $\mathcal{D}'$). El último término muestra que la distribución a posteriori se puede calcular aplicando la regla de Bayes utilizando la verosimilitud de $\mathbf{w}$ para el dataset $\mathcal{D}'$ y la distribución a posterior de $\mathbf{w}$ dado $\mathcal{D}$ haciendo el papel de la distribución a priori.

- El procedimiento del apartado b puede aplicarse aunque la varianza del ruido en $\mathcal{D}'$ haya cambiado. La única consecuencia de sobre el diseño es que debe utilizarse la varianza que corresponda en cada verosimilitud.

Ejercicio R18

Considere el problema de regresión unidimensional caracterizado por el modelo $s_k = f(\mathbf{x}_k) + \varepsilon_k$, en el que las realizaciones del ruido ε_k son independientes entre sí.

Considere el modelo de regresión lineal

$$s = \mathbf{w}^\top \mathbf{x} + \varepsilon = w_0 x_0 + w_1 x_1 + \varepsilon,$$

en el que se asumen las siguientes distribuciones a priori:

$$\varepsilon \sim \mathcal{N}(0, 1) \text{ y } \mathbf{w} = [w_0, w_1]^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Se sabe además que las realizaciones de ruido (ε) son independientes entre sí e independientes de los pesos y del valor de $\mathbf{x}$.

Si se observan las salidas $s_0 = 2$ y $s_1 = 5$ para $\mathbf{x}_0 = [1, 2]^\top$ y $\mathbf{x}_1 = [2, 3]^\top$, respectivamente, calcule la distribución a posteriori del vector de pesos.

Nota:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Solution: $\mathbf{w} | \mathbf{x}_0, s_0, \mathbf{x}_1, s_1 \sim \mathcal{N}(\bar{\mathbf{w}}, \Sigma_w)$, con

$$\Sigma_w = \begin{bmatrix} 6 & 8 \\ 8 & 14 \end{bmatrix}^{-1} \quad \bar{\mathbf{w}} = \Sigma_w \begin{bmatrix} 1 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 2 \\ 5 \end{bmatrix}$$

Ejercicio R19

Considere el modelo de regresión no lineal $s_k = w_0 x_k + w_1 x_k^2 + \varepsilon_k$, en el que se asumen las siguientes distribuciones a priori: $\varepsilon \sim \mathcal{N}(0, 1)$ y $\mathbf{w} = [w_0, w_1]^T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. Se sabe además que las realizaciones de ruido (ε_k) son independientes entre sí e independientes de los pesos y del valor de x_k .

Se observan las salidas $s_0 = 2.5$ y $s_1 = 8.3$ para $x_0 = 1$ y $x_1 = 2$, respectivamente.

- Calcule la distribución a posteriori del vector de pesos.
- Calcule la media predictiva a posteriori para $x_2 = 3$, i.e., $\mathbb{E}\{s_2 | x_0, s_0, x_1, s_1\}$.

Nota:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Solution:

$$(a) \quad \Sigma_w = \begin{bmatrix} 6 & 9 \\ 9 & 18 \end{bmatrix}^{-1} = \frac{1}{9} \begin{bmatrix} 6 & -3 \\ -3 & 2 \end{bmatrix} \quad \bar{\mathbf{w}} = \Sigma_w \begin{bmatrix} 1 & 2 \\ 1 & 4 \end{bmatrix} \begin{bmatrix} 2.5 \\ 8.3 \end{bmatrix}$$

$$(b) \quad \mathbb{E}\{s_2 | x_0, s_0, x_1, s_1\} = [3 \ 9] \cdot \bar{\mathbf{w}}$$

Ejercicio R20

Se tiene un modelo del tipo $s_k = \mathbf{w}^\top \mathbf{x}_k + \varepsilon_k$, donde las entradas $\{\mathbf{x}_k\}$ son variables bidimensionales. Se sabe que los residuos son $\varepsilon_k \sim \mathcal{N}(0, 2)$, e independientes entre sí y de $\mathbf{w}$.

Suponga en principio que el vector de pesos tiene la siguiente distribución a priori $\mathcal{N}\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}\right)$.

Se observa $s_0 = 3$ para la entrada $\mathbf{x}_0 = [1 \ 0]^\top$.

- (a) Calcule la matriz de covarianza a posteriori del vector de pesos, $\text{Cov}[\mathbf{w}|s_0, \mathbf{x}_0]$.
- (b) Y si la distribución a priori de los pesos fuera $\mathcal{N}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}\right)$, ¿cuál sería la media a posteriori del vector de pesos, $\mathbb{E}[\mathbf{w}|s_0, \mathbf{x}_0]$?

Nota:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Solution:

$$(a) \text{Cov}[\mathbf{w}|s_0, \mathbf{x}_0] = \frac{1}{5} \begin{pmatrix} 6 & 2 \\ 2 & 14 \end{pmatrix}$$

$$(b) \mathbb{E}[\mathbf{w}|s_0, \mathbf{x}_0] = \frac{1}{5} \begin{pmatrix} 9 \\ 0 \end{pmatrix}$$

Ejercicio R21

Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_k, s_k\}_{k=0}^{K-1}$ para un problema de regresión, con el que se desea ajustar un modelo polinómico

$$\hat{s}_k = w_0 + w_1 x_{k,0} + w_2 x_{k,1} + w_3 x_{k,0}^2 + w_4 x_{k,1}^2$$

- (a) Indique la secuencia de ecuaciones que deben aplicarse para obtener los pesos del estimador LS dado $\mathcal{D}$, $\mathbf{w}_{\text{LS}}$. (Puede definir, en este apartado y los siguientes, las variables intermedias que considere oportunas para simplificar la notación)

Para abordar el problema mediante un enfoque basado en regresión bayesiana, se considera que las variables s_k están relacionadas con las entradas $\mathbf{x}_k$ a través del modelo

$$s_k = w_0 + w_1 x_{k,0} + w_2 x_{k,1} + w_3 x_{k,0}^2 + w_4 x_{k,1}^2 + \varepsilon_k,$$

en el que las variables ε_k , $k = 0, \dots, K-1$, son muestras de ruido independientes entre sí e independientes de los parámetros del modelo, con media 0 y varianza 2.

Además, se asume por simplicidad que la distribución a priori de cada uno de los coeficientes w_i del modelo es gaussiana de media 0 y varianza 100, y que todos los parámetros del modelo son, a priori, independientes entre sí.

- (b) Indique la secuencia de ecuaciones que deben aplicarse para obtener el estimador de máximo a posteriori de $\mathbf{w}$ dado $\mathcal{D}$, $\mathbf{w}_{\text{MAP}}$.
- (c) Utilizando la asunción de que la matriz de covarianzas a posteriori de $\mathbf{w}$ dado $\mathcal{D}$ es $3\mathbf{I}$, exprese la varianza predictiva de s dado $\mathbf{x}$, i.e., $\text{Var}\{s|\mathbf{x}, \mathcal{D}\}$.

Solution:

- (a) Definiendo

$$\mathbf{s} = [s_0, s_1, \dots, s_{K-1}]^\top \quad (\ell \times 1)$$

$$\mathbf{Z} = \begin{bmatrix} 1 & x_{0,0} & x_{0,1} & x_{0,0}^2 & x_{0,1}^2 \\ 1 & x_{1,0} & x_{1,1} & x_{1,0}^2 & x_{1,1}^2 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{K-1,0} & x_{K-1,1} & x_{K-1,0}^2 & x_{K-1,1}^2 \end{bmatrix} \quad (K \times 5)$$

Se tiene que $\mathbf{w}_{\text{LS}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{s}$.

- (b) Como $p(\mathbf{w}|\mathbf{s})$ es gaussiana, el máximo de dicha distribución coincide con su media, i.e., $\mathbf{w}_{\text{MAP}} = \mathbf{w}_{\text{MSE}}$, y pueden emplearse las ecuaciones para el cálculo de la media a posteriori:

$$\mathbf{V}_{\mathbf{w}} = \left[\frac{1}{\sigma_{\varepsilon}^2} \mathbf{Z}^{\top} \mathbf{Z} + \Sigma_p^{-1} \right]^{-1}$$

$$\mathbf{w}_{\text{MAP}} = \frac{1}{\sigma_{\varepsilon}^2} \mathbf{V}_{\mathbf{w}} \mathbf{Z}^{\top} \mathbf{s}$$

donde $\sigma_{\varepsilon} = \sqrt{2}$ y $\Sigma_p = 100\mathbf{I}$.

- (c) Definiendo $\mathbf{z} = [1, x_1, x_2, x_1^2, x_2^2]^{\top}$, tenemos $s = \mathbf{w}^{\top} \mathbf{z} + \varepsilon$. Por tanto:

$$\text{Var}\{s|\mathbf{s}\} = \mathbf{z}^{\top} \text{Cov}(\mathbf{w}|\mathbf{s}) \mathbf{z} + \sigma_{\varepsilon}^2 = 3\mathbf{z}^{\top} \mathbf{z} + 2,$$

donde se ha empleado la independencia de cada muestra de ruido, y la asunción del anunciado: $\text{Cov}(\mathbf{w}|\mathbf{s}) = 3\mathbf{I}$.

Ejercicio R22

Considere un problema de regresión multidimensional para el que se dispone de un conjunto de ℓ datos de entrenamiento, $\mathcal{D} = \{\mathbf{x}_k, s_k\}_{k=0}^{K-1}$, generados a partir de un modelo

$$s = w_0 x_0^2 + w_1 \ln x_1 + \epsilon,$$

donde w_0 y w_1 son parametros desconocidos y ϵ es ruido aleatorio de distribución $p_E(\epsilon) \sim \mathcal{N}(0, \sigma_n^2)$. Considere así mismo que las muestras de ruido asociadas a cada uno de los datos de entrenamiento son i.i.d. e independientes de las observaciones.

- (a) Obtenga el estimador ML de $\mathbf{w} = [w_0, w_1]$, $\mathbf{w}_{\text{ML}}$.
- (b) Asumiendo una distribución a priori para el vector de pesos $p(\mathbf{w}) \sim \mathcal{N}(\mathbf{w}_0, \Sigma_{\mathbf{w}})$, proporcione una regla de gradiente que permita obtener el estimador de máximo *a posteriori* de $\mathbf{w}$.

Solution: TBD


Ejercicio R23

Considere un problema de regresión multidimensional para el que se dispone del conjunto de datos de entrenamiento, $\mathcal{D} = \{x_k, s_k\}_{k=0}^{K-1}$, generados a partir de un modelo

$$s = f_{\mathbf{w}}(x) + \varepsilon,$$

donde $f_{\mathbf{w}}(x) = \mathbf{w}^{\top} \mathbf{z}$ es una función por determinar, $\mathbf{w}$ es un vector de parámetros de dicha función, $\mathbf{z}$ es un vector cuyas componentes se obtienen a partir de transformaciones de x , y ε es ruido aleatorio de distribución $p_E(\varepsilon) \sim \mathcal{N}(0, \sigma_{\varepsilon}^2)$. Considere asimismo que las muestras de ruido asociadas a cada uno de los datos de entrenamiento son i.i.d.

La siguiente figura proporciona un *scatter plot* de los datos de entrenamiento.



- (a) Proponga una transformación $\mathbf{z} = T(x)$ que proporcione un modelo adecuado para la resolución del problema a la vista del comportamiento de los datos de entrenamiento. Justifique su respuesta.
- (b) Explique cómo ajustaría el vector de pesos para minimizar el error cuadrático promedio evaluado sobre el conjunto de entrenamiento. Explícite las fórmulas que permitirían obtener la solución, así como los elementos de cualquier matriz o vector (distinto de $\mathbf{w}$) que formen parte de dichas fórmulas.

Solution:

- (a) Una posible respuesta sería un polinomio de grado 4, que puede tener hasta tres máximos o mínimos locales. Para este ejemplo: $\mathbf{z} = [1, x, x^2, x^3]$.
- (b) La solución solicitada es la solución de mínimos cuadrados, que coincide con la solución ML, por tanto: $\mathbf{w}_{LS} = \mathbf{w}_{ML} = \arg \min_{\mathbf{w}} \|\mathbf{s} - \mathbf{Z}\mathbf{w}\|^2 = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{s}$.

Ejercicio R24

Considere el modelo paramétrico dado por

$$s_k = w_0 \sqrt{x_k} + w_1(x_k - 4) + \varepsilon_k,$$

en el que las muestras de ruido ε_k , $i = 0, \dots, 3$, son gaussianas de media nula y varianza 2, independientes entre sí e independientes de los parámetros del modelo.

El vector de parámetros $\mathbf{w} = (w_1, w_2)^\top$ es desconocido, pero se sabe que su distribución a priori es $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \frac{1}{5}\mathbf{I})$.

Para estimar $\mathbf{w}$, se dispone solamente de un conjunto de tres muestras de entrenamiento

$$\mathcal{D} = \{(x_k, s_k), k = 0, \dots, 2\} = \{(0, 1), (1, 0), (9, 1)\}$$

- (a) Determine $\mathbb{E}\{s^2\}$ para una observación $x = 4$.
- (b) Determine la matriz de varianzas de la distribución a posteriori de $\mathbf{w}$ dados los datos.
- (c) Determine el estimador de mínimo error cuadrático medio de $\mathbf{w}$, $\mathbf{w}_{\text{MSE}}$.
- (d) Determine la predicción de mínimo error cuadrático medio $\hat{s}_{\text{MSE}}$ para una observación $x = 4$.
- (e) Determine $\mathbb{E}\{s^2|\mathcal{D}\}$ para una observación $x = 4$.

Solution:

(a)

$$s = w_0\sqrt{x} + w_1(x - 4) + \varepsilon = 2w_0 + \varepsilon$$

por tanto, dado que $\mathbf{w}_0$ y el ruido son independientes,

$$\mathbb{E}\{s^2\} = 4\mathbb{E}\{w_0^2\} + \sigma_\varepsilon^2$$

y, teniendo en cuenta la distribución a priori de $\mathbf{w}$, resulta

$$\mathbb{E}\{s^2\} = \frac{4}{5} + 2 = 2.8$$

(b)

$$\mathbf{V}_{\mathbf{w}} = \left(\frac{1}{\sigma_\varepsilon^2} \mathbf{Z}^\top \mathbf{Z} + \mathbf{V}_p^{-1} \right)^{-1}$$

siendo

$$\mathbf{Z} = \begin{pmatrix} 0 & -4 \\ 1 & -3 \\ 3 & 5 \end{pmatrix}$$

de modo que

$$\begin{aligned} \mathbf{V}_{\mathbf{w}} &= \left(\frac{1}{2} \begin{pmatrix} 10 & 12 \\ 12 & 50 \end{pmatrix} + 5\mathbf{I} \right)^{-1} = \begin{pmatrix} 10 & 6 \\ 6 & 30 \end{pmatrix}^{-1} \\ &= \frac{1}{132} \begin{pmatrix} 15 & -2 \\ -2 & 5 \end{pmatrix} \end{aligned}$$

(c)

$$\mathbf{w}_{\text{MSE}} = \frac{1}{\sigma_\varepsilon^2} \mathbf{V}_{\mathbf{w}} \mathbf{Z}^\top \mathbf{s}$$

siendo

$$\mathbf{s} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

de modo que

$$\begin{aligned} \mathbf{w}_{\text{MSE}} &= \frac{1}{2} \frac{1}{142} \begin{pmatrix} 30 & -4 \\ -4 & 10 \end{pmatrix} \begin{pmatrix} 0 & -4 \\ 1 & -3 \\ 3 & 5 \end{pmatrix}^\top \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \\ &= \frac{1}{284} \begin{pmatrix} 15 & -2 \\ -2 & 5 \end{pmatrix} \begin{pmatrix} 3 \\ 1 \end{pmatrix} = \frac{1}{284} \begin{pmatrix} 43 \\ -1 \end{pmatrix} \end{aligned}$$

(d)

$$\hat{s}_{\text{MSE}} = \mathbf{w}_{\text{MSE}}^\top \begin{pmatrix} \sqrt{x} \\ x - 4 \end{pmatrix} = \frac{43}{284} \sqrt{x} - \frac{1}{284} (x - 4)$$

(e) En este caso:

$$\mathbb{E}\{s^2|\mathcal{D}\} = 4\mathbb{E}\{w_0^2|\mathcal{D}\} + \sigma_\varepsilon^2 = 4(\text{var}\{w_0|\mathcal{D}\} + \mathbb{E}\{w_0|\mathcal{D}\}^2) + \sigma_\varepsilon^2 \quad (11)$$

y, teniendo en cuenta las expresiones de la media y la varianza a posteriori obtenidas en los apartados anteriores, resulta

$$\mathbb{E}\{s^2|\mathcal{D}\} = 4 \left(\frac{15}{142} + \frac{43^2}{284^2} \right) + 2 \quad (12)$$

Ejercicio R25

Considere el conjunto $\mathcal{D} = \{(\mathbf{x}_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^d$ y $s_k \in \mathbb{R}$. Se desea ajustar un modelo de regresión lineal según el modelo paramétrico

$$s = \mathbf{w}^\top \mathbf{x} + \varepsilon$$

con $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ y distribución a priori de pesos $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, v\mathbf{I})$.

Se sabe, además, que $\sum_k \mathbf{x}_k \mathbf{x}_k^\top = \mathbf{I}$ y $\sum_k \mathbf{x}_k s_k = \mathbf{1}$, siendo $\mathbf{1}$ el vector con todas sus componentes iguales a uno y longitud d .

- (a) Obtenga el estimador de máxima verosimilitud del vector de pesos, $\hat{\mathbf{w}}_{\text{ML}}$. Simplifique la expresión obtenida tanto como le sea posible, dejándola en función únicamente de σ_ε y v .

Suponga ahora que

$$\mathcal{D} = \left\{ \left(\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, 1 \right), \left(\begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}, 0 \right) \right\} \quad (13)$$

- (b) Obtenga el estimador de máxima verosimilitud del vector de pesos, $\hat{\mathbf{w}}_{\text{MAP}}$. Simplifique la expresión obtenida tanto como le sea posible, dejándola en función únicamente de σ_ε y v .
- (c) Calcule la media predictiva de s , $\mathbb{E}\{\mathbf{w}^\top \mathbf{x} | \mathcal{D}\}$, de acuerdo al modelo propuesto.
- (d) Calcule la covarianza a posteriori de s , $\text{Cov}(s | \mathcal{D})$, de acuerdo al modelo propuesto. Justifique si el modelo muestra mayor confianza acerca de sus predicciones para ciertos valores de $\mathbf{x}$.

Solution:

(a)

$$\hat{\mathbf{w}}_{\text{ML}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{s} = \mathbf{1}$$

(b) En este caso tenemos

$$\mathbf{X} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} \quad \mathbf{s} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

y por tanto $\mathbf{X}^\top \mathbf{X} = \mathbf{I}$ y $\mathbf{X}^\top \mathbf{s} = (1/\sqrt{2}) \cdot \mathbf{1}$. Sustituyendo en las expresiones para calcular $\hat{\mathbf{w}}_{\text{MAP}}$ se obtiene:

$$\mathbf{V}_{\mathbf{w}} = \left[\frac{1}{\sigma_\varepsilon^2} \mathbf{X}^\top \mathbf{X} + (v\mathbf{I})^{-1} \right]^{-1} = \left[\left(\frac{1}{\sigma_\varepsilon^2} + \frac{1}{v} \right) \mathbf{I} \right]^{-1} = \frac{\sigma_\varepsilon^2 \cdot v}{\sigma_\varepsilon^2 + v} \mathbf{I}$$

$$\hat{\mathbf{w}}_{\text{MAP}} = \frac{1}{\sigma_\varepsilon^2} \mathbf{V}_{\mathbf{w}} \mathbf{X}^\top \mathbf{s} = \frac{v}{\sqrt{2}(\sigma_\varepsilon^2 + v)} \mathbf{1}$$

(c)

$$\mathbb{E}\{\mathbf{w}^\top \mathbf{x} | \mathcal{D}\} = \hat{\mathbf{w}}_{\text{MAP}}^\top \mathbf{x} = \frac{v}{\sqrt{2}(\sigma_\varepsilon^2 + v)} \mathbf{1}^\top \mathbf{x}$$

(d)

$$\text{Cov}(\mathbf{w}^\top \mathbf{x} + \varepsilon | \mathcal{D}) = \mathbf{x}^\top \mathbf{V}_{\mathbf{w}} \mathbf{x} + \sigma_\varepsilon^2 = \sigma_\varepsilon^2 \left[1 + \frac{v}{\sigma_\varepsilon^2 + v} \|\mathbf{x}\|^2 \right]$$

La confianza del modelo decrece al aumentar la norma de $\mathbf{x}$.

2.5. Regresión bayesiana. Modelos no gaussianos**Ejercicio R26**

Considere que el conjunto $\mathcal{D} = \{(x_k, s_k), k = 0, \dots, K-1\}$ contiene muestras i.i.d. provenientes

de una distribución

$$p(s|x, w) = wx \exp(-wxs), \quad s \geq 0, x \geq 0, w \geq 0$$

El parámetro w es desconocido, pero está dado por una distribución a priori

$$p(w) = \exp(-w), \quad w \geq 0$$

- Suponiendo conocido w , determine la predicción de mínimo error cuadrático medio de s , $\hat{s}_{\text{MSE}}$.
- Determine una expresión de la función de verosimilitud del parámetro w para el conjunto de datos observados, $\mathcal{D}$.
- Determine la distribución a posteriori del parámetro w dados los datos
- Determine el estimador MAP de w dados los datos.
- Determine la media a posteriori de w dados los datos.
- Determine la media predictiva de s para una entrada x y dados los datos, (es decir, $\hat{s} = \mathbb{E}\{s|\mathbf{s}, x\}$)

Indicación: para todo entero N y todo $z > 0$

$$\int_0^\infty w^N \exp(-wz) dw = \frac{N!}{z^{N+1}}$$

Solution:

(a) $\hat{s}_{\text{MSE}} = \mathbb{E}\{S|x, w\} = \frac{1}{wx}$

(b)

$$\begin{aligned} p(\mathbf{s}|w) &= \prod_{k=0}^{K-1} wx_k \exp(-wx_k s_k) = w^K \left(\prod_{k=0}^{K-1} x_k \right) \exp \left(-w \sum_{k=0}^{K-1} x_k s_k \right) \\ &= w^K \left(\prod_{k=0}^{K-1} x_k \right) \exp(-w \mathbf{X}^\top \mathbf{s}) \end{aligned}$$

siendo $\mathbf{X} = (x_0, x_1, \dots, x_{K-1})^\top$ y $\mathbf{s} = (s_0, s_1, \dots, s_{K-1})^\top$

(nótese que en este caso la matriz $\mathbf{X}$ dispone únicamente de una columna)

(c)

$$\begin{aligned} p(w|\mathbf{s}) &= \frac{p(\mathbf{s}|w)p(w)}{p(\mathbf{s})} = \frac{w^K \left(\prod_{k=0}^{K-1} x_k \right) \exp(-w \mathbf{X}^\top \mathbf{s}) \exp(-w)}{p(\mathbf{s})} \\ &= \frac{w^K \exp(-w(1 + \mathbf{X}^\top \mathbf{s}))}{\int_0^\infty w^K \exp(-w(1 + \mathbf{X}^\top \mathbf{s})) dw} \\ &= \frac{(1 + \mathbf{X}^\top \mathbf{s})^{K+1}}{K!} w^K \exp(-w(1 + \mathbf{X}^\top \mathbf{s})) \end{aligned}$$

(d)

$$\begin{aligned} w_{\text{MAP}} &= \underset{w}{\operatorname{argmax}} \log(p(w|\mathbf{s})) = \underset{w}{\operatorname{argmax}} \{K \log w - w(1 + \mathbf{X}^\top \mathbf{s})\} \\ &= \frac{K}{1 + \mathbf{X}^\top \mathbf{s}} \end{aligned}$$

(e)

$$\begin{aligned}
 w_{\text{MSE}} &= \int_0^\infty wp(w|\mathbf{s})dw = \frac{(1 + \mathbf{X}^\top \mathbf{s})^{K+1}}{K!} \int_0^\infty w^{K+1} \exp(-w(1 + \mathbf{X}^\top \mathbf{s})) dw \\
 &= \frac{(1 + \mathbf{X}^\top \mathbf{s})^{K+1}}{K!} \frac{(K+1)!}{(1 + \mathbf{X}^\top \mathbf{s})^{K+2}} \\
 &= \frac{K+1}{1 + \mathbf{X}^\top \mathbf{s}}
 \end{aligned}$$

(f)

$$\begin{aligned}
 \hat{s} &= \mathbb{E}\{S|\mathbf{s}, x\} = \int_0^\infty \mathbb{E}\{S|\mathbf{s}, x, w\}p(w|\mathbf{s})dw = \int_0^\infty \frac{1}{wx}p(w|\mathbf{s})dw \\
 &= \frac{(1 + \mathbf{X}^\top \mathbf{s})^{K+1}}{K!x} \int_0^\infty w^{K-1} \exp(-w(1 + \mathbf{X}^\top \mathbf{s})) dw \\
 &= \frac{1 + \mathbf{X}^\top \mathbf{s}}{Kx}
 \end{aligned}$$

Ejercicio R27

Considere que el conjunto $\mathcal{D} = \{(x_k, s_k), k = 0, \dots, K-1\}$ contiene muestras i.i.d. provenientes de una distribución

$$p(s|w, x) = \frac{wx}{s} \exp(-wx \ln(s)), \quad s \geq 1, \quad w \geq 0, \quad x \geq 0$$

El parámetro w está dado por una distribución a priori exponencial

$$p(w) = \exp(-w), \quad w \geq 0$$

- Suponiendo conocido w , determine la predicción de mínimo error cuadrático medio de S , $\hat{s}_{\text{MSE}}$, para $w > 1$, $x > 1$.
- Determine una expresión de la función de verosimilitud del parámetro w para el conjunto de datos observados, $\mathcal{D}$. Expresé la solución en función de los estadísticos

$$r_K = \prod_{k=0}^{K-1} \frac{x_k}{s_k}$$

$$t_K = \sum_{k=0}^{K-1} x_k \ln(s_k)$$

- Determine la distribución a posteriori del parámetro w dados los datos, $p(w|\mathbf{s})$. Utilice de nuevo los estadísticos r_K y/o t_K si le resultan convenientes para simplificar las expresiones.
- Determine el estimador de mínimo error cuadrático medio de w dados los datos, $\hat{w}_{\text{MSE}}$

Indicación: para todo entero $n > 0$ y todo número real $z > 0$

$$\int_0^\infty w^n \exp(-wz)dw = \frac{n!}{z^{n+1}}$$

Solution:

(a)

$$\begin{aligned}
\hat{s}_{\text{MSE}} &= \mathbb{E}\{S|x, w\} \\
&= \int_1^\infty wx \exp(-wx \ln(s)) ds \\
&= wx \int_1^\infty s^{-wx} ds = wx \left[\frac{s^{1-wx}}{1-wx} \right]_1^\infty \\
&= \frac{wx}{wx-1}
\end{aligned}$$

donde la última igualdad es correcta dado que $wx > 1$.

(b) La función de verosimilitud es

$$\begin{aligned}
p(\mathbf{s}|w) &= \frac{w^K \prod_{k=0}^{K-1} x_k}{\prod_{k=0}^{K-1} s_k} \exp\left(-w \sum_{k=0}^{K-1} x_k \ln(s_k)\right) \\
&= r_K w^K \exp(-w \cdot t_K), \quad \min_k s_k \geq 1
\end{aligned}$$

(c) Sabiendo que

$$\begin{aligned}
p(\mathbf{s}) &= \int p(\mathbf{s}|w)p(w)dw \\
&= \int_0^\infty r_K w^K \exp(-t_K w) \exp(-w)dw \\
&= r_K \int_0^\infty w^K \exp(-(1+t_K)w) dw \\
&= r_K \frac{K!}{(1+t_K)^{K+1}}
\end{aligned}$$

la distribución a posteriori será

$$\begin{aligned}
p(w|\mathbf{s}) &= \frac{p(w)p(\mathbf{s}|w)}{p(\mathbf{s})} \\
&= \frac{r_K w^K \exp(-(1+t_K)w)}{r_K} \frac{(1+t_K)^{K+1}}{K!} \\
&= \frac{(1+t_K)^{K+1}}{K!} w^K \exp(-(1+t_K)w), \quad w \geq 0
\end{aligned}$$

(d) El estimador de mínimo MSE de w será

$$\begin{aligned}
\hat{w}_{\text{MSE}} &= \mathbb{E}\{w|\mathbf{s}\} \\
&= \frac{(1+t_K)^{K+1}}{K!} \int_0^\infty w^{K+1} \exp(-(1+t_K)w) dw \\
&= \frac{(1+t_K)^{K+1}}{K!} \frac{(K+1)!}{(1+t_K)^{K+2}} \\
&= \frac{K+1}{1+t_K}
\end{aligned}$$

2.6. kNN y regresión paramétrica

Ejercicio R28

Considere el siguiente conjunto de entrenamiento para un problema de regresión:

$$\mathcal{D} = \{(x_k, y_k)\}_{k=0}^3 = \{(-3, -5), (-1, -2), (1, 6), (3, 9)\}$$

(a) Obtenga y represente gráficamente la función de regresión asociada a un modelo 2-NN.

Considere para el resto del problema el siguiente modelo paramétrico para la generación de los datos

$$s_k = w_1 x_k + w_2 x_k^2 + \varepsilon_k,$$

en el que las muestras de ruido ε_k , $i = 0, \dots, 3$, son realizaciones independientes entre sí e independientes de los parámetros del modelo. Asumiendo además las distribuciones a priori $\mathbf{w} = [w_1, w_2]^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ y $\varepsilon \sim \mathcal{N}(0, 2)$, calcule:

(b) La solución de máxima verosimilitud, $\hat{\mathbf{w}}_{\text{ML}}$.

(c) La solución de máxima a posteriori, $\hat{\mathbf{w}}_{\text{MAP}}$.

Solution:

(a)

$$\hat{y} = \begin{cases} -3, 5, & x \in [-\infty, -1] \\ 2, & x \in [-1, 1] \\ 7, 5, & x \in [1, \infty] \end{cases}$$

(b)

$$\begin{aligned} \hat{s}_{\text{ML}} &= \mathbf{w}_{\text{ML}}^\top \begin{bmatrix} x \\ x^2 \end{bmatrix} \\ \mathbf{w}_{\text{ML}} &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{s} \end{aligned}$$

donde se han definido las matrices

$$\mathbf{Z} = \begin{bmatrix} -3 & 9 \\ -1 & 1 \\ 1 & 1 \\ 3 & 9 \end{bmatrix} \quad \mathbf{s} = \begin{bmatrix} -5 \\ -2 \\ 6 \\ 9 \end{bmatrix}$$

La solución final es

$$\hat{s}_{\text{ML}} = \frac{5}{2}x + \frac{10}{41}x^2$$

(c)

$$\begin{aligned} \hat{s}_{\text{MAP}} &= \mathbf{w}_{\text{MAP}}^\top \begin{bmatrix} x \\ x^2 \end{bmatrix} \\ \mathbf{w}_{\text{MAP}} &= \frac{1}{2} \left(\frac{1}{2} \mathbf{Z}^\top \mathbf{Z} + \mathbf{I} \right)^{-1} \mathbf{Z}^\top \mathbf{s} \\ \hat{s}_{\text{MAP}} &= \frac{25}{11}x + \frac{4}{33}x^2 \end{aligned}$$

3. Clasificación

3.1. k -NN

Ejercicio C1

Se pretende diseñar un clasificador binario mediante un conjunto de datos $\{(\mathbf{x}_k, y_k), k = 0, \dots, 999\}$, con observaciones $\mathbf{x}_k \in \mathbb{R}^2$ y etiquetas binarias $y_k \in \{0, 1\}$. Se desea aplicar un clasificador basado en los k vecinos más próximos (k -NN).

Suponga que se destinan el 80 % de los datos para validación.

- Explique los pasos del método de validación cruzada de 10 partes (10-fold) para la determinación del hiperparámetro k .
- Determine cuántas distancias calcularía entre puntos del dataset para completar dicha validación cruzada.
- Determine cuántas distancias calcularía entre puntos del dataset para completar la validación cruzada si, en lugar de validación cruzada de 10 partes se aplica un procedimiento de *Leave-One-Out* (LOO).

Solution:

(a)

(b) Se utilizan 800 muestras para validación. Por tanto, habría que calcular:

- Por cada parte (*fold*), la distancia de las 80 muestras de validación a las 720 de train, es decir: $80 \times 720 = 57.600$ distancias.
- Para todas las partes: $10 \times 57.600 = 576.000$ distancias.

Esta cifra puede reducirse a la mitad (288.000) si guardamos las distancias ya calculadas en memoria, de modo tal que no se calcule la distancia de un punto x_a a otro x_b si ya se calculó la distancia de x_b a x_a en otro paso de validación.

(c) De modo similar, se precisarían $800 \times 1 \times 799 = 639.200$ distancias, que pueden reducirse a la mitad (319.500) guardando distancias ya calculadas en memoria.


Ejercicio C2

Se dispone de una colección de datos etiquetados $\mathcal{S} = \{(\mathbf{x}_k, y_k), n = 0, \dots, 127\}$ relativos a un problema de clasificación binaria. Las etiquetas y_k toman valores binarios en $\{0, 1\}$. Para clasificar cierta observación $\mathbf{x}$ aplicando el algoritmo k -NN, en principio es necesario calcular todas las distancias (cuadráticas) $d_n = \|\mathbf{x} - \mathbf{x}_k\|^2$

- Explique brevemente qué hace el algoritmo k -NN después de calcular todas las distancias d_n .
- Suponga que las observaciones tienen dimensión 1, es decir, $x_k \in \mathbb{R}$. En tal caso, es posible evitar el cálculo de todas las distancias d_n para clasificar un dato nuevo. Suponga, por ejemplo, que todas las observaciones están ordenadas de menor a mayor, es decir, $x_0 < x_1 < \dots < x_{127}$. Sugiera un procedimiento para aplicar 1-NN que no precise calcular todas las distancias.
- Indique cómo modificaría su algoritmo del apartado b para implementar un clasificador 3-NN. ¿Necesitaría calcular todas las distancias d_k ?

Ejercicio C3


Considere el conjunto de datos de entrenamiento de la figura, para un problema de clasificación binaria.



- (a) Dibuje de forma aproximada la frontera de clasificación 1-NN.
- (b) Determine las decisiones del clasificador k -NN para una entrada $\mathbf{x} = (2.5, 3.5)^\top$, para todos los valores impares y positivos de k , con $k < 12$.
- (c) Determine la estimación de la probabilidad a posteriori de la clase 1, para entrada $\mathbf{x} = (2.5, 3.5)^\top$, de acuerdo con el algoritmo k -NN, para todos los valores impares de k , con $k < 12$.
- (d) A pesar de que el número de muestras disponibles de cada categoría son iguales, se sabe que la probabilidad a priori de la clase 1 es doble que la de la clase 0, es decir, $P(Y = 1) = \frac{2}{3}$. Sugiera alguna modificación del algoritmo k -NN para adaptarse a esta discrepancia entre las probabilidades a priori de las clases y las proporciones de ambas en el conjunto de entrenamiento.

Solution:

- (a) La frontera se muestra en la figura:



- (b) El clasificador k -NN asigna la muestra a la clase +1 para todos los valores impares de k .
- (c) Las estimaciones son

k	1	3	5	7	9	11
Prob	1	1	$\frac{4}{5}$	$\frac{4}{7}$	$\frac{5}{9}$	$\frac{7}{11}$

Ejercicio C4

Considere un conjunto de muestras unidimensionales $\{(x_k, y_k), k = 0, \dots, 7\}$ para la resolución de un problema de clasificación:

k	0	1	2	3	4	5	6	7
x_k	-13	-12	-5	-3	1	2	3	5
y_k	0	0	1	1	0	1	1	1

- (a) Represente las regiones de decisión de un clasificador 1-NN.
- (b) Estime la probabilidad a posteriori de la clase 1 en $x = -0.25$ que proporcionaría un clasificador 3-NN.

Solution:

$$(a) \hat{y} = \begin{cases} 0, & x \in [-1, 1.5] \text{ or } x < -8.5 \\ 1 & x \in [-8.5, -1] \text{ or } x > 1.5 \end{cases}$$

$$(b) P_{H|x}(1 | -0.25) = \frac{2}{3}$$

Ejercicio C5

La consistencia de un clasificador es una propiedad asociada a su comportamiento conforme aumenta el número de muestras de entrenamiento. Proponga un ejemplo que ilustre que el clasificador 1-NN no es consistente. Justifique su respuesta comparando la tasa de error que en dicho ejemplo obtendría el clasificador de Bayes con la tasa de error del clasificador 1-NN conforme el número de muestras de entrenamiento tiende a infinito.

Ejercicio C6

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_k, s_k\}_{k=0}^5$ para un problema de clasificación:

i	0	1	2	3	4	5
$x_{i,0}$	0	0	1	2	2	3
$x_{i,1}$	0	1	0	2	3	2
y_i	0	0	0	0	1	1

- (a) Represente gráficamente, de forma aproximada, los datos de entrenamiento, junto con la frontera de clasificación del algoritmo del vecino más próximo (1-NN) que se obtiene con estos datos.
- (b) Represente gráficamente, de forma aproximada, los datos de entrenamiento, junto con la frontera de clasificación de una SVM lineal sin término de riesgo empírico ($C = 0$).
- (c) Para evaluar las prestaciones del algoritmo, se desea aplicar validación cruzada por Leave-One-Out (LOO) sobre estos datos. Determine la probabilidad de error promedio en validación por este procedimiento en ambos casos (1-NN y SVM).

Ejercicio C7

Considere un problema de clasificación binaria (categoría $y \in \{0, 1\}$) y bidimensional (observación $\mathbf{x} = (x_1, x_2)^T \in \mathbb{R}^2$) en el que las verosimilitudes de ambas hipótesis son:

$$\begin{aligned} p(\mathbf{x}|Y=0) &= 1, & -0.5 \leq x_1 \leq 0.5, & & -0.5 \leq x_2 \leq 0.5 \\ p(\mathbf{x}|Y=1) &= 1, & 0 \leq x_1 \leq 1, & & 0 \leq x_2 \leq 1 \end{aligned}$$

se sabe además que la hipótesis $Y = 0$ tiene probabilidad *a priori* $P(Y = 0) = \frac{2}{3}$.

- (a) Represente gráficamente las regiones de clasificación del clasificador de mínima probabilidad de error
- (b) Calcule dicha probabilidad de error.
- (c) Obtenga la probabilidad de error del clasificador 1-NN según el número de muestras de entrenamiento aumenta hacia infinito.

Solution:

- (a) El clasificador de mínima probabilidad de error está dado por

$$P(Y = 1|\mathbf{x}) \underset{D=0}{\overset{D=1}{\geq}} P(Y = 0|\mathbf{x})$$

siendo D la decisión del clasificador, es decir

$$\frac{1}{3}p(\mathbf{x}|Y = 1) \underset{D=0}{\overset{D=1}{\geq}} \frac{2}{3}P(\mathbf{x}|Y = 0)$$

En las regiones donde las distribuciones no se solapan, se decidirá la clase con verosimilitud no nula. En la región en la que se solapan, ambas verosimilitudes tienen altura 1, y por tanto, de acuerdo con la regla anterior, se decidirá 0. Por tanto, se decidirá $D = 0$ siempre que $x_1 \leq 0.5$ y $x_2 \leq 0.5$.

- (b) La probabilidad de error puede escribirse como

$$\begin{aligned} P_e &= P(D = 0, Y = 1) + P(D = 1, Y = 0) \\ &= \frac{1}{3} \times P(D = 0|Y = 1) + \frac{2}{3}P(D = 1|Y = 0) \end{aligned} \quad (14)$$

Cuando $Y = 0$ siempre se decide 0, luego

$$P(D = 1|Y = 0) = 0$$

El primer término se puede calcular como

$$P(D = 0|Y = 1) = \int_0^{0.5} \int_0^{0.5} p(\mathbf{x}|Y = 1)dx = \frac{1}{4}$$

Por tanto

$$P_e = \frac{1}{3} \times \frac{1}{4} = \frac{1}{12}$$

- (c) A medida que el número de muestras tiende a infinito, todos los errores tenderán a producirse en la región
- $\mathcal{R}$
- en la que se solapan las dos distribuciones. Es decir:

$$\begin{aligned} P_e &= P(D \neq Y) = \\ &= P(D \neq Y | \mathcal{R})P(\mathcal{R}) + P(D \neq Y | \text{no } \mathcal{R})(1 - P(\mathcal{R})) = \\ &= \frac{1}{4} \cdot P(D \neq Y | \mathcal{R}) \end{aligned} \quad (15)$$

Dado que las distribuciones son uniformes, en la región de solapamiento la decisión no depende de Y , luego

$$\begin{aligned} P_e &= \frac{1}{4} (P(D = 0, Y = 1 | \mathcal{R}) + P(D = 1, Y = 0 | \mathcal{R})) = \\ &= \frac{1}{4} (P(D = 0 | \mathcal{R}) \cdot P(Y = 1 | \mathcal{R}) + P(D = 1 | \mathcal{R}) \cdot P(Y = 0 | \mathcal{R})) \\ &= \frac{1}{4} \left(\frac{2}{3} \cdot \frac{1}{3} + \frac{1}{3} \cdot \frac{2}{3} \right) \\ &= \frac{1}{9} \end{aligned} \quad (16)$$

Ejercicio C8

Considere un problema de clasificación binaria (categoría $y \in \{0, 1\}$) unidimensional para el que se dispone del siguiente conjunto de muestras de entrenamiento:

$$\mathcal{D} = \{(x_k, y_k)\}_{k=0}^8 = \{(0, 0), (0.8, 0), (1.6, 0), (2, 0), (2.6, 0), (2.8, 0), (1.2, 1), (1.4, 1), (1.8, 1)\}$$

Se sabe además que las verosimilitudes de ambas hipótesis son:


$$\begin{aligned} p(x|Y=0) &= 1/3, & 0 \leq x \leq 3, \\ p(x|Y=1) &= 1, & 1 \leq x \leq 2 \end{aligned} \quad (17)$$

se sabe además que la hipótesis $Y=0$ tiene probabilidad *a priori* $P(Y=0) = \frac{2}{3}$.

- Represente gráficamente la estimación de la probabilidad a posteriori $P(Y=1|x)$ obtenida por un clasificador 3-NN.
- Determine las regiones de clasificación de dicho clasificador 3-NN.
- Obtenga la probabilidad de error del clasificador 3-NN empleando para ello la información probabilística disponible.
- Obtenga el clasificador de mínima probabilidad de error.

Solution:

- La figura muestra la probabilidad a posteriori como función de x . Podemos construir dicha función buscando los vecinos más próximos al mover x de izquierda a derecha. A la izquierda de $x = 0,7$ tenemos únicamente una muestra de clase 1, mientras que justo a la derecha dos de las tres muestras más cercanas son de clase 1. De manera similar, podemos encontrar los otros dos cambios en el valor de la función.



- El clasificador 3-NN decide en favor de $Y=1$ cuando al menos dos de las tres muestras más cercanas son de clase 1. Por lo tanto, a la vista de la figura anterior, se decide según

$$D = \begin{cases} 1 & 0.7 < x < 1.7 \\ 0 & \text{en otro caso} \end{cases}$$

-

$$P_{FA} = P(D=1|H=0) = P(0.7 < x < 1.7|H=0) = \int_{0.7}^{1.7} \frac{1}{3} dx = \frac{1}{3}$$

$$P_M = P(D=0|H=1) = P(x < 0.7 \text{ o } x > 1.7|H=1) = \int_{1.7}^2 dx = 0.3$$

$$P_e = P_{FA}P_H(0) + P_MP_H(1) = \frac{2}{3} \cdot \frac{1}{3} + \frac{1}{3} \cdot 0.3 = \frac{2.9}{9}$$

- (d) En $0 < x < 1$ y $2 < x < 3$ se debe decidir la única clase posible, por tanto $D = 0$ en esas regiones.

En $1 < x < 2$ se debe decidir la hipótesis con mayor probabilidad a posteriori. Por tanto hay que comparar $P_{H|X}(0|x)$ y $P_{H|X}(1|x)$ en dicho intervalo:

$$P_{H|X}(0|x) = \frac{p_{x|H}(x|0)P_H(0)}{p_X(x)} = \frac{2/9}{p_X(x)}$$

$$P_{H|X}(1|x) = \frac{p_{x|H}(x|1)P_H(1)}{p_X(x)} = \frac{1/3}{p_X(x)}$$

Por tanto, con independencia del valor de x , en dicho intervalo se tiene $P_{H|X}(1|x) > P_{H|X}(0|x)$ y el clasificador de mínima probabilidad de error resulta:

$$D = \begin{cases} 1 & 1 < x < 2 \\ 0 & \text{en otro caso} \end{cases}$$

Podemos comprobar que tiene menor probabilidad de error que este clasificador tiene efectivamente menor probabilidad de error que el 3NN:


$$P'_{\text{FA}} = P(D = 1|H = 0) = P(1 < x < 2|H = 0) = \int_1^2 \frac{1}{3} dx = \frac{1}{3}$$

$$P'_M = P(D = 0|H = 1) = P(x < 1 \text{ o } x > 2|H = 1) = 0$$

$$P'_e = P'_{\text{FA}}P_H(0) + P'_MP_H(1) = \frac{2}{3} \cdot \frac{1}{3} = \frac{2}{9}$$

Ejercicio C9

Considere el conjunto de 20 muestras de entrenamiento de la figura, para un problema de clasificación binaria.



- Determine la decisión de los clasificador k -NN para una entrada $\mathbf{x} = (4, 3)^\top$, para todos los valores impares y positivos de k , con $k \leq 9$.
- Determine la estimación de la probabilidad a posteriori de la clase 1, para entrada $\mathbf{x} = (4, 3)^\top$, de acuerdo con el algoritmo k -NN, para todos los valores impares de k , con $k \leq 9$.
- Determine la tasa de error de validación que resulta de aplicar validación cruzada por Leave-One-Out (LOO) sobre estos datos, al emplear el clasificador 1-NN.

- (d) Considere el clasificador dado por el modelo de regresión logística

$$P(1|\mathbf{x}, \mathbf{w}) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{z})}$$

siendo $\mathbf{z} = (x_0, x_1, 1)^\top$. Determine el número de errores del clasificador dado por $\mathbf{w} = (2, 0, -9)^\top$, calculados sobre el conjunto de entrenamiento.

Solution:

(a)

k	1	3	5	7	9
$\hat{y}$	0	0	1	0	1

(b)

k	1	3	5	7	9
Prob	0	$\frac{1}{3}$	$\frac{3}{5}$	$\frac{3}{7}$	$\frac{5}{9}$

- (c) Dado que 7 muestras tienen su vecino más próximo de la otra categoría, la tasa de error de validación LOO es $\frac{7}{20}$.
- (d) El clasificador decide 1 cuando $\mathbf{w}^\top \mathbf{z} > 0$, es decir, $2x_0 - 9 > 0$ o, equivalentemente, $x_0 > 4.5$. Observando la figura se comprueba que dicho clasificador clasifica 3 muestras erróneamente, luego la tasa de error es de $\frac{3}{20} = 0.15$

3.2. Regresión logística

Ejercicio C10

- (a) Explique brevemente qué modelo estadístico de los datos supone implícitamente un algoritmo de regresión logística.
- (b) Desde el punto de vista de la función que se optimiza, ¿en qué se diferencia el estimador MAP de los parámetros del modelo y el ML?

Ejercicio C11

Se dispone de una colección de datos etiquetados $\mathcal{S} = \{(\mathbf{x}_k, y_k), k = 0, \dots, 99\}$ relativos a un problema de clasificación binaria. Las etiquetas y_k toman valores binarios en $\{0, 1\}$. Según se ha estudiado, la ecuación que define la solución de máximo a posteriori de un modelo de regresión logística es

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg \min_{\mathbf{w}} \{L(\mathbf{w}) - \log[p_{\mathbf{w}}(\mathbf{w})]\}$$

donde $p_{\mathbf{w}}(\mathbf{w})$ es el prior del vector de pesos y $L(\mathbf{w})$ es la verosimilitud del modelo dada por

$$L(\mathbf{w}) = - \sum_{k=0}^{99} \log [P_{Y|\mathbf{X}}(y_k|\mathbf{x}_k, \mathbf{w})]$$

- (a) Particularice la verosimilitud para el modelo de regresión logística estudiado en la asignatura.
- (b) Derive un algoritmo de descenso de gradiente que permita optimizar la solución de forma iterativa asumiendo un prior gaussiano para $\mathbf{w}$, con media $\mathbf{w}_0$ y matriz de covarianzas $v\mathbf{I}$.

Ejercicio C12

Se dispone de una colección de datos de entrenamiento etiquetados $\mathcal{S} = \{(\mathbf{x}_k, y_k), n = 1, \dots, 100\}$ para un problema de clasificación binaria. Las etiquetas y_k toman valores binarios en $\{0, 1\}$.

Considerando el modelo de regresión logística estudiado en la asignatura, derive un algoritmo de descenso de gradiente para obtener la solución de máximo *a posteriori*, asumiendo un prior gaussiano para $\mathbf{w}$, con media $\mathbf{w}_0$ y matriz de covarianzas $v\mathbf{I}$.

Ejercicio C13

Sea $g(t)$ la función logística, demuestre la propiedad de simetría ($g(-t) = 1 - g(t)$) y que se trata de una función monótona con derivada $g'(t) = g(t)[1 - g(t)] \geq 0$

Ejercicio C14

Determine la regla de descenso por gradiente para la estimación MAP de los coeficientes de regresión logística con prior laplaciano.

$$p_{\mathbf{w}}(\mathbf{w}) = \frac{1}{(2C)^N} \exp\left(-\frac{1}{C}\|\mathbf{w}\|_1\right)$$

3.3. k -NN y regresión logística**Ejercicio C15**

Se pretende resolver un problema de clasificación binaria para el que se dispone de un conjunto de N muestras de entrenamiento, $\mathcal{D} = \{(\mathbf{x}_n, y_n), n = 0, \dots, N-1\}$. Las entradas $\mathbf{x}_n$ tienen dimensión D . Para ello se consideran las siguientes alternativas:

- Una implementación básica del clasificador k -NN, optimizando el parámetro k para todos los valores en el rango $1 \leq k \leq 100$ mediante validación cruzada (10-fold).
- Un modelo de regresión logística, con transformación polinómica, incluyendo todos (y solamente) los términos polinómicos de grado 1 y 2 (esto es, $x_0, x_1, \dots, x_{D-1}, x_0^2, x_0x_1, x_0x_2, \dots$), entrenado con la regla de aprendizaje por gradiente estocástico para estimación de máxima verosimilitud, durante un sólo ciclo de entrenamiento (es decir, aplicando la regla de aprendizaje una sola vez por muestra de entrenamiento), y con un valor prefijado del paso de aprendizaje (learning step).

Discuta las ventajas e inconvenientes de ambas alternativas desde el punto de vista de la carga computacional. Para ello, determine, de forma aproximada, el número de multiplicaciones requerido para

- (a) Clasificar una entrada arbitraria, $\mathbf{x}$, tras el entrenamiento, mediante regresión logística.
- (b) Clasificar una entrada arbitraria, $\mathbf{x}$, mediante k -NN, para un valor arbitrario de k .
- (c) Ajustar el modelo de regresión logística con los datos de entrenamiento.
- (d) Ajustar el hiperparámetro k , del k -NN.

No es necesario realizar un cálculo exacto. Principalmente, se debe determinar cómo depende la carga computacional, en cada caso, de la dimensión D y del tamaño del dataset, N .

Solution:

- (a) Dado que la transformación polinómica extiende las D variables de entrada con $\frac{1}{2}D(D+1)$ términos de grado 2, la entrada transformada tiene dimensión $\frac{1}{2}D(D+3)$. Por tanto, se requieren:

- Para calcular la transformación polinómica: $\frac{1}{2}D(D+1)$ multiplicaciones.
- Para multiplicar por los pesos del modelo: $\frac{1}{2}D(D+3)$ multiplicaciones

Por tanto, se requieren $D(D+2)$ multiplicaciones (aproximadamente, $\sim D^2$)

- (b) En una implementación básica, se calcula la distancia a todas las muestras de entrenamiento. Cada distancia requiere D multiplicaciones, por tanto se necesitan DN multiplicaciones.

(c) La regla de gradiente sobre una muestra requiere:

- Aplicar el modelo a una muestra: $D(D + 2)$ (como se ha visto en (a))
- Aplicar la regla de gradiente estocástico: $\frac{1}{2}D(D + 3) + 1$ multiplicaciones

Por tanto, se requieren $\frac{1}{2}D(3D + 7)N + N$ multiplicaciones (de forma aproximada, $\sim \frac{3}{2}D^2N$ multiplicaciones, o del orden de D^2N).

(d) En una implementación básica, por cada valor de k y cada paso de validación (*fold*), se requiere calcular la distancia del 10 % de las muestras al restante 90 %, es decir, $0.1N \cdot 0.9 \cdot DN = 0.09DN^2$ multiplicaciones. Para los 10 pasos, se precisarán $0.9DN^2$ multiplicaciones. Dado que las distancias son simétricas, este número se puede reducir a la mitad ($0.45DN^2$).

Para el resto de valores de k , se requieren las mismas distancias, y por lo tanto no es necesario recalcularlas, de modo que el número total de multiplicaciones es $0.45DN^2$ (o del orden de DN^2).

3.4. Clasificación ML

Ejercicio C16

Se dispone del conjunto de datos $\{(x_k, y_k), k = 0, \dots, K - 1\}$ de muestras independientes e idénticamente distribuidas. Las variables binarias $y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo probabilístico dado por

$$p(y|x, w) = F(\tilde{y}(x - w)),$$

donde $\tilde{y} = 2y - 1$ es una representación de la etiqueta de clase en $\{-1, 1\}$, y F es la función de distribución acumulativa normalizada de una Gaussiana, es decir,

$$F(x) = \int_{-\infty}^x \mathcal{N}(\alpha|0, 1)d\alpha,$$

y $\mathcal{N}(\alpha|0, 1)$ denota la función Gaussiana con media cero y varianza unitaria. Se desea estimar el parámetro w minimizando la verosimilitud negativa:

$$\text{NLL}(w) = -\ln(p(y_0, \dots, y_{K-1}|x_0, \dots, x_{K-1}, w)) \quad (18)$$

- (a) Encuentre la regla de aprendizaje del algoritmo de descenso de gradiente con paso de adaptación η .
- (b) Encuentre la regla de aprendizaje correspondiente al método de Newton.

Pista: Para simplificar las expresiones finales, podría ser útil definir

$$r_k(w) = \frac{\mathcal{N}(x_k|w, 1)}{F(\tilde{y}_k(x_k - w))}$$

y usarla para expresar las reglas de aprendizaje.

Solution:

- (a) La regla de aprendizaje del algoritmo de descenso de gradiente es:

$$w_{n+1} = w_n - \eta \sum_{k=0}^{K-1} \tilde{y}_k r_k(w_n)$$

- (b) La regla de aprendizaje correspondiente al método de Newton es:

$$w_{n+1} = w_n - \frac{\sum_{k=0}^{K-1} \tilde{y}_k r_k(w_n)}{\sum_{k=0}^{K-1} \tilde{y}_k r_k(w_n)(x_k - w_n - \tilde{y}_k r_k(w_n))}$$

Ejercicio C17

Se dispone de una colección de datos etiquetados $\mathcal{S} = \{(x_k, y_k), k = 0, \dots, 99\}$, donde las observaciones x_k son unidimensionales y las etiquetas y_k toman valores binarios en $\{0, 1\}$. Se desea utilizar estos datos para diseñar un clasificador paramétrico basado en el modelo de probabilidad a posteriori dado por

$$p(y|x, w) = \frac{(x - w)^{2y}}{1 + (x - w)^2}, \quad w \in \mathbb{R}, \quad x \in \mathbb{R}$$

- Suponga que $w = 3$. Represente gráficamente, sobre la recta $\mathbb{R}$, las regiones de decisión del clasificador de mínima probabilidad de error (o MAP, de máximo a posteriori).
- Determine una expresión para la log-verosimilitud negativa del modelo, $NLL(w)$ para las observaciones en el conjunto $\mathcal{S}$.
- Derive la regla de descenso por gradiente para determinar el estimador de w de mínima log-verosimilitud negativa, con paso de adaptación ρ . Para simplificar las expresiones, exprese la regla utilizando $q_{n,k} = \frac{(x_k - w_n)^2}{1 + (x_k - w_n)^2}$

Solution:

- (a) La regla de decisión MAP s

$$p(1|x, w) \underset{D=0}{\overset{D=1}{\geq}} \frac{1}{2}$$

luego

$$\frac{(x - w)^2}{1 + (x - w)^2} \underset{D=0}{\overset{D=1}{\geq}} \frac{1}{2}$$

es decir

$$(x - w)^2 \underset{D=0}{\overset{D=1}{\geq}} 1$$

Por tanto, se decide 0 para $w - 1 \leq x \leq w + 1$

(b) La log-verosimilitud negativa será

$$\begin{aligned}
 \text{NLL}(w) &= -\log \left(\prod_{k=0}^{99} p(y_k | x_k, w) \right) \\
 &= -\sum_{k=0}^{99} \log p(y_k | x_k, w) \\
 &= -\sum_{k=0}^{99} \log \frac{(x_k - w)^{2y}}{1 + (x_k - w)^2} \\
 &= -\sum_{k=0}^{99} \left(y_k \log \left((w - x_k)^2 \right) - \log \left(1 + (w - x_k)^2 \right) \right) \quad (19)
 \end{aligned}$$

(c) Derivando la expresión anterior, resulta

$$\begin{aligned}
 \frac{d\text{NLL}}{dw} &= -\sum_{k=0}^{99} \left(2y_k \frac{1}{w - x_k} - \frac{2(w - x_k)}{1 + (w - x_k)^2} \right) \\
 &= -\sum_{k=0}^{99} \frac{2}{w - x_k} \left(y_k - \frac{(x_k - w)^2}{1 + (x_k - w)^2} \right) \quad (20)
 \end{aligned}$$

$$\text{Por tanto: } w_{n+1} = w_n - 2\rho \sum_{k=0}^{99} \frac{y_k - q_{n,k}}{w_n - x_k}$$

Ejercicio C18

Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_k, y_k\}_{k=0}^{K-1}$ para un problema de clasificación. Todas las entradas $\mathbf{x}_k$ son bidimensionales, con componentes no negativas, es decir, $x_{0,k} \geq 0$ y $x_{1,k} > 0$, para $k = 0, \dots, K-1$.

Se desea diseñar un clasificador basado en el modelo dado por

$$P_{Y|\mathbf{X}}(1|\mathbf{x}) = \frac{x_0^{w_0} x_1^{w_1}}{1 + x_0^{w_0} x_1^{w_1}}, \quad x_0 \geq 0, \quad x_1 \geq 0 \quad (21)$$

- Suponiendo $w_0 = w_1 = 1$, determine la regla de decisión del clasificador de mínima probabilidad de error y represente de forma aproximada, sobre el plano $x_0 - x_1$, la frontera de decisión del clasificador.
- Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(w_0, w_1)$
- Determine la regla de descenso por gradiente estocástico para estimar los parámetros w_0 o w_1 de máxima verosimilitud. (Nota: a su conveniencia, puede expresar la solución como una sola ecuación para $\mathbf{w} = (w_0, w_1)$ o bien como dos ecuaciones, una regla de aprendizaje para w_0 y otra para w_1).

Solution:

(a) La regla de decisión MAP es

$$P_{Y|\mathbf{X}}(1|\mathbf{x}) \begin{matrix} D=1 \\ \geq \\ D=0 \end{matrix} \frac{1}{2}$$

luego

$$\frac{x_0^{w_0} x_1^{w_1}}{1 + x_0^{w_0} x_1^{w_1}} \begin{matrix} D = 1 \\ \geq \\ D = 0 \end{matrix} \frac{1}{2}$$

que es equivalente a

$$x_0^{w_0} x_1^{w_1} \begin{matrix} D = 1 \\ \geq \\ D = 0 \end{matrix} 1$$

Para $w_0 = w_1 = 1$ la frontera de clasificación es

$$x_1 = \frac{1}{x_0}$$

(b) La log-verosimilitud negativa es

$$\begin{aligned} NLL(w_0, w_1) &= - \sum_{k=0}^{K-1} \ln \left(\frac{x_{0,k}^{w_0} x_{1,k}^{w_1}}{1 + x_{0,k}^{w_0} x_{1,k}^{w_1}} \right) \\ &= - \sum_{k=0}^{K-1} \left(w_0 \ln(x_{0,k}) + w_1 \ln(x_{1,k}) - \ln(1 + x_{0,k}^{w_0} x_{1,k}^{w_1}) \right) \end{aligned}$$

(c) Las componentes del gradiente de la log-verosimilitud negativa son

$$\begin{aligned} \frac{\partial NLL}{\partial w_0}(w_0, w_1) &= - \sum_{k=0}^{K-1} \left(\ln(x_{0,k}) - \frac{x_{0,k}^{w_0} x_{1,k}^{w_1} \ln(x_{0,k})}{1 + x_{0,k}^{w_0} x_{1,k}^{w_1}} \right) \\ &= - \sum_{k=0}^{K-1} \ln(x_{0,k}) \left(1 - \frac{x_{0,k}^{w_0} x_{1,k}^{w_1}}{1 + x_{0,k}^{w_0} x_{1,k}^{w_1}} \right) \\ &= - \sum_{k=0}^{K-1} \frac{\ln(x_{0,k})}{1 + x_{0,k}^{w_0} x_{1,k}^{w_1}} \end{aligned}$$

$$\frac{\partial NLL}{\partial w_1}(w_0, w_1) = - \sum_{k=0}^{K-1} \frac{\ln(x_{1,k})}{1 + x_{0,k}^{w_0} x_{1,k}^{w_1}}$$

Por tanto, las reglas de aprendizaje para w_0 y w_1 serán

$$\begin{aligned} w_{0,n+1} &= w_{0,n} + \rho \frac{\ln(x_{0,n})}{1 + x_{0,n}^{w_0} x_{1,n}^{w_1}} \\ w_{1,n+1} &= w_{1,n} + \rho \frac{\ln(x_{1,n})}{1 + x_{0,n}^{w_0} x_{1,n}^{w_1}} \end{aligned}$$

3.5. Clasificación ML y MAP

Ejercicio C19

Considere el conjunto $\{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, siendo $\mathbf{x}_k = (x_{k0}, x_{k1})^T$ observaciones bidimensionales. Las variables binarias

$y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$p(y|\mathbf{x}, \mathbf{w}) = (\exp(-w_0x_0 - w_1x_1))^y \cdot (1 - \exp(-w_0x_0 - w_1x_1))^{1-y},$$

$$w_0 \geq 0, \quad w_1 \geq 0, \quad x_0 \geq 0, \quad x_1 \geq 0$$

Se desea determinar el estimador ML del vector de parámetros $\mathbf{w} = (w_0, w_1)^T$. Para ello, se minimiza la log-verosimilitud negativa

$$\text{NLL}(\mathbf{w}) = -\ln(p(y_0, \dots, y_{K-1}|\mathbf{x}_0, \dots, \mathbf{x}_{K-1}, \mathbf{w}))$$

- (a) Determine el gradiente de $\ln p(y|\mathbf{x}, \mathbf{w})$ respecto de $\mathbf{w}$
- (b) Determine la regla de descenso por gradiente con paso de aprendizaje η .
- (c) Sabiendo que la distribución a priori del vector de coeficientes es

$$p_{\mathbf{w}}(\mathbf{w}) = \frac{1}{2\pi} \exp\left(-\frac{\|\mathbf{w}\|^2}{2}\right),$$

¿podría determinar una regla de descenso por gradiente que proporcione un estimador MAP?

Solution:

(a)

$$\mathbf{g}(\mathbf{w}) = -\left(y - \frac{1 - y}{\exp(\mathbf{w}^T \mathbf{x}) - 1}\right) \mathbf{x} = -\frac{y - \exp(-\mathbf{w}^T \mathbf{x})}{1 - \exp(-\mathbf{w}^T \mathbf{x})} \mathbf{x}$$

(b)

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \eta \sum_{k=0}^{K-1} \frac{y_k - \exp(-\mathbf{w}_n^T \mathbf{x}_k)}{1 - \exp(-\mathbf{w}_n^T \mathbf{x}_k)} \mathbf{x}_k$$

(c)

$$\mathbf{w}_{n+1} = (1 - \eta) \mathbf{w}_n - \eta \sum_{k=0}^{K-1} \frac{y_k - \exp(-\mathbf{w}_n^T \mathbf{x}_k)}{1 - \exp(-\mathbf{w}_n^T \mathbf{x}_k)} \mathbf{x}_k$$

Ejercicio C20

Considere el conjunto $\{(x_k, y_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, siendo $x_k \in \mathbb{R}$ observaciones unidimensionales. Las variables binarias $y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$p(y|x, w) = (\exp(-(w-x)^2))^y \cdot (1 - \exp(-(w-x)^2))^{1-y}, \quad w \in \mathbb{R}, \quad x \in \mathbb{R}$$

- (a) Suponiendo conocido w , determine las regiones de decisión del decisor MAP basado en este modelo.
- (b) Se desea determinar el estimador ML del parámetro w . Para ello, se minimiza la log-verosimilitud negativa

$$\text{NLL}(w) = -\ln(p(y_0, \dots, y_{K-1}|\mathbf{x}_0, \dots, \mathbf{x}_{K-1}, w))$$

Determine la regla de descenso por gradiente con paso de aprendizaje η .

- (c) Sabiendo que la distribución a priori del vector de coeficientes es

$$p_W(w) = \frac{1}{\pi(1+w^2)},$$

¿podría determinar una regla de descenso por gradiente que proporcione un estimador MAP?

- (d) Explique (sin hacer los cálculos) cómo determinaría la regla de aprendizaje basada del algoritmo de Newton para este modelo.

Indicación: para obtener una expresión más compacta de la solución, y facilitar el cálculo, puede apoyarse en la función

$$z_k(w) = \exp(-(w - x_k)^2)$$

y tener en cuenta que

$$\frac{dz_k(w)}{dw} = -2(w - x_k) \cdot z_k(w)$$

Solution:

- (a) Se decide $D = 1$ para $x \in [w - \sqrt{\ln(2)}, w + \sqrt{\ln(2)}]$

- (b)

$$w_{n+1} = w_n - 2\eta \sum_{k=0}^{K-1} \frac{y_k - z_k(w_n)}{1 - z_k(w_n)} (w_n - x_k)$$

- (c)

$$w_{n+1} = w_n - 2\eta \sum_{k=0}^{K-1} \frac{y_k - z_k(w_n)}{1 - z_k(w_n)} (w_n - x_k) - 2\eta \frac{w_n}{1 + w_n^2}$$

Ejercicio C21

Considere el conjunto $\{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^N$. Las variables binarias $y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$P(y|\mathbf{x}, \mathbf{w}) = [\sin(\mathbf{w}^\top \mathbf{x})]^{2(1-y)} \cdot [\cos(\mathbf{w}^\top \mathbf{x})]^{2y}, \quad \mathbf{w} \in \mathbb{R}^N, \quad \mathbf{x} \in \mathbb{R}^N$$

- (a) Suponiendo conocido $\mathbf{w}$, determine una regla de clasificación MAP para este modelo.
 (b) Suponiendo dimensión $N = 2$ y $\mathbf{w} = [0, 2]^\top$, represente gráficamente de forma aproximada sobre $\mathbb{R}^2$ las regiones de decisión del decisor MAP.
 (c) Determine una expresión para la log-verosimilitud negativa, $NLL(\mathbf{w})$.
 (d) Determine una regla de aprendizaje de descenso por gradiente con paso de aprendizaje η para estimación del parámetro $\mathbf{w}$ de máxima verosimilitud.
 (e) Sabiendo que la distribución a priori del vector de coeficientes tiene la forma

$$p_{\mathbf{w}}(\mathbf{w}) = \frac{1}{(2\pi)^{N/2} \sigma^N} \exp\left(-\frac{\|\mathbf{w}\|^2}{2\sigma^2}\right)$$

determine una regla de descenso por gradiente para estimación MAP de $\mathbf{w}$.

Solution:

- (a) El decisor MAP tiene la forma

$$P(1|\mathbf{x}, \mathbf{w}) \underset{D=0}{\overset{D=1}{\geq}} P(0|\mathbf{x}, \mathbf{w})$$

es decir

$$\cos^2(\mathbf{w}^\top \mathbf{x}) \underset{D=0}{\overset{D=1}{\geq}} \sin^2(\mathbf{w}^\top \mathbf{x})$$

(b) Para $\mathbf{w} = [0, 2]^\top$, el clasificador para entrada $\mathbf{x} = [x_0, x_1]^\top$ tiene la forma

$$\begin{array}{ccc} D = 1 & & \\ \cos^2(w_1 x_1) & \geq & \sin^2(w_1 x_1) \\ D = 0 & & \end{array}$$

Por tanto se decidirá $D = 1$ siempre que $-\frac{\pi}{4} - n\pi \leq w_1 x_1 - n\pi \leq \frac{\pi}{4}$ para algún entero n . Es decir, las regiones de decisión son bandas horizontales de anchura $\frac{\pi}{2}$ centradas en los múltiplos de π .

(c)

$$\begin{aligned} \text{NLL}(\mathbf{w}) &= \sum_{k=0}^{K-1} \log \left(\sin^{2(1-y_k)}(\mathbf{w}^\top \mathbf{x}_k) \cdot \cos^{2y_k}(\mathbf{w}^\top \mathbf{x}_k) \right) \\ &= \sum_{k=0}^{K-1} ((1-y_k) \log(\sin^2(\mathbf{w}^\top \mathbf{x}_k)) + y_k \log(\cos^2(\mathbf{w}^\top \mathbf{x}_k))) \end{aligned}$$

(d) La regla de descenso por gradiente será

$$\begin{aligned} \mathbf{w}_{n+1} &= \mathbf{w}_n - \eta \sum_{k=0}^{K-1} ((1-y_k) \nabla_{\mathbf{w}} \log(\sin^2(\mathbf{w}^\top \mathbf{x}_k)) + y_k \nabla_{\mathbf{w}} \log(\cos^2(\mathbf{w}^\top \mathbf{x}_k))) \\ &= \mathbf{w}_n - \eta \sum_{k=0}^{K-1} \left((1-y_k) \frac{2 \sin(\mathbf{w}^\top \mathbf{x}_k) \cos(\mathbf{w}^\top \mathbf{x}_k)}{\sin^2(\mathbf{w}^\top \mathbf{x}_k)} - y_k \frac{2 \sin(\mathbf{w}^\top \mathbf{x}_k) \cos(\mathbf{w}^\top \mathbf{x}_k)}{\cos^2(\mathbf{w}^\top \mathbf{x}_k)} \right) \mathbf{x}_k \\ &= \mathbf{w}_n - 2\eta \sum_{k=0}^{K-1} ((1-y_k) \cot(\mathbf{w}^\top \mathbf{x}_k) - y_k \tan(\mathbf{w}^\top \mathbf{x}_k)) \mathbf{x}_k \end{aligned}$$

(e)

$$\begin{aligned} \mathbf{w}_{n+1} &= \mathbf{w}_n - \eta (\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) - \log(p_{\mathbf{w}}(\mathbf{w})) \\ &= \left(1 - \frac{2\eta}{\sigma^2}\right) \mathbf{w}_n - 2\eta \sum_{k=0}^{K-1} ((1-y_k) \cot(\mathbf{w}^\top \mathbf{x}_k) - y_k \tan(\mathbf{w}^\top \mathbf{x}_k)) \mathbf{x}_k \end{aligned}$$

Ejercicio C22

Considere el conjunto $\{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, siendo $\mathbf{x}_k = (x_{k0}, x_{k1})^T$ observaciones bidimensionales. Las variables binarias $y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$p(y|\mathbf{x}, \mathbf{w}) = \exp(-y\mathbf{w}^\top \mathbf{x}) \cdot (1 - \exp(-\mathbf{w}^\top \mathbf{x})),$$

$$w_0 \geq 0, \quad w_1 \geq 0, \quad x_0 \geq 0, \quad x_1 \geq 0$$

Se desea determinar el estimador ML del vector de parámetros $\mathbf{w} = (w_0, w_1)^T$. Para ello, se minimiza la log-verosimilitud negativa

$$\text{NLL}(\mathbf{w}) = -\ln(p(y_0, \dots, y_{K-1} | \mathbf{x}_0, \dots, \mathbf{x}_{K-1}, \mathbf{w}))$$

- Determine el gradiente de $\ln p(y|\mathbf{x}, \mathbf{w})$ respecto de $\mathbf{w}$
- Determine la regla de descenso por gradiente con paso de aprendizaje η para minimización de $\text{NLL}(\mathbf{w})$

(c) Sabiendo que la distribución a priori del vector de coeficientes es

$$p_{\mathbf{W}}(\mathbf{w}) = w_0 w_1 \exp(-w_0 - w_1) \quad w_0 \geq 0, w_1 \geq 0$$

determine una regla de descenso por gradiente estocástico para estimación MAP de los parámetros del modelo.

Solution:

(a) Dado que

$$\ln p(y|\mathbf{x}, \mathbf{w}) = -y\mathbf{w}^T \mathbf{x} + \ln(1 - (1 - y) \exp(-\mathbf{w}^T \mathbf{x}))$$

resulta

$$\begin{aligned} \mathbf{g}(\mathbf{w}) &= -y\mathbf{x} + \frac{(1 - y) \exp(-\mathbf{w}^T \mathbf{x}) \mathbf{x}}{1 - (1 - y) \exp(-\mathbf{w}^T \mathbf{x})} \\ &= -\left(y - \frac{1 - y}{\exp(\mathbf{w}^T \mathbf{x}) - 1}\right) \mathbf{x} \\ &= -\frac{y - \exp(-\mathbf{w}^T \mathbf{x})}{1 - \exp(-\mathbf{w}^T \mathbf{x})} \mathbf{x} \end{aligned} \quad (22)$$

(b)

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \eta \sum_{k=0}^{K-1} \frac{y_k - \exp(-\mathbf{w}_n^T \mathbf{x}_k)}{1 - \exp(-\mathbf{w}_n^T \mathbf{x}_k)} \mathbf{x}_k$$

(c) El gradiente del logaritmo de la distribución a priori es

$$\begin{aligned} \nabla_{\mathbf{w}} (\ln p_{\mathbf{W}}(\mathbf{w})) &= \nabla_{\mathbf{w}} (\ln w_0 + \ln w_1 - w_0 - w_1) \\ &= \nabla_{\mathbf{w}} (\ln w_0 + \ln w_1 - w_0 - w_1) \\ &= \begin{pmatrix} \frac{1}{w_0} - 1 \\ \frac{1}{w_1} - 1 \end{pmatrix} \end{aligned} \quad (23)$$

y teniendo en cuenta que debe minimizarse

$$\sum_{k=0}^{K-1} \left(-\ln p(y_k|\mathbf{x}_k, \mathbf{w}) - \frac{1}{K} \ln p(\mathbf{w}) \right) \quad (24)$$

la regla de gradiente estocástico será

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{\eta}{K} \begin{pmatrix} \frac{1}{w_{0,n}} - 1 \\ \frac{1}{w_{1,n}} - 1 \end{pmatrix} - \eta \frac{y_n - \exp(-\mathbf{w}_n^T \mathbf{x}_n)}{1 - \exp(-\mathbf{w}_n^T \mathbf{x}_n)} \mathbf{x}_n$$

3.6. SVM

Ejercicio C23

- Explique qué criterio aplican las máquinas de vectores soporte (SVM) para determinar la frontera de decisión en problemas separables.
- Explique brevemente cómo se modifica el diseño de la SVM separable para que pueda funcionar en problemas no separables.

- (c) De un problema de clasificación bidimensional se ha obtenido el conjunto de datos etiquetados que se muestra en la tabla.

k	0	1	2	3	4
$\mathbf{x}_i$	(0,0)	(0,2)	(2,0)	(2,2)	(3,3)
y_k	-1	-1	-1	1	1

Represente gráficamente la frontera de decisión y determine los pesos $\mathbf{w} = (w_0, w_1)$ y el valor del parámetro b de la respuesta $\mathbf{w}^T \mathbf{x} + b$ que obtendría la SVM para este problema. (Indicación: no es necesario que resuelva el problema de optimización de la SVM, puede apoyarse en argumentos geométricos o gráficos si lo considera oportuno).

Solution:

(a) ...

(b) ...

- (c) Por consideraciones puramente geométricas es sencillo comprobar que los vectores soporte en este problema son (0, 2), (2, 0) y (2, 2). Para los vectores soporte de la clase 1 se tiene que $\mathbf{w}^T \mathbf{x} - b = 1$, luego

$$2w_0 + 2w_1 - b = 1$$

Análogamente, para los vectores soporte de la clase -1 se tiene que $\mathbf{w}^T \mathbf{x} - b = 1$, luego

$$2w_0 + 0w_1 - b = -1$$

$$0w_0 + 2w_1 - b = -1$$

Resolviendo este sistema de 3 ecuaciones con 3 incógnitas w_0 , w_1 y b resulta $\mathbf{w} = (1, 1)$, $b = 3$

Ejercicio C24

Explique los siguientes conceptos relativos a la máquina de vectores soporte (SVM) para clasificación, ilustrando cada uno de ellos con un ejemplo:

- (a) Solución de máximo margen.
- (b) Vector soporte.
- (c) Parámetro 'C' (constante de penalización del riesgo empírico)
- (d) Función kernel o núcleo.

Ejercicio C25

Considere un problema de clasificación binaria bidimensional con el siguiente conjunto de entrenamiento:

$$\mathcal{D} = \{(\mathbf{x}_k, s_k)\}_{k=0}^4 = \{([0, 0]^\top, 0), ([0, -1]^\top, 0), ([-3, 1]^\top, 0), ([0, 1]^\top, 1), ([1, 0]^\top, 1)\}$$

- (a) Represente gráficamente los puntos del conjunto de entrenamiento, así como la frontera de un clasificador 1-NN
- (b) Represente gráficamente los puntos del conjunto de entrenamiento, así como la frontera de un clasificador SVM.

3.7. MLP

Ejercicio C26

- (a) Demuestre la siguiente propiedad de la derivada de la función logística $g(t) = \text{logistic}(t)$:

$$g'(t) = g(t) \cdot [1 - g(t)].$$

- (b) Justifique el uso de la función logística para la activación de la capa de salida de una red neuronal para la resolución de un problema de clasificación binaria.
- (c) Explique cómo modificaría la función de activación de la capa de salida de la red neuronal para un problema multiclase, de manera que las salidas de la red puedan interpretarse como las probabilidades de pertenencia a cada una de las clases.
- (d) Represente de forma gráfica una red neuronal para la resolución de un problema de clasificación con tres clases, con los siguientes datos sobre su topología: *i*) una única capa oculta con 4 neuronas, y *ii*) patrones de entrada de 2 dimensiones. Si necesita alguna información adicional, tome las decisiones que estime oportuno indicándolo en su respuesta.
- (e) Proponga una función objetivo para la optimización de la red anterior.

Ejercicio C27

- (a) Describa brevemente la arquitectura de una red neuronal de capa simple (single-layer neural network, SLNN) para clasificación binaria. Formule matemáticamente la relación de entrada-salida de la red. Es decir, la fórmula o fórmulas que determinen el valor de la decisión $\hat{y}$ para una entrada $\mathbf{x}$,

Considere ahora una SLNN para clasificación binaria en la que la función de activación logística ha sido reemplazada por una función de activación softplus, dada por

$$\text{softplus}(t) = \log(1 + \exp(t))$$

Se desea entrenar la red utilizando la función de pérdidas (*loss function*) dada por

$$\ell(y, q) = (y - q)^4$$

donde $y \in \{0, 1\}$ es la clase verdadera y q es la salida de la función de activación. Para ello, se desea minimizar el riesgo empírico

$$R = \sum_{k=0}^{K-1} \ell(y_k, q_k)$$

con respecto a los parámetros de la red, sobre un conjunto de K muestras de entrenamiento.

- (b) Determine la regla de aprendizaje por gradiente para los parámetros de la red, que minimice el riesgo empírico dado.
- (c) Dado que la función de activación no es de tipo probabilístico y la función de pérdidas tampoco es asimilable a la log-verosimilitud, no tenemos garantías de que, tras el entrenamiento, el valor de q proporcione un valor de probabilidad de la clase 1. Por tanto, la regla de decisión

$$\begin{array}{l} D = 1 \\ q \geq \frac{1}{2} \\ D = 0 \end{array}$$

podría ser subóptima. Para evitar este problema, se plantea el uso de un umbral μ ajustable

$$\begin{array}{l} D = 1 \\ q \geq \mu \\ D = 0 \end{array}$$

Proponga algún procedimiento para ajustar el valor de μ a partir de los datos de entrenamiento, de modo que se minimice la tasa de errores de clasificación.

Solution:

(a) La relación entrada-salida de la red es

$$\hat{y} = q \begin{cases} D = 1 \\ \geq \frac{1}{2} \\ D = 0 \end{cases}$$

siendo

$$q = \text{logistic}(\mathbf{w}^\top \mathbf{x} + b)$$

(b)

$$\hat{y} = q \begin{cases} D = 1 \\ \geq \frac{1}{2} \\ D = 0 \end{cases}$$

siendo

$$q = \log(1 + \exp(\mathbf{w}^\top \mathbf{x} + b))$$

$$\begin{aligned} \mathbf{w}_{n+1} &= \mathbf{w}_n - \rho \sum_{k=0}^{K-1} \frac{d}{d\mathbf{w}} (y_k - q_k)^4 \\ &= \mathbf{w}_n + 4\rho \sum_{k=0}^{K-1} (y_k - q_{n,k})^3 \frac{d}{d\mathbf{w}} q_{n,k} \\ &= \mathbf{w}_n + 4\rho \sum_{k=0}^{K-1} (y_k - q_{n,k})^3 \frac{\exp(\mathbf{w}_n^\top \mathbf{x}_k + b_n)}{1 + \exp(\mathbf{w}_n^\top \mathbf{x}_k + b_n)} \mathbf{x}_k \\ &= \mathbf{w}_n + 4\rho \sum_{k=0}^{K-1} (y_k - q_{n,k})^3 \text{logistic}(\mathbf{w}_n^\top \mathbf{x}_k + b_n) \mathbf{x}_k \\ b_{n+1} &= b_n + 4\rho \sum_{k=0}^{K-1} (y_k - q_{n,k})^3 \text{logistic}(\mathbf{w}_n^\top \mathbf{x}_k + b_n) \end{aligned}$$

(c) μ no es ajustable por gradiente, pero puede ajustarse por exploración, eligiendo un valor que minimice el número de errores sobre el conjunto de entrenamiento.

Ejercicio C28


Explique cómo puede extenderse la red neuronal de una sola capa (SLN, single-layer neural network) para problemas de clasificación multiclase. Para ello:

- Represente gráficamente la arquitectura de la red. Suponga, para simplificar, entrada $\mathbf{x}$ de dimensión 4, y 3 clases.
- Formule matemáticamente las ecuaciones que definen la relación entrada-salida de la red neuronal.
- Si M es el número de clases y N la dimensión de la entrada, indique la dimensión del espacio de parámetros de la red (es decir, el número de parámetros ajustables).

- (d) Proponga una función de pérdidas (*loss function*) para el ajuste de los parámetros de la red a partir de un conjunto de datos de entrenamiento, que permita garantizar que las salidas blandas (soft-decisions) de la red sean estimaciones de las probabilidades de las clases.

Solution:

- (a) La figura muestra una NN multiclase genérica de una sola capa, para una entrada de dimensión 4096 y M clases



- (b)

$$\hat{\mathbf{y}} = \text{hardmax}(\mathbf{q})$$

siendo

$$\mathbf{q} = \text{softmax}(\mathbf{o})$$

y

$$\mathbf{o} = \mathbf{W}^T \mathbf{x} + \mathbf{b}$$

La función softmax está dada por:

$$q_i = \frac{\exp(o_i)}{\sum_{j=0}^{M-1} \exp(o_j)}$$

- (c) Los parámetros ajustables son la matriz $\mathbf{W}$ (de dimensión $N \times M$) y el vector $\mathbf{b}$ de dimensión M . Por tanto, la dimensión del espacio de parámetros es $(N + 1) \cdot M$.
- (d) Por ejemplo, la entropía cruzada:

$$\ell(\mathbf{q}, \mathbf{y}) = -\mathbf{y}^T \log(\mathbf{q})$$

Ejercicio C29

Se desea entrenar un perceptrón de tres capas (una capa de entrada, una capa oculta y una capa de salida) para resolver un problema de clasificación. Se debe elegir una función de activación para las neuronas de la capa oculta y de la capa de salida.

- (a) Indique brevemente qué funciones de activación suelen utilizarse en redes neuronales. Preferentemente, indique su nombre, y su fórmula o una representación gráfica aproximada.

Se desea que el clasificador proporcione salidas que puedan interpretarse como valores de probabilidad.

Asimismo, se desea utilizar (en la medida de lo posible) funciones de activación que mitiguen el problema de desvanecimiento del gradiente (es decir, que las derivadas se hagan 0 para valores

grandes de la entrada).

- (b) Discuta qué función o funciones de activación recomendaría para la capa oculta.
- (c) Discuta qué función o funciones de activación recomendaría para la capa de salida, si el clasificador es binario.
- (d) Discuta qué función o funciones de activación recomendaría para la capa de salida, si el clasificador es multiclase.

Solution:

- (a) Logística, ReLu, PreLu, softplus, etc. También, la función escalón, para la etapa de decisión. En problemas multiclase, también se utiliza la activación softmax y, para la decisión, hardmax.
- (b) Relu, Prelu o softplus. Su derivada no se hace cero para valores grandes de la entrada. Prelu también tiene pendiente constante y positiva para valores negativos de la entrada.
- (c) La función logística
- (d) Softmax.

Ejercicio C30

Considere la resolución de un problema de clasificación utilizando redes neuronales.

- (a) Explique brevemente en qué consiste el sobreajuste (over-fitting).
- (b) Explique qué dificultades plantea el uso de validación cruzada *leave one out* (LOO) para el entrenamiento de un MLP con múltiples capas, como método para reducir el sobreajuste.
- (c) Explique qué otros métodos, además de validación cruzada, suelen utilizarse para evitar el sobreajuste durante el entrenamiento de redes neuronales.

Solution:

- (a) A medida que el número de neuronas y parámetros en un modelo de red neuronal aumenta, el proceso de entrenamiento puede incurrir en problemas de sobreajuste: el modelo aprende a desempeñarse excepcionalmente bien en los datos de entrenamiento pero falla en generalizar efectivamente a nuevos datos no vistos: el modelo capta ruido y detalles específicos en los datos de entrenamiento, en lugar de los patrones subyacentes. Los modelos sobreajustados tienen un rendimiento predictivo deficiente.
- (b) El número de entrenamientos a realizar puede ser prohibitivo si el tamaño del dataset es grande o también el número de posibles configuraciones de red (número de capas, neuronas por capa, etc.).
- (c)
 - **Regularización por un término de penalización:** la función de pérdida se extiende con un término adicional que penaliza los pesos grandes. Dos ejemplos comunes de regularización para un riesgo empírico $R(\mathbf{w})$ son:
 - $L_2 : R(\mathbf{w}) + \lambda \|\mathbf{w}\|^2$
 - $L_1 : R(\mathbf{w}) + \lambda \|\mathbf{w}\|_1$
 - **Parada temprana (early stopping):** Implica monitorear el rendimiento del modelo en un conjunto de datos de validación durante el entrenamiento. Si el rendimiento de validación comienza a degradarse (por ejemplo, el error de validación aumenta), el entrenamiento se detiene temprano y se guarda el modelo con el mejor rendimiento en los datos de validación.

- **Dropout:** Durante el entrenamiento, el abandono descarta aleatoriamente (desactiva) una fracción de neuronas o unidades en una capa, previniendo la coadaptación de neuronas y reduciendo el sobreajuste. Ayuda a que el modelo generalice mejor al hacerlo más robusto y menos dependiente de neuronas específicas durante la predicción. Durante la inferencia, el abandono suele estar desactivado y se utilizan todas las neuronas.
- **Aumento de datos:** implica aplicar transformaciones aleatorias a los datos de entrenamiento para crear ejemplos de entrenamiento adicionales. En imágenes, estas transformaciones pueden incluir operaciones como rotación, escalado, recorte, volteo, ajustes de brillo y más. Al exponer la red a una variedad más amplia de ejemplos de entrenamiento, el aumento de datos ayuda al modelo a aprender a ser invariante a estas transformaciones y generalizar mejor a datos no vistos.

Ejercicio C31

Se dispone de un conjunto de datos de entrenamiento para la resolución de un problema de clasificación binaria, $\mathcal{D} = \{(\mathbf{x}_k, y_k), k = 0, \dots, K - 1\}$, con $\mathbf{x}_k \in \mathbb{R}^5$ e $y_k \in \{0, 1\}$

- (a) Derive la función de coste para la regresión logística $\hat{y} = g(\mathbf{w}^\top \mathbf{x})$, donde $g(\cdot)$ es la función logística, utilizando el método de máxima verosimilitud.
- (b) Considere ahora la resolución del problema mediante una red neuronal con una sola capa oculta de 3 neuronas y una capa de salida con una neurona, con activación reLU en la capa oculta y logística en la capa de salida. Dibuje la arquitectura de esta red neuronal y etiquete claramente todas las entradas, salidas y funciones de activación.

4. Aprendizaje No Supervisado

4.1. Análisis por Componentes Principales

Ejercicio U1

- (a) Explique la secuencia de pasos de un algoritmo de extracción de las m componentes principales del conjunto de observaciones N -dimensionales, $\mathcal{D} = \{\mathbf{x}_k, k = 0, \dots, K-1\}$, con $m < K$.
- (b) Sea $\mathbf{v}_k$ el vector de las m componentes principales de la muestra $\mathbf{x}_k$, y considere el conjunto de datos $\mathcal{D}' = \{\mathbf{x}'_k, k = 0, \dots, K-1\}$, con $m < K$, siendo $\mathbf{x}'_k = 10\mathbf{x}_k$, para todo k . Se aplica un análisis PCA sobre $\mathcal{D}'$, resultando las componentes principales $\mathbf{v}'_k$. ¿Qué relación existe entre $\mathbf{v}_k$ y $\mathbf{v}'_k$? Justifique la respuesta.

Solution:

- (a)
1. Arrange data into matrix $\mathbf{X}$.
 2. Compute the m unitary eigenvectors $\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_{m-1}$ from matrix $\mathbf{X}^\top \mathbf{X}$ with the m largest eigenvalues.
 3. Arrange the eigenvectors columnwise into an $N \times m$ weight matrix

$$\mathbf{W} = (\mathbf{w}_0 | \mathbf{w}_1 | \dots | \mathbf{w}_{m-1})$$

4. Compute the principal components for all samples in data matrix $\mathbf{X}$ as $\mathbf{T} = \mathbf{X}\mathbf{W}$
- (b) $\mathbf{v}'_k = 10\mathbf{v}_k$. Esto es debido a que los autovectores unitarios de $\mathbf{X}^\top \mathbf{X}$ coinciden con los de $\mathbf{X}'^\top \mathbf{X}' = 100\mathbf{X}^\top \mathbf{X}$, y por tanto las direcciones principales no cambian (es decir, la matriz de transformación $\mathbf{T}$ es la misma).

Ejercicio U2

Se dispone de un conjunto de K datos d dimensionales, dispuestos por filas en una matriz $\mathbf{X}$. Se desea disminuir la dimensión de dicho conjunto de datos aplicando PCA. Como primer paso del PCA, los datos son centrados, de manera que la media de todos los datos de entrenamiento sea el vector nulo. Posteriormente, se extraen las primeras m proyecciones de los datos, con $m < d$, de manera que la matriz de datos proyectados es $\tilde{\mathbf{X}}$.

Discuta la verdad o falsedad de las siguientes afirmaciones.

- (a) Si sobre $\tilde{\mathbf{X}}$ se vuelve a ejecutar otra vez el PCA extrayendo únicamente m' proyecciones, con $m' < m$, el resultado final es equivalente al que se obtendría haciendo PCA sobre la matriz $\mathbf{X}$ original y extrayendo únicamente las primeras m' proyecciones, salvo por el hecho de que varias de sus columnas pueden quedar multiplicadas por -1 .
- (b) Si se extienden los datos originales, añadiendo una componente con valor constante igual a 1 al final de cada vector, la matriz de datos proyectados $\tilde{\mathbf{X}}$ no cambia, salvo por el hecho de que varias de sus columnas pueden quedar multiplicadas por -1 .
- (c) Si se realizase el PCA sobre la matriz $-\mathbf{X}$, la matriz de datos proyectados $\tilde{\mathbf{X}}$ no cambia, salvo por el hecho de que varias de sus columnas pueden quedar multiplicadas por -1 .

Solution:

Todas son verdaderas, con alguna excepción.

- (a) Utilizando los autovalores y autovectores principales de la matriz de covarianzas (muestrales) de los datos, dicha matriz puede descomponerse como

$$\mathbf{C}_\mathbf{X} = \frac{1}{K} \mathbf{X}^\top \mathbf{X} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$$

donde se ha considerado ya que los datos $\mathbf{X}$ han sido centrados, $\mathbf{\Lambda}$ es una matriz diagonal con los autovalores de $\mathbf{C}_{\mathbf{X}}$ dispuestos según valor decreciente, y las columnas de $\mathbf{U}$ contienen los autovectores asociados a cada autovalor.

El algoritmo PCA proyecta los datos utilizando los autovectores asociados a los mayores autovalores de $\mathbf{C}_{\mathbf{X}}$, de manera que

$$\mathbf{C}_{\tilde{\mathbf{X}}} = \frac{1}{K} \tilde{\mathbf{X}}^{\top} \tilde{\mathbf{X}} = \mathbf{U}^{(m)} \mathbf{\Lambda}^{(m)} \mathbf{U}^{(m)\top}$$

donde $\mathbf{U}^{(m)}$ es la matriz que conserva únicamente las primeras m columnas de $\mathbf{U}$, y $\mathbf{\Lambda}^{(m)}$ es una matriz diagonal cuadrada de dimensión m , que contiene únicamente los primeros autovalores de $\mathbf{\Lambda}$, ordenados nuevamente en orden decreciente.

Hacer un nuevo PCA sobre $\tilde{\mathbf{X}}$ equivale a proyectar los datos utilizando las m' primeras columnas de $\mathbf{U}^{(m)}$, que es equivalente a proyectar $\mathbf{X}$ según las primeras m' columnas de $\mathbf{U}$, por lo que la afirmación es cierta.

Hay dos argumentos adicionales que pueden tenerse en cuenta:

- La descomposición no es única, ya que no cambia si cualquier autovector se multiplica por -1 . La consecuencia de esto sería que la correspondiente proyección queda multiplicada por -1 , que es una eventualidad que ya considera el enunciado.
 - La segunda consideración es que en el caso en que haya dos (o más) autovectores con exactamente el mismo autovalor, la descomposición del PCA no es única, y en dicho caso la afirmación del enunciado no tendría por qué ser cierta.
- (b) El centrado de los datos hace que la componente que hemos añadido se haga igual a 0, por lo que la matriz de covarianzas no cambia. El único efecto es que en la descomposición de $\mathbf{C}_{\mathbf{X}}$ aparece un nuevo autovalor nulo que no afecta a la extracción de las primeras componentes del PCA. Por lo tanto, la afirmación es cierta.
- (c) Al multiplicar la matriz de datos por -1 la matriz de covarianzas no cambia, por lo que tampoco lo hace su descomposición. Por tanto, los vectores de proyección no cambian, salvo por el eventual cambio de signo, que provocará a su vez el cambio de signo en la correspondiente proyección. Por lo tanto, la afirmación es verdadera.

Ejercicio U3

Suponga que tenemos un conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_n, n = 1, \dots, 100\}$ y deseamos aplicar sobre estos datos un análisis de componentes principales (PCA). Consideramos que las componentes principales vienen dadas por la siguiente expresión

$$t_{n,k} = \mathbf{w}_k^{\top} \mathbf{x}_n.$$

donde $k = 1, \dots, K$ denota la componente principal, $\mathbf{w}_k$ representa el k -ésimo vector de proyección y $t_{n,k}$ la proyección de la muestra n -ésima en la componente k -ésima.

- (a) Describa el objetivo principal del algoritmo PCA y explique cómo se obtienen las componentes principales a partir de los datos incluyendo las ecuaciones necesarias para calcularlo.
- (b) ¿Qué criterios podrían utilizarse para seleccionar el número adecuado de componentes principales? Comente las implicaciones de conservar más o menos componentes.
- (c) Explique cómo podría recuperar la mejor aproximación posible de la matriz de datos original a partir de las componentes principales y analice el impacto de conservar un número reducido de componentes.

Solution:

- (a) El objetivo principal de PCA es reducir la dimensionalidad de los datos mientras se conserva la mayor cantidad posible de información en términos de varianza. Los pasos principales son:

1. Centrar los datos restando la media de cada característica.
2. Calcular la matriz de covarianza de los datos centrados.
3. Obtener los autovalores y autovectores de la matriz de covarianza.
4. Ordenar los autovectores por autovalor de mayor a menor y seleccionar los correspondientes.
5. Proyectar los datos sobre el subespacio definido por esos vectores.

Formalmente:

$$\mathbf{W} = (\mathbf{w}_1 | \mathbf{w}_2 | \dots | \mathbf{w}_K),$$

$$\mathbf{T} = \mathbf{XW}.$$

- (b) Algunos criterios:

1. **Varianza explicada acumulada:** fijar un umbral (ej. 95 %).
2. **Método del codo:** observar el punto de inflexión en la gráfica de varianza explicada.

Conservar más componentes implica menos pérdida de información pero menos reducción de dimensionalidad.

- (c) Para reconstruir:

$$\hat{\mathbf{X}} = \mathbf{ZW}^\top + \mathbf{m}_x,$$

donde $\mathbf{Z}$ son las proyecciones, $\mathbf{W}$ los vectores seleccionados y $\mathbf{m}_x$ la media original. Con menos componentes se obtiene una aproximación que retiene la varianza más alta, lo que simplifica y reduce ruido, pero puede perder información relevante.

4.2. Agrupamiento

Ejercicio U4

- (a) Explique cuáles son los pasos de un algoritmo de agrupamiento espectral.
- (b) Ponga un ejemplo de un conjunto de datos en el que un algoritmo de agrupamiento espectral y un algoritmo tipo k -means proporcionan resultados cualitativamente diferentes.

Ejercicio U5

- (a) Indique qué función de distorsión optimiza el algoritmo k -medias.
- (b) Explique brevemente los pasos del algoritmo.
- (c) Explique, mediante un ejemplo gráfico, la diferencia en el comportamiento del algoritmo k -medias y un algoritmo de agrupamiento espectral.

Ejercicio U6

Utilice el algoritmo k -medias y la distancia euclidiana para agrupar los siguientes 8 ejemplos en 3 clusters:

$$\mathbf{x}_0 = (2, 10), \mathbf{x}_1 = (2, 5), \mathbf{x}_2 = (8, 4), \mathbf{x}_3 = (5, 8), \mathbf{x}_4 = (7, 5), \mathbf{x}_5 = (6, 4), \mathbf{x}_6 = (1, 2), \mathbf{x}_7 = (4, 9)$$

Suponga que los centroides están inicializados en $\mathbf{x}_1$, $\mathbf{x}_4$ y $\mathbf{x}_7$. Ejecute el algoritmo k -medias durante una única época. Al final de esta época, muestre:

- Los nuevos clusters (es decir, los ejemplos que pertenecen a cada cluster).
- Los centros de los nuevos clusters.
- Dibuje los puntos de entrenamiento y los centroides en un eje de coordenadas 2D. ¿Cuántas iteraciones adicionales del K -means serían necesarias para converger?

Ejercicio U7

Considere un problema unidimensional de aprendizaje no supervisado cuyo conjunto de entrenamiento está dado por las siguientes 6 muestras: $x_0 = 1.8$, $x_1 = -0.2$, $x_2 = -1.6$, $x_3 = 2.6$, $x_4 = 1.6$ y $x_5 = -1.8$.

- Para agrupar los datos, se ejecuta un algoritmo k -medias con 2 grupos, utilizando la siguiente inicialización para las medias de los grupos: $\mu_{0,0} = x_3$ y $\mu_{1,0} = x_2$. Determine el número de iteraciones necesarias para la convergencia del algoritmo y los vectores de medias que se obtendrán.
- Justifique si es posible encontrar otros vectores de medias diferentes de los anteriores que proporcionen una menor distorsión cuadrática total:

$$J = \sum_{x_k \in \mathcal{C}_0} (x_k - \mu_0)^2 + \sum_{x_k \in \mathcal{C}_1} (x_k - \mu_1)^2$$

- Utilizando el criterio de asignación de k -medias, calcule las estimaciones muestrales de las probabilidades a priori y varianza de cada grupo. Aproxime sus resultados con dos cifras decimales.
- Suponiendo que la densidad de probabilidad que ha generado los datos de cada grupo sigue una distribución gaussiana, proporcione la expresión que permite calcular la log-verosimilitud del modelo GMM que utiliza los parámetros calculados en los apartados anteriores.

Solution:

- La convergencia se produce en dos iteraciones, con medias $\mu_{0,2} = -1.2$ y $\mu_{1,2} = 2$
- No es posible, ya que para la partición obtenida la distorsión se minimiza seleccionando los centroides como promedios muestrales, y si se cambiase la asignación la distorsión aumentaría.
- $\hat{P}(\omega_0) = \hat{P}(\omega_21) = 0.5$, $\hat{v}_0 \approx 0.51$ y $\hat{v}_1 \approx 0.19$.
- $L = \log \left[\prod_{k=0}^5 \frac{1}{2} p(x_k | \hat{\mu}_0, \hat{v}_0) + \frac{1}{2} p(x_k | \hat{\mu}_1, \hat{v}_1) \right]$
 $= -4.16 \sum_{k=0}^5 \log \left[p(x_k | \hat{\mu}_0, \hat{v}_0) + \frac{1}{2} p(x_k | \hat{\mu}_1, \hat{v}_1) \right] (\approx -9.13)$, donde $p(x_k | \hat{\mu}_i, \hat{v}_i) = \frac{1}{\sqrt{2\pi\hat{v}_i}} \exp \left[-\frac{(x_k - \hat{\mu}_i)^2}{2\hat{v}_i} \right]$

Ejercicio U8

- Explique qué función de distorsión persigue minimizar el algoritmo k -medias.
- Explique por qué el número de grupos del algoritmo k -medias no se puede determinar eligiendo el número de grupos que minimicen la función de distorsión.
- Explique por qué se aplica el algoritmo k -medias en una de las etapas del algoritmo de clustering espectral.

Solution:

- (a) El algoritmo k -medias persigue minimizar la distorsión cuadrática total

$$D = \sum_{k=0}^{K-1} \sum_{\mathbf{x} \in \mathcal{G}_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2$$

siendo K el número de grupos, $\mathcal{G}_k$ el grupo k y $\boldsymbol{\mu}_k$ es el centroide del grupo k .

- (b) Porque la distorsión cuadrática total se minimiza asignando un centroid a cada muestra (en cuyo caso $D = 0$). Dicha optimización no tendría interés práctico.
- (c) Los autovectores de la matriz de similitud con menores autovalores tienen dimensión igual al número de muestras, y tienden a tomar valores similares en las componentes relativas a las muestras similares (conectadas en un cluster). Los grupos de muestras con valores similares de estas componentes forman clusters conectados en el grafo original, y pueden descubrirse aplicando k -medias.

Ejercicio U9

- (a) Explique cuáles son los pasos de un algoritmo de agrupamiento espectral.
- (b) Ponga un ejemplo de un conjunto de datos en el que un algoritmo de agrupamiento espectral y un algoritmo tipo k -means proporcionan resultados cualitativamente diferentes.

Ejercicio U10

Indique si las siguientes afirmaciones son verdaderas o falsas. Justifique su respuesta.

- (a) El algoritmo de agrupamiento K -medias converge siempre a la solución de mínima distorsión global.
- (b) Durante la ejecución del agrupamiento K -medias la distorsión global no puede crecer de forma puntual en alguna iteración.
- (c) Un criterio adecuado para elegir el valor de K (número de grupos) al aplicar el algoritmo K -medias es seleccionar el valor de K que permite alcanzar la mínima distorsión global medida sobre el conjunto de entrenamiento.
- (d) La aplicación de un algoritmo de clustering espectral requiere que las muestras estén ordenadas según el grupo al que pertenecen.

Solution:

- (a) Falso. El algoritmo converge cuando la asignación de muestras a centroides no cambia, pero eso no implica necesariamente que dicha solución sea la de mínima distorsión global. En general, la convergencia a una solución u otra depende de la inicialización. A modo de ejemplo, si en la aplicación de un 2-means con inicialización aleatoria los centroides caen de manera que uno de los dos centroides iniciales captura la totalidad de las muestras, la solución no cambia, pero existen otras soluciones mejores.
- (b) Verdadero. Los dos pasos de que consta el K -medias son óptimos para una asignación dada / para una posición determinada de los centroides. Puesto que ambos pasos garantizan que la distorsión global no crece, no puede hacerlo en ningún momento durante la aplicación del algoritmo.
- (c) Falso. Si se fija K igual al número de muestras de entrenamiento, se puede alcanzar distorsión global nula, pero situar un centroide sobre cada muestra no constituye una solución deseable del problema de agrupamiento.

- (d) Falso. Precisamente, el objetivo del problema de agrupamiento espectral consiste en encontrar “columnas similares” en la matriz de adyacencia, independientemente del orden en que estén dichas columnas. Asumir que las muestras ya están ordenadas según el grupo equivale a asumir que el problema de agrupamiento está resuelto de antemano.

Ejercicio U11

Se desea comprimir una imagen de 1024×1024 píxeles, y tres canales (RGB) de 8 bits de resolución (i.e., valores 0-255). Para ello, se decide aplicar cuantificación vectorial, de manera que se seleccionan 64 centroides y cada píxel se representa utilizando el centroide más cercano.

Responda a las siguientes cuestiones utilizando un máximo de una cara. Debe justificar todas sus respuestas.

- (a) Calcule el número de bits utilizado para representar la imagen original y la imagen comprimida.
- (b) Explique cómo seleccionaría los centroides aplicando un algoritmo de clustering K-medias. Indique de manera explícita cómo formaría la matriz de datos para la aplicación del algoritmo.
- (c) Enumere de forma concisa los dos pasos de que consta el algoritmo K-medias.
- (d) Si se necesita comprimir 100 imágenes, justifique las ventajas e inconvenientes que tendría emplear los centroides obtenidos para la imagen original *vs* calcular nuevos centroides para cada imagen a comprimir. ¿Cuál de las dos estrategias aconsejaría?

Ejercicio U12

Se desea aplicar cuantificación vectorial para reducir el tamaño de una matriz de datos $\mathbf{X}$ de tamaño $100\,000 \times 84$, cuyas componentes son floats. Se sabe además que cada float requiere para su representación 4 Bytes (B) de longitud.

Se aplica cuantificación vectorial para obtener una versión aproximada de dicha matriz $\tilde{\mathbf{X}}$, utilizando para ello un número K de centroides seleccionados mediante el algoritmo de agrupamiento K-medias.

Explique por qué la cuantificación vectorial permite un ahorro de memoria para el almacenamiento de la matriz de datos. Incluya en su respuesta los siguientes aspectos:

- (a) Una explicación de cómo se debería aplicar el algoritmo K-medias como parte del proceso de cuantificación vectorial.
- (b) Explique por qué resulta adecuado seleccionar los centroides utilizando un algoritmo de agrupamiento como K-medias en lugar de emplear alternativas más simples (e.g., selección aleatoria).
- (c) Calcule el ahorro obtenido en función del número de centroides K , explicando los aspectos que deben considerarse para la selección de dicho parámetro. Puede asumir en su respuesta que K es una potencia de 2.

Solution:

- (a) Se debe aplicar K medias sobre las filas de $\mathbf{X}$ para obtener la representación de los centroides. De esta manera, puede almacenarse la matriz aproximada mediante una matriz de bits de tamaño $100\,000 \times \log_2(K)$, y otra matriz de floats de tamaño $K \times 84$. El valor de K puede ser determinado a priori, o fijado con algún método como la exploración de la evolución del error cuadrático medio con K , o la suma de la distorsión cuadrática y un término de regularización que penalice valores altos de K .

Una vez seleccionado K y aprendidos los centroides, cada fila de X debe aproximarse con el centroide más cercano (según distancia L_2), de manera que es suficiente conservar el índice correspondiente al centroide asignado a cada fila de $\mathbf{X}$, lo que requiere $10^5 \cdot \log_2(K)$ bits.

Adicionalmente ha de almacenarse una matriz con todos los centroides proporcionados por K -medias con la resolución original, i.e., cada centroide requiere $84 \cdot 32$ bits.

- (b) La selección mediante K -medias trata de encontrar el conjunto de centroides que minimiza la distorsión cuadrática media de la aproximación.
- (c)
- La representación de $\mathbf{X}$ requiere $10^5 \cdot 84 \cdot 32$ bits
 - La representación de $\tilde{\mathbf{X}}$ requiere $10^5 \cdot \log_2(K) + K \cdot 84 \cdot 32$ bits.

La selección de K implica un compromiso entre calidad de la aproximación y ahorro de memoria. Para K pequeño se tiene un ahorro máximo pero una distorsión grande. Conforme aumenta el valor de K la aproximación es mejor a costa de un menor ahorro de memoria.

Ejercicio U13

Explique los siguientes aspectos del algoritmo K-medias:

- (a) Distintas posibilidades para la inicialización de los centroides
- (b) El proceso iterativo principal del algoritmo
- (c) La convergencia del algoritmo y posibles criterios de parada
- (d) Algún método para la selección del número de centros del algoritmo

Solution:

(a) Por ejemplo:

- Selección aleatoria
- Primer centroide de manera aleatoria, resto tratando de maximizar la distancia a los ya seleccionados (k-means ++).

(b)

- Se asigna cada muestra al grupo caracterizado por el centroide más cercano
- Se recalcula el centroide de cada grupo como la media de las muestras asignadas al grupo

(c)

- El algoritmo converge siempre, aunque no necesariamente a la solución que minimiza la función objetivo (i.e., el algoritmo para, pero puede no ser la mejor solución posible)
- Posibles criterios de parada: por número de iteraciones, por disminución relativa de la función de distorsión global.

(d) Por ejemplo:

- Entrenar para distintos valores de K , y hacerlo de forma manual buscando el codo de la curva que muestra la distorsión global frente al valor de K .
- Similar al anterior, pero conservando el valor de K que minimice la suma de la distorsión global con un término de penalización creciente con el valor de K .

Ejercicio U14

Considere la aplicación del algoritmo de agrupamiento K -medias sobre un conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_n, n = 0, \dots, L - 1\}$.

- (a) Describa los pasos principales del algoritmo.
- (b) ¿Cómo afecta la elección del número de clusters K en el resultado del algoritmo K-medias? Proponga alguna estrategia para elegir un valor adecuado de K .
- (c) Justifique por qué es habitual ejecutar varios entrenamientos del algoritmo con distintas inicializaciones, y cómo se selecciona a partir de dichas soluciones el agrupamiento final.

5. Procesamiento de Lenguaje Natural

5.1. Modelos de Tópicos

Ejercicio NLP1

- (a) Describa muy brevemente, con ayuda de un diagrama de bloques, el modelo de generación de documentos del corpus que supone el algoritmo LDA.
- (b) Explique qué resultados produce el algoritmo LDA y qué representan. ¿Cómo podría reconocer si una matriz de tópicos procede de un algoritmo LDA o LSI?

Ejercicio NLP2

- (a) Explique qué representan las componentes del vector que caracteriza un tópico o perfil en el algoritmo *Latent Dirichlet Allocation*.
- (b) Explique en qué consisten la eliminación de *stopwords* y la lematización, y discuta su conveniencia como técnicas de preprocesado previas al análisis de tópicos de un corpus documental.

Ejercicio NLP3

- (a) En *Latent Dirichlet Allocation*, explique qué representan las componentes del vector que caracteriza un tópico. ¿Existe alguna restricción que deba cumplir este vector?
- (b) Describa los procedimientos de eliminación de *stopwords* y la lematización. ¿Por qué son convenientes como herramientas de preprocesamiento para un análisis de modelado de tópicos?

Ejercicio NLP4

Considere un modelo de K tópicos basado en el algoritmo *Latent Dirichlet Allocation*, y considere que las distribuciones de probabilidad β_k , $k = 0, \dots, K - 1$, caracterizan la distribución sobre el vocabulario de términos asociada a cada uno de los $K - 1$ tópicos del modelo.

- (a) Explique el significado para el algoritmo LDA de la distribución de probabilidad $p(\beta)$.
- (b) Describa la generación del documento d a partir de cierta distribución $p(\theta)$ y de las distribuciones β_k , $k = 0, \dots, K - 1$, de acuerdo al modelo generativo del algoritmo LDA.

Ejercicio NLP5

Considere el corpus formado por la siguiente lista de 3 documentos

- Doc 0: 'Un robot no hará daño a un ser humano o, por inacción, permitirá que un ser humano sufra daño'
 - Doc 1: 'Un robot debe cumplir las órdenes dadas por los seres humanos, a excepción de aquellas que entrasen en conflicto con la primera ley'
 - Doc 2: 'Un robot debe proteger su propia existencia en la medida en que esta protección no entre en conflicto con la primera o con la segunda ley'
- (a) Aplique sobre el corpus un procesado de texto estándar, que convierta cada documento en una lista de tokens apropiada para el análisis semántico.
 - (b) Construya un modelo de bolsa de palabras (BoW) para el corpus dado, determinando la representación vectorial del documento 1.
 - (c) Considere el siguiente modelo generativo del corpus: cada documento se ha generado estocásticamente como una secuencia aleatoria de palabras, donde cada palabra se ha generado aleatoriamente de acuerdo con una distribución de probabilidad común para todas las palabras. Dado el corpus, infiera una distribución de probabilidad para el corpus dado.

Solution:

- (a)
- Doc 0: ['robot', 'daño', 'ser humano', 'inacción', 'permitir', 'ser humano', 'sufrir', 'daño']
 - Doc 1: ['robot', 'deber', 'cumplir', 'orden', 'dar', 'ser humano', 'entrar', 'conflicto', 'primera', 'ley']
 - Doc 2: ['robot', 'deber', 'proteger', 'propia', 'existencia', 'protección', 'entrar', 'conflicto', 'primera', 'segunda', 'ley']
- (b) Un posible diccionario, junto con la representación vectorial del documento 1 se muestran en la tabla siguiente:

	Diccionario	Doc 1	Distrib. prob
0	'robot'	1	3/29
1	'daño'	0	2/29
2	'ser humano'	1	3/29
3	'inacción'	0	1/29
4	'permitir'	0	1/29
5	'sufrir'	0	1/29
6	'deber'	1	2/29
7	'cumplir'	1	1/29
8	'orden'	1	1/29
9	'dar'	1	1/29
10	'entrar'	1	2/29
11	'conflicto'	1	2/29
12	'primera'	1	2/29
13	'ley'	1	2/29
14	'proteger'	0	1/29
15	'propia'	0	1/29
16	'existencia'	0	1/29
17	'protección'	0	1/29
18	'segunda'	0	1/29

- (c) Una distribución de probabilidad basada en frecuencias de palabras se muestra también en la tabla anterior.

Ejercicio NLP6

La distribución de Dirichlet con parámetro de concentración η tiene la forma

$$p(x_1, \dots, x_N) = \frac{1}{B(\eta)} \prod_{i=1}^N x_i^{\eta_i - 1}$$

siendo

$$B(\eta) = \frac{\Gamma(\eta)^N}{\Gamma(N\eta)}$$

una constante de normalización (que garantiza que p tiene integral unitaria y, por tanto, es una densidad de probabilidad). Γ es la función Gamma.

- (a) Explique qué influencia tiene el parámetro η sobre la distribución.
- (b) Explique para qué se utiliza la distribución de Dirichlet en el modelado de tópicos mediante el algoritmo LDA.
- (c) Explique cuál es la influencia de los parámetros de concentración sobre el modelo de tópicos basado en el algoritmo LDA.

Ejercicio NLP7

- (a) Explique brevemente qué parámetros libres (hiperparámetros) tiene el algoritmo LDA, y su significado.
- (b) Explique brevemente qué resultado produce el algoritmo LDA; indicando qué dimensiones tienen las matrices de salida del algoritmo.
- (c) Suponga que se ha aplicado el algoritmo LDA sobre un corpus de 10000 documentos para obtener una representación en un espacio de 5 tópicos. Explique brevemente cómo utilizaría el modelo generativo del LDA para generar, de forma sintética, un documento artificial de 100 tokens del tópico 0.
- (d) Explique brevemente cómo utilizaría el modelo generativo del apartado anterior LDA para generar, de forma sintética, un documento artificial de 100 tokens, cuyo vector de tópicos es $(0.2, 0.8, 0, 0, 0)$.

Solution:

- (a) Número de tópicos y parámetros de concentración (α y η) de las distribuciones de Dirichlet del algoritmo.
- (b)
 - Matriz de tópicos: dimensiones (número de tokens del vocabulario) $\times$ (número de tópicos)
 - Matriz de documentos: dimensiones (número de documentos del vocabulario) $\times$ (número de tópicos)
- (c) Se seleccionan de forma aleatoria e independiente 100 tokens de acuerdo con la distribución de tokens del tópico 0, que está definida por los valores de probabilidad de la matriz de tópicos en la columna 0.
- (d) Se seleccionan de forma aleatoria e independiente 100 tokens. Para cada token, se selecciona aleatoriamente un tópico: 0 con probabilidad 0.2, o 1 con probabilidad 0.9). Una vez seleccionado el tópico, se selecciona aleatoriamente un token de acuerdo con la distribución de del tópico elegido, que está definida por los valores de probabilidad de la matriz de tópicos en la columna correspondiente.

5.2. Modelos de Lenguaje**Ejercicio NLP8**

Un equipo de desarrollo está implementando un sistema de traducción automática del inglés al español. Inicialmente utilizan una arquitectura basada en RNNs con atención en el decodificador, pero posteriormente migran a un modelo basado en Transformers.

- (a) Describa la arquitectura del sistema basado en RNN con atención en el decodificador, detallando matemáticamente el funcionamiento del mecanismo de atención.
- (b) Explique la diferencia entre *self-attention* y *cross-attention* en la arquitectura codificador-decodificador del Transformer.
- (c) Compare brevemente la eficiencia computacional y la capacidad de paralelización de los modelos Transformer frente a los modelos basados en RNN.

Solution:

- (a) En el modelo RNN con atención, el codificador produce estados ocultos $\mathbf{h}_1, \dots, \mathbf{h}_T$. En cada paso t , el decodificador calcula un contexto como combinación ponderada de

estos estados:

$$\alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_j \exp(e_{t,j})}, \quad e_{t,i} = \mathbf{v}^\top \tanh(\mathbf{W}_1 \mathbf{s}_{t-1} + \mathbf{W}_2 \mathbf{h}_i),$$

$$\mathbf{c}_t = \sum_i \alpha_{t,i} \mathbf{h}_i.$$

El vector $\mathbf{c}_t$ se concatena con el estado del decodificador para predecir la salida.

- (b) En *self-attention*, las consultas, claves y valores provienen de la misma secuencia (p.ej. palabras de entrada en el codificador). En *cross-attention*, las consultas provienen del decodificador mientras que claves y valores provienen de la salida del codificador, permitiendo al decodificador usar la información codificada de la entrada.
- (c) Los RNN procesan secuencias paso a paso, con dependencias temporales que limitan la paralelización. Los Transformers aplican atención en paralelo a toda la secuencia, lo que aumenta la eficiencia y aprovecha mejor el cómputo en GPU/TPU. Esto los hace más rápidos y escalables en secuencias largas.