

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	7	Total
Points:	8	12	20	10	10	10	10	80
Score:								

Indicaciones:


- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita.

1. Primera parte

- (8%) 1. Considere el problema de regresión unidimensional caracterizado por el modelo $y^{(n)} = f(x^{(n)}) + \varepsilon^{(n)}$, en el que las realizaciones del ruido $\varepsilon^{(n)}$ son independientes entre sí, e independientes del valor de la función $f(\cdot)$. Se sabe que $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$ y $f(x) \sim \mathcal{GP}(m, k(x, x'))$, siendo la función de covarianza

$$k(x, x') = \sigma_f^2 \exp \left[-\frac{(x - x')^2}{2\rho^2} \right].$$

La siguiente figura ilustra la media y varianza predictivas de y basadas en la observación de cuatro puntos de entrenamiento $\mathcal{D} = \{x^{(n)}, y^{(n)}\}_{n=1}^4$.



Si se sabe que $f(x^{(2)})|\mathcal{D} \sim \mathcal{N}(2.73, 0)$ y que $f(0)|\mathcal{D} \sim \mathcal{N}(0, 2)$, explique de cuáles de entre las variables siguientes se puede conocer su valor, calculándolo cuando sea posible. Justifique sus respuestas.

- La varianza del ruido: σ_n^2 .
- La media del proceso Gaussiano $f(x)$: m .
- El parámetro σ_f^2 de la función de covarianza.
- El parámetro ρ de la función de covarianza.
- La etiqueta asociada a $x^{(2)}$: $y^{(2)}$.

Solution:

- $\sigma_n^2 = 0$

- (b) $m = 0$
- (c) $\sigma_f^2 = 2$
- (d) No se dispone de suficiente información para determinar el valor de ρ
- (e) $y^{(2)} = 2.73$.

- (12 %) 2. Considere el modelo de regresión no lineal $y = w_1x + w_2x^2 + \varepsilon$, en el que se asumen las siguientes distribuciones a priori: $\varepsilon \sim \mathcal{N}(0, 1)$ y $\mathbf{w} = [w_1, w_2]^T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. Se sabe además que las realizaciones de ruido (ε) son independientes entre sí e independientes de los pesos y del valor de x .

Se observan las salidas $y^{(1)} = 2.5$ e $y^{(2)} = 8.3$ para $x^{(1)} = 1$ y $x^{(2)} = 2$, respectivamente.

- (a) Calcule la distribución a posteriori del vector de pesos.
- (b) Calcule la media predictiva a posteriori para $x^{(3)} = 3$, i.e., $\mathbb{E}\{y^{(3)}|x^{(1)}, y^{(1)}, x^{(2)}, y^{(2)}\}$.

Nota:

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Solution:

$$(a) \Sigma_w = \begin{bmatrix} 6 & 9 \\ 9 & 18 \end{bmatrix}^{-1} \quad \bar{\mathbf{w}} = \Sigma_w \begin{bmatrix} 1 & 1 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} 2.5 \\ 8.3 \end{bmatrix}$$

$$(b) \mathbb{E}\{y^{(3)}|x^{(1)}, y^{(1)}, x^{(2)}, y^{(2)}\} = [3 \ 9] \cdot \bar{\mathbf{w}}$$

- (20 %) 3. Considere el conjunto $\{(\mathbf{x}_i, y_i), i = 1, \dots, N\}$ de muestras independientes e idénticamente distribuidas, siendo $\mathbf{x}_i \in \mathbb{R}$ observaciones unidimensionales. Las variables binarias $y_i \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$p(y|x, w) = (\exp(-(w-x)^2))^y \cdot (1 - \exp(-(w-x)^2))^{1-y}, \quad w \in \mathbb{R}, x \in \mathbb{R}$$

- (a) Suponiendo conocido w , determine las regiones de decisión del decisor MAP basado en este modelo.
- (b) Se desea determinar el estimador ML del parámetro w . Para ello, se minimiza la log-verosimilitud negativa

$$\text{NLL}(w) = -\ln(p(y_1, \dots, y_N | \mathbf{x}_1, \dots, \mathbf{x}_N, w))$$

Determine la regla de descenso por gradiente con paso de aprendizaje η .

- (c) Sabiendo que la distribución a priori del vector de coeficientes es

$$p_W(w) = \frac{1}{\pi(1+w^2)},$$

¿podría determinar una regla de descenso por gradiente que proporcione un estimador MAP?

- (d) Explique (sin hacer los cálculos) cómo determinaría la regla de aprendizaje basada del algoritmo de Newton para este modelo.

Indicación: para obtener una expresión más compacta de la solución, y facilitar el cálculo, puede apoyarse en la función

$$z_i(w) = \exp(-(w - x_i)^2)$$

y tener en cuenta que

$$\frac{dz_i(w)}{dw} = -2(w - x_i) \cdot z_i(w)$$

Solution:

(a) Se decide $D = 1$ para $x \in [w - \sqrt{\ln(2)}, w + \sqrt{\ln(2)}]$

(b)

$$w_{k+1} = w_k - 2\eta \sum_{i=1}^N \frac{y_i - z_i(w_k)}{1 - z_i(w_k)} (w_k - x_i)$$

(c)

$$w_{k+1} = w_k - 2\eta \sum_{i=1}^N \frac{y_i - z_i(w_k)}{1 - z_i(w_k)} (w_k - x_i) - 2\eta \frac{w}{1 + w^2}$$

(10%) 4. Justifique la validez de las siguientes afirmaciones:

- (a) El uso del algoritmo EM para ajustar una mezcla de Gaussianas garantiza encontrar el conjunto de parámetros que maximiza la verosimilitud del modelo.
- (b) Aumentar el número de grupos permite aumentar la verosimilitud de un modelo de mezcla de Gaussianas optimizado mediante el algoritmo EM.

(10%) 5. Se dispone de un conjunto de muestras $\{x_k\}_{k=1}^n$ para el estudio de un determinado proceso físico. Se sabe que dichas muestras han podido ser generadas por G fenómenos diferentes, caracterizados por las siguientes distribuciones con parámetros desconocidos a_i , $i = 1, \dots, G$:

$$p(x|\omega_i, a_i) = a_i \exp[-a_i \exp(-x) + x]; \quad a_i > 0, \quad x \in \mathbb{R}$$

donde ω_i representa el fenómeno que ha causado la observación, siendo desconocidas las probabilidades $P(\omega_i)$.

Para estimar la información desconocida, se decide emplear un procedimiento EM para ajustar el siguiente modelo:

$$p(\{x_k\}_{k=1}^n|\theta) = \prod_{k=1}^n \sum_{i=1}^G P(\omega_i) p(x_k|\omega_i, a_i).$$

donde θ representa el conjunto de parámetros del modelo, i.e., $\theta = [a_1 \dots a_G P(\omega_1) \dots P(\omega_G)]^T$. Obtenga la ecuación que permite actualizar los parámetros a_i en el paso M del algoritmo, a partir de las estimaciones $\hat{P}(\omega_i|x_k, \theta)$.

Solution:

$$\hat{a}_i = \frac{\sum_{k=1}^n \hat{P}(\omega_i|x_k, \theta)}{\sum_{k=1}^n \hat{P}(\omega_i|x_k, \theta) x_k}$$

EJERCICIO 1.

- (a) Dado que $f(x^{(2)})|D$ tiene varianza nula, podemos concluir que conocido el valor de $y^{(2)}$, $f(x^{(2)})$ puede determinarse de forma exacta. Dado que $y^{(2)} = f(x^{(2)}) + \epsilon^{(2)}$, lo anterior sólo es posible si la varianza del ruido es nula: $\sigma_n^2 = 0$

Si lo queremos demostrar de forma más precisa:

$$\begin{bmatrix} y^{(2)} \\ f(x^{(2)}) \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} m \\ m \end{bmatrix}, \begin{bmatrix} \sigma_f^2 + \sigma_n^2 & \sigma_f^2 \\ \sigma_f^2 & \sigma_f^2 \end{bmatrix} \right)$$

Utilizando las propiedades de las distribuciones gaussianas multidimensionales: $\text{Var}[f(x^{(2)})|y^{(2)}] = \sigma_f^2 - \frac{\sigma_f^4}{\sigma_f^2 + \sigma_n^2} = 0$

... lo cual únicamente se verifica si $\sigma_n^2 = 0$.

- (b) y (c)

De la figura vemos que $f(0)|D$ se distribuye igual que $f(0)$ a priori. Por tanto, $m = 0$ y $\sigma_f^2 = 2$

- (d) El valor de f no puede conocerse de forma exacta

- (e) Del razonamiento seguido en el apartado (a) podemos concluir que $f(x^{(2)}) = y^{(2)} = 2.73$

EJERCICIO 2

(a)

Definiendo la transformación no lineal $\phi(x) = \begin{bmatrix} x \\ x^2 \end{bmatrix}$, podemos considerar que tenemos un modelo lineal en el espacio definido por dicha transformación.

Extendiendo los resultados del caso lineal, tenemos:

$$w | \underline{\Phi}, \underline{y} \sim \mathcal{N} \left(\frac{1}{\sigma_n^2} A^{-1} \underline{\Phi}^T \underline{y}, A^{-1} \right)$$

$$\text{donde } A = \frac{1}{\sigma_n^2} \underline{\Phi} \underline{\Phi}^T + \Sigma_p^{-1}$$

Por tanto:

$$\bullet \mathbb{E}[\underline{w} | \underline{\Phi}, \underline{y}] = (\underline{\Phi} \underline{\Phi}^T + \mathbf{I})^{-1} \underline{\Phi} \cdot \underline{y}$$

$$\text{con } \underline{y} = \begin{bmatrix} 2.5 \\ 8.3 \end{bmatrix} \text{ y } \underline{\Phi} = \begin{bmatrix} 1 & 2 \\ 1 & 4 \end{bmatrix}$$

$$\bullet \text{Cov}[\underline{w} | \underline{\Phi}, \underline{y}] = (\underline{\Phi} \underline{\Phi}^T + \mathbf{I})^{-1} = \begin{pmatrix} 6 & 9 \\ 9 & 18 \end{pmatrix}^{-1}$$

$$(b) \mathbb{E}\{y^{(3)} | \underline{\Phi}, \underline{y}\} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}^T \mathbb{E}\{\underline{w} | \underline{\Phi}, \underline{y}\}$$

$$= \begin{bmatrix} 1 & 3 \end{bmatrix} \cdot \frac{1}{27} \begin{pmatrix} 18 & -9 \\ -9 & 6 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 1 & 4 \end{pmatrix} \begin{bmatrix} 2.5 \\ 8.3 \end{bmatrix}$$

P3

a


$$p(1|x, \omega) \stackrel{1}{\geq} \sum_0 p(0|x, \omega) \Leftrightarrow$$

$$\Leftrightarrow \exp(-(w-x)^2) \stackrel{1}{\geq} 1 - \exp(-(w-x)^2) \Leftrightarrow$$

$$\Leftrightarrow 2\exp(-(w-x)^2) \stackrel{1}{\geq} 1 \Leftrightarrow$$

$$\Leftrightarrow (w-x)^2 \leq \ln 2 \Leftrightarrow$$

$$D = \begin{cases} 1 & \text{si } \omega - \sqrt{\ln 2} < x < \omega + \sqrt{\ln 2} \\ 0 & \text{resto} \end{cases}$$



b

$$\begin{aligned} NLL(\omega) &= -\ln p(y_1, \dots, y_N | x_1, \dots, x_N, \omega) = -\sum_{k=1}^N \ln p(y_k | x_k, \omega) = \\ &= \sum_{k=1}^N y_k (w - x_k)^2 - \sum_{k=1}^N (1 - y_k) \ln (1 - \exp(-(w - x_k)^2)) \Rightarrow \end{aligned}$$

$$\begin{aligned} \Rightarrow \frac{dNLL(\omega)}{d\omega} &= \sum_{k=1}^N 2y_k (w - x_k) - \sum_{k=1}^N (1 - y_k) \frac{-\exp(-(w - x_k)^2)}{1 - \exp(-(w - x_k)^2)} \cdot (-2(w - x_k)) \\ &= \sum_{k=1}^N 2(w - x_k) \left[y_k - (1 - y_k) \frac{\exp(-(w - x_k)^2)}{1 - \exp(-(w - x_k)^2)} \right] = \\ &= \sum_{k=1}^N 2(w - x_k) \frac{y_k - \exp(-(w - x_k)^2)}{1 - \exp(-(w - x_k)^2)} \end{aligned}$$

llamando

$$z_{ik} = \exp(-(w_i - x_k)^2) \Rightarrow$$

$$w_{i+1} = w_i - \eta \sum_{k=1}^N (w_i - x_k) \frac{y_k - z_{ik}}{1 - z_{ik}}$$

c El estimador MAP será

$$\begin{aligned}\omega_{\text{MAP}} &= \arg \max_{\omega} p(\omega | y_1, \dots, y_N, x_1, \dots, x_N) = \\ &= \arg \max_{\omega} p_W(\omega) \cdot p(y_1, \dots, y_N | x_1, \dots, x_N, \omega) = \\ &= \arg \min_{\omega} [NLL(\omega) - \ln p_W(\omega)]\end{aligned}$$

Sabiendo que

$$\frac{d}{d\omega} \ln p_W(\omega) = \frac{d}{d\omega} \ln [\pi(1+\omega^2)] = \frac{2\omega}{1+\omega^2} \Rightarrow$$

$$\begin{aligned}\omega_{i+1} &= \omega_i - \eta NLL'(\omega_i) = \eta \cdot \frac{2\omega_i}{1+\omega_i^2} = \\ &= \omega_i - 2\eta \left[\sum_{k=1}^N \frac{y_k - z_{ik}}{1 - z_{ik}} (\omega_i - z_{ik}) + \frac{\omega_i}{1+\omega_i^2} \right]\end{aligned}$$

d El algoritmo de Newton adopta la forma $\omega_{i+1} = \omega_i - \eta \left[\frac{\partial^2 NLL(\omega_i)}{\partial \omega_i^2} \right]^{-1} \frac{dNLL(\omega_i)}{d\omega_i}$
Por tanto, bastaría con calcular $\frac{d^2 NLL(\omega_i)}{d\omega_i^2}$

$$z_k(\omega) = \exp(-(\omega - x_k)^2) \Rightarrow z_k'(\omega) = -2(\omega - x_k) z_k(\omega) \Rightarrow$$

$$\begin{aligned}\frac{d^2 NLL(\omega)}{d\omega^2} &= 2 \sum_{k=1}^N \frac{y_k - z_k(\omega)}{1 - z_k(\omega)} + \sum_{k=1}^N (\omega - x_k) \frac{-z_k'(\omega)(1 - z_k(\omega)) + z_k'(\omega)(y_k - z_k(\omega))}{[1 - z_k(\omega)]^2} \\ &= 2 \sum_{k=1}^N \frac{y_k - z_k(\omega)}{1 - z_k(\omega)} + \sum_{k=1}^N (\omega - x_k) \frac{y_k - 1}{[1 - z_k(\omega)]^2} \cdot (-2(\omega - x_k) z_k(\omega)) \\ &= 2 \sum_{k=1}^N \frac{y_k - z_k(\omega)}{1 - z_k(\omega)} - 2 \sum_{k=1}^N \frac{(y_k - 1) z_k(\omega)}{(1 - z_k(\omega))^2} \cdot (\omega - x_k)^2\end{aligned}$$

Por tanto el algoritmo de Newton será

$$\omega_{i+1} = \omega_i - \eta \frac{\sum_{k=1}^N \frac{y_k - z_{ik}}{1 - z_{ik}} (\omega_i - z_{ik})}{\sum_{k=1}^N \frac{y_k - z_{ik}}{1 - z_{ik}} + \sum_{k=1}^N \frac{(y_k - 1) z_{ik}}{(1 - z_{ik})^2} (\omega_i - x_{ik})^2}$$

EJERCICIO 4

- (a) La afirmación no es correcta. El algoritmo EM converge en general a un máximo local de la verosimilitud. De hecho, podemos comprobar (lo hemos visto en la sesión de laboratorio), que inicializando el modelo con distintos valores se converge a soluciones diferentes.
- (b) Nuevamente, dependerá de cada inicialización concreta, pero en general aumentar el número de grupos si permite ~~(obtener soluciones)~~ garantizar que la verosimilitud ~~(óptima)~~ del modelo óptimo crezca. Otra cosa es que no podemos garantizar que ~~(dicha solución)~~ el algoritmo EM converja a dicha solución óptima.

Exercício 5

A solução de máxima verossimilhança verifica:

$$\sum_{k=1}^K \hat{P}(w_i | x_k, \hat{\underline{\theta}}_{ML}) \cdot \nabla_{\underline{\theta}_i} \ln p(x_k | w_i, \underline{\theta}_i, \mu_i) = 0$$

como $\frac{d}{da_i} \ln p(x_k | w_i, a_i) = \frac{1}{a_i} - \exp(-x^{(k)})$, temos

$$\sum_{k=1}^K \hat{P}(w_i | x_k, \hat{\underline{\theta}}_{ML}) \left[\frac{1}{\hat{a}_i} - \exp(-x^{(k)}) \right] = 0$$

$$\frac{1}{\hat{a}_i} \sum_{k=1}^K \hat{P}(w_i | x_k, \hat{\underline{\theta}}_{ML}) - \sum_{k=1}^K \hat{P}(w_i | x_k, \hat{\underline{\theta}}_{ML}) \exp(-x^{(k)}) = 0$$

$$\hat{a}_i = \frac{\sum_{k=1}^K \hat{P}(w_i | x_k, \hat{\underline{\theta}}_{ML})}{\sum_{k=1}^K \hat{P}(w_i | x_k, \hat{\underline{\theta}}_{ML}) \cdot \exp(-x^{(k)})}$$