

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

(10 %) 1. Indique si las siguientes afirmaciones son verdaderas o falsas:

- (a) k -NN puede considerarse un método de regresión paramétrica ya que requiere el ajuste de un parámetro (k).
☐ Verdadero. ☒ **Falso.**
- (b) En Inferencia Bayesiana no es posible ajustar los hiperparámetros mediante validación cruzada, por lo que ha de recurrirse a la maximización de la verosimilitud marginal.
☐ Verdadero. ☒ **Falso.**
- (c) La regresión mediante procesos gaussianos proporciona una estimación de la confianza del propio modelo acerca de cada una de sus predicciones.
☒ **Verdadero.** ☐ Falso.
- (d) Una función de covarianzas proporciona un criterio para medir la similitud existente entre dos matrices de covarianzas diferentes.
☐ Verdadero. ☒ **Falso.**

(10 %) 2. Indique cuáles de los siguientes clasificadores tienen siempre fronteras de clasificación lineales:

- (a) $1 - NN$.
☐ Verdadero. ☒ **Falso.**
- (b) Clasificador basado en un modelo de regresión logística: $P_{Y|\mathbf{X}, \mathbf{w}}(1|\mathbf{x}, \mathbf{w}) = f(\mathbf{w}^\top \mathbf{x})$, siendo f la función logística.
☒ **Verdadero.** ☐ Falso.
- (c) Máquina de vectores soporte con kernel $k(\mathbf{x}, \mathbf{x}') = \mathbf{x}^\top \mathbf{x}'$
☒ **Verdadero.** ☐ Falso.
- (d) Máquina de vectores soporte con kernel $k(\mathbf{x}, \mathbf{x}') = \exp(-\mathbf{x}^\top \mathbf{x}')$
☐ Verdadero. ☒ **Falso.**

(10 %) 3. Indique si las siguientes afirmaciones son ciertas o falsas:

- (a) La lematización (stemming) consiste en eliminar de una colección de documentos las palabras que no proporcionan ninguna información semántica relevante para el modelado de tópicos.
☐ Verdadero. ☒ **Falso.**
- (b) Permutar el orden de las palabras de un documento no tienen ninguna influencia en su representación como *bolsa-de-palabras*.
☒ **Verdadero.** ☐ Falso.

- (c) Un tópico en Latent Dirichlet Allocation (LDA) se define como una colección de documentos con una temática común.
☐ Verdadero. ☒ **Falso.**
- (d) LDA se basa en un modelo generativo que caracteriza la generación de todos los documentos de una colección. Por lo tanto, si el modelo generativo se ejecutase múltiples veces, en todas las ocasiones se obtendría la misma colección de documentos.
☐ Verdadero. ☒ **Falso.**
- (e) Al usar LDA cada palabra del vocabulario puede pertenecer como máximo a un tópico.
☐ Verdadero. ☒ **Falso.**
- (f) De acuerdo al modelo generativo de LDA, las proporciones de tópicos calculadas por el algoritmo suman necesariamente 1 para cada documento de la colección.
☒ **Verdadero.** ☐ Falso.

- (25 %) 4. Se dispone del siguiente conjunto de datos de entrenamiento $\mathcal{D} = \{x_i, s_i\}_{i=1}^5$ para un problema de regresión unidimensional

i	1	2	3	4	5
x_i	-2	-1	0	1	2
s_i	8.2	3.6	1.8	3.8	7.6

- (a) Represente la curva de regresión obtenida mediante la aplicación del procedimiento del vecino más próximo (1-NN).
- (b) Represente la curva de regresión obtenida por el método k -NN, para $k = 2$.
- (c) Asumiendo el siguiente modelo paramétrico

$$s_i = w_0 + w_1 x_i^2,$$

proporcione los coeficientes óptimos del modelo de acuerdo con el procedimiento de mínimos cuadrados (LS).


- (d) Asuma ahora el siguiente modelo paramétrico para la generación de los datos

$$s_i = w_0 + w_1 x_i^2 + \varepsilon_i,$$


en el que las muestras de ruido ε_i , $i = 1, \dots, 5$, son realizaciones independientes entre sí e independientes de los parámetros del modelo. Asumiendo además las distribuciones a priori $\mathbf{w} = [w_0, w_1]^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ y $\varepsilon \sim \mathcal{N}(0, 1)$, indique cómo calcularía la distribución a posteriori del vector de pesos, i.e., $p(\mathbf{w}|\mathcal{D})$.

- (25 %) 5. (a) Explique brevemente qué modelo estadístico de los datos supone implícitamente un algoritmo de regresión logística.
- (b) Desde el punto de vista de la función que se optimiza, ¿en qué se diferencia el estimador MAP de los parámetros del modelo y el ML?
- (20 %) 6. (a) Indique qué función de distorsión optimiza el algoritmo k -medias.
- (b) Explique brevemente los pasos del algoritmo.
- (c) Explique, mediante un ejemplo gráfico, la diferencia en el comportamiento del algoritmo k -medias y un algoritmo de agrupamiento espectral.

CUESTIÓN 4



5 pt.



6 pt

(c)

$$\begin{bmatrix} w_0^* \\ w_1^* \end{bmatrix} = (Z^T Z)^{-1} Z^T \underline{s} \quad ; \quad \text{con } Z = \begin{bmatrix} 1 & 4 \\ 1 & 1 \\ 1 & 0 \\ 1 & 1 \\ 1 & 1 \\ 1 & 4 \end{bmatrix} \quad y \quad \underline{s} = \begin{bmatrix} 8.2 \\ 3.6 \\ 1.8 \\ 3.8 \\ 7.6 \end{bmatrix}$$

7 pt

operando:

$$\begin{bmatrix} w_0^* \\ w_1^* \end{bmatrix} = \begin{bmatrix} 5 & 10 \\ 10 & 34 \end{bmatrix}^{-1} \begin{bmatrix} 25 \\ 70.6 \end{bmatrix} = \frac{1}{70} \begin{bmatrix} 34 & -10 \\ -10 & 5 \end{bmatrix} \begin{bmatrix} 25 \\ 70.6 \end{bmatrix} \approx \begin{bmatrix} 144/70 \\ 103/70 \end{bmatrix}$$

(d) $p(\underline{w} | D) \sim \mathcal{N}(\bar{\underline{w}}, \Sigma_{\underline{w}})$, donde

$$\Sigma_{\underline{w}} = \left[\frac{1}{v_e^2} Z^T Z + \Sigma_p^{-1} \right]^{-1} = (Z^T Z + I)^{-1}$$

$$\bar{\underline{w}} = v_e^{-2} \Sigma_{\underline{w}} Z^T \underline{s} = (Z^T Z + I)^{-1} Z^T \underline{s}$$

7 pt

donde Z y $\underline{s}$ son los definidos en el apdo anterior.