

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

(10%) 1. Considere un conjunto de ℓ datos de entrenamiento para un problema de regresión unidimensional, $\{x_i, s_i\}_{i=1}^{\ell}$, $x_i, s_i \in \mathbb{R}$. Se puede afirmar que:

- (a) El error de entrenamiento del algoritmo k -NN es no decreciente con el valor de k .
☐ Verdadero. ☒ **Falso.**
- (b) El error cuadrático promedio de entrenamiento de un modelo de regresión lineal *least squares* no puede crecer al aumentar el número de muestras de entrenamiento disponibles.
☐ Verdadero. ☒ **Falso.**
- (c) Para una función analítica de regresión determinada, $\hat{s}_w(x)$, la inferencia bayesiana, gracias a su enfoque probabilístico, proporciona el menor error cuadrático promedio posible en el conjunto de entrenamiento.
☐ Verdadero. ☒ **Falso.**
- (d) La inferencia bayesiana es un método probabilístico, y como tal no requiere ajustar hiperparámetros.
☐ Verdadero. ☒ **Falso.**

(10%) 2. Se puede afirmar que:

- (a) Si los datos de entrenamiento son linealmente separables, una máquina de vectores soporte (SVM) lineal puede garantizar cero errores de clasificación en el conjunto de entrenamiento.
☒ **Verdadero.** ☐ Falso.
- (b) Si los datos de entrenamiento son linealmente separables, una SVM lineal puede garantizar cero errores de clasificación en el conjunto de test.
☐ Verdadero. ☒ **Falso.**
- (c) Si los datos no son linealmente separables, se pueden conseguir cero errores de clasificación sobre el conjunto de entrenamiento utilizando variables de holgura (*slack variables*) y una SVM lineal.
☐ Verdadero. ☒ **Falso.**
- (d) La elección del parámetro C del clasificador SVM permite graduar el número de vectores soporte, pero no afecta a las tasas de error de clasificación sobre el conjunto de test.
☐ Verdadero. ☒ **Falso.**

Se puede afirmar que

- (10%) 3. (a) Una de las diferencias fundamentales entre los algoritmos de agrupamiento k -medias y clustering espectral, es que el primero emplea representantes o centroides para cada uno de los grupos, y el segundo no.
☒ **Verdadero.** ☐ Falso.

- (b) Conviene fijar un número máximo de iteraciones al aplicar k medias, porque de lo contrario el algoritmo podría no converger en tiempo finito.

☐ Verdadero. ☒ **Falso.**

- (c) En clustering espectral, únicamente se pueden identificar los grupos a partir de la matriz de afinidad cuando estos vienen ordenados según la clase real a la que pertenece cada dato.

☐ Verdadero. ☒ **Falso.**

- (d) El algoritmo de clustering espectral se basa en la identificación de los autovectores asociados a los mayores autovalores del Laplaciano de la matriz de afinidad.

☐ Verdadero. ☒ **Falso.**

- (25 %) 4. Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_k, s_k\}_{k=1}^{\ell}$ para un problema de regresión. Las variables s_k están relacionadas con las entradas $\mathbf{x}_k$ a través del modelo

$$s_k = w_0 + w_1 x_{k,1} + w_2 x_{k,2} + \varepsilon_k,$$

en el que las variables ε_k , $k = 1, \dots, \ell$, son muestras de ruido independientes entre sí e independientes de los parámetros del modelo, con media 0 y varianza 2.

Se sabe que la distribución a priori de cada uno de los coeficientes w_i del modelo es gaussiana de media 0 y varianza 100, y que todos los parámetros del modelo son, apriori, independientes entre sí.

- (a) Indique la secuencia de ecuaciones que deben aplicarse para estimar la media y la varianza de la distribución a posteriori del vector de pesos $\mathbf{w} = (w_0, w_1, w_2)$ dado $\mathcal{D}$. (Puede definir, para ello, las variables intermedias que considere oportunas),
- (b) Suponga que, tras completar el cálculo de la media y la varianza a posteriori, se recibe un conjunto adicional de datos $\mathcal{D}'$ del mismo modelo. Discuta cómo podría estimar la distribución a posteriori de $\mathbf{w}$ dados $\mathcal{D}$ y $\mathcal{D}'$ sin necesidad de volver a utilizar $\mathcal{D}$.
- (c) Finalmente, suponga que el conjunto $\mathcal{D}'$ corresponde al mismo modelo, pero las componentes de ruido del nuevo dataset tienen varianza 8. ¿Qué consecuencia tiene esto sobre el diseño del apartado anterior?

- (25 %) 5. Se dispone de una colección de datos etiquetados $\mathcal{S} = \{(\mathbf{x}^{(n)}, y^{(n)}), n = 1, \dots, 100\}$ relativos a un problema de clasificación binaria. Las etiquetas $y^{(n)}$ toman valores binarios en $\{0, 1\}$. Según se ha estudiado, la ecuación que define la solución de máximo a posteriori de un modelo de regresión logística es

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg \min_{\mathbf{w}} \{L(\mathbf{w}) - \log[p_{\mathbf{w}}(\mathbf{w})]\}$$

donde $p_{\mathbf{w}}(\mathbf{w})$ es el prior del vector de pesos y $L(\mathbf{w})$ es la verosimilitud del modelo dada por

$$L(\mathbf{w}) = - \sum_{n=1}^{100} \log \left[P_{Y|\mathbf{X}}(y^{(n)} | \mathbf{x}^{(n)}, \mathbf{w}) \right]$$

- (a) Particularice la verosimilitud para el modelo de regresión logística estudiado en la asignatura.
- (b) Derive un algoritmo de descenso de gradiente que permita optimizar la solución de forma iterativa asumiendo un prior gaussiano para $\mathbf{w}$, con media $\mathbf{w}_0$ y matriz de covarianzas $v\mathbf{I}$.

- (20 %) 6. (a) Describa muy brevemente, con ayuda de un diagrama de bloques, el modelo de generación de documentos del corpus que supone el algoritmo LDA.
- (b) Explique qué resultados produce el algoritmo LDA y qué representan. ¿Cómo podría reconocer si una matriz de tópicos procede de un algoritmo LDA o LSI?