

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10%) 1. Considere un conjunto de ℓ datos de entrenamiento, $\{x_i, s_i\}_{i=1}^{\ell}$, $x_i, s_i \in \mathbb{R}$. Se desea aplicar un algoritmo de regresión paramétrica para predecir s a partir de x . Para ello, se ofrecen dos alternativas: (1) obtener el coeficiente w_{LS} de regresión de mínimos cuadrados, o bien (2) suponer que las observaciones x_i son i.i.d. (independientes e idénticamente distribuidas) y se han generado a partir de s_i mediante $x_i = ws_i + \epsilon_i$, siendo ϵ_i una variable de ruido aleatorio de distribución $p_E(\epsilon)$, y calcular el estimador w_{ML} de máxima verosimilitud.

Se puede afirmar que:

- (a) Si $p_E(\epsilon)$ es gaussiana de media nula, $w_{LS} = w_{ML}$.
☒ Verdadero. ☐ Falso.
- (b) Si $p_E(\epsilon)$ no es gaussiana, $w_{LS} = w_{ML}$.
☐ Verdadero. ☒ Falso.
- (c) Para calcular w_{ML} es necesario conocer la distribución a priori de w , $p_W(w)$.
☐ Verdadero. ☒ Falso.
- (d) El error cuadrático promedio del predictor $\hat{s} = w_{ML}x$, evaluado sobre el conjunto de entrenamiento, es cero.
☐ Verdadero. ☒ Falso.

- (10%) 2. Se puede afirmar que:

- (a) Si los datos de entrenamiento son linealmente separables, un clasificador basado en k-NN producirá una frontera lineal.
☐ Verdadero. ☒ Falso.
- (b) Si los datos de entrenamiento son linealmente separables, un clasificador basado en k-NN tendrá siempre una tasa de errores nula sobre el conjunto de entrenamiento, para cualquier valor de k .
☐ Verdadero. ☒ Falso.
- (c) En una SVM lineal aplicada a un conjunto de datos linealmente separable, el tamaño del margen es inversamente proporcional a la norma del vector de pesos, $\mathbf{w}$.
☒ Verdadero. ☐ Falso.
- (d) Considérese la clasificación mediante SVM en un caso no separable, para el que se introducen *slack variables* ξ_i , cada una de ellas asociada a una muestra de entrenamiento diferente. El valor de ξ_i únicamente es mayor de 0 para aquellas muestras de entrenamiento que se clasifican erróneamente.
☐ Verdadero. ☒ Falso.

Se puede afirmar que

- (10 %) 3. (a) La eliminación de *stopwords* durante el preprocesado de los documentos de un corpus documental tiene como principal objetivo suprimir palabras poco frecuentes que aparecen en muy pocos documentos de la colección.
☐ Verdadero. ☒ **Falso.**
- (b) En el contexto del Procesamiento de Lenguaje Natural, los procesos de *Stemming* y lematización pueden considerarse complementarios, por lo que suele aplicarse la lematización sobre los resultados del *stemming*.
☐ Verdadero. ☒ **Falso.**
- (c) De acuerdo al modelo generativo del algoritmo LDA, la suma de las componentes del vector θ_d de cada documento es siempre 1.
☒ **Verdadero.** ☐ Falso.
- (d) De acuerdo al modelo generativo del algoritmo LDA, la suma de las componentes i -ésimas de los vectores β_k que caracterizan a todos los tópicos es siempre 1, i.e., $\sum_k \beta_{k,i} = 1$, donde la suma se realiza sobre todos los tópicos del modelo.
☐ Verdadero. ☒ **Falso.**
- (25 %) 4. Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_k, s_k\}_{k=1}^\ell$ para un problema de regresión, con el que se desea ajustar un modelo polinómico

$$\hat{s}_k = w_0 + w_1 x_{k,1} + w_2 x_{k,2} + w_3 x_{k,1}^2 + w_4 x_{k,2}^2$$

- (a) Indique la secuencia de ecuaciones que deben aplicarse para obtener los pesos del estimador LS dado $\mathcal{D}$, $\mathbf{w}_{\text{LS}}$. (Puede definir, en este apartado y los siguientes, las variables intermedias que considere oportunas para simplificar la notación)

Para abordar el problema mediante un enfoque basado en regresión bayesiana, se considera que las variables s_k están relacionadas con las entradas $\mathbf{x}_k$ a través del modelo

$$s_k = w_0 + w_1 x_{k,1} + w_2 x_{k,2} + w_3 x_{k,1}^2 + w_4 x_{k,2}^2 + \varepsilon_k,$$

en el que las variables ε_k , $k = 1, \dots, \ell$, son muestras de ruido independientes entre sí e independientes de los parámetros del modelo, con media 0 y varianza 2.

Además, se asume por simplicidad que la distribución a priori de cada uno de los coeficientes w_i del modelo es gaussiana de media 0 y varianza 100, y que todos los parámetros del modelo son, a priori, independientes entre sí.

- (b) Indique la secuencia de ecuaciones que deben aplicarse para obtener el estimador de máximo a posteriori de $\mathbf{w}$ dado $\mathcal{D}$, $\mathbf{w}_{\text{MAP}}$.
- (c) Utilizando la asunción de que la matriz de covarianzas a posteriori de $\mathbf{w}$ dado $\mathcal{D}$ es $3\mathbf{I}$, exprese la varianza predictiva de s dado $\mathbf{x}$, i.e., $\text{Var}\{s|\mathbf{x}, \mathcal{D}\}$.

Solution:

- (a) Definiendo

$$\mathbf{s} = [s_1, s_2, \dots, s_\ell]^\top \quad (\ell \times 1)$$

$$\mathbf{Z} = \begin{bmatrix} 1 & x_{1,1} & x_{1,2} & x_{1,1}^2 & x_{1,2}^2 \\ 1 & x_{2,1} & x_{2,2} & x_{2,1}^2 & x_{2,2}^2 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{\ell,1} & x_{\ell,2} & x_{\ell,1}^2 & x_{\ell,2}^2 \end{bmatrix} \quad (\ell \times 5)$$

Se tiene que $\mathbf{w}_{\text{LS}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{s}$.

- (b) Como $p(\mathbf{w}|\mathbf{s})$ es gaussiana, el máximo de dicha distribución coincide con su media, i.e., $\mathbf{w}_{\text{MAP}} = \mathbf{w}_{\text{MSE}}$, y pueden emplearse las ecuaciones para el cálculo de la media a posteriori:

$$\mathbf{V}_{\mathbf{w}} = \left[\frac{1}{\sigma_{\varepsilon}^2} \mathbf{Z}^{\top} \mathbf{Z} + \Sigma_p^{-1} \right]^{-1}$$

$$\mathbf{w}_{\text{MAP}} = \frac{1}{\sigma_{\varepsilon}^2} \mathbf{V}_{\mathbf{w}} \mathbf{Z}^{\top} \mathbf{s}$$

donde $\sigma_{\varepsilon} = \sqrt{2}$ y $\Sigma_p = 100\mathbf{I}$.

- (c) Definiendo $\mathbf{z} = [1, x_1, x_2, x_1^2, x_2^2]^{\top}$, tenemos $s = \mathbf{w}^{\top} \mathbf{z} + \varepsilon$. Por tanto:

$$\text{Var}\{s|\mathbf{s}\} = \mathbf{z}^{\top} \text{Cov}(\mathbf{w}|\mathbf{s}) \mathbf{z} + \sigma_{\varepsilon}^2 = 3\mathbf{z}^{\top} \mathbf{z} + 2,$$

donde se ha empleado la independencia de cada muestra de ruido, y la asunción del anunciado: $\text{Cov}(\mathbf{w}|\mathbf{s}) = 3\mathbf{I}$.

- (25 %) 5. Se dispone de una colección de datos etiquetados $\mathcal{S} = \{(x_n, y_n), n = 1, \dots, 100\}$, donde las observaciones x_n son unidimensionales y las etiquetas y_n toman valores binarios en $\{0, 1\}$. Se desea utilizar estos datos para diseñar un clasificador paramétrico basado en el modelo de probabilidad a posteriori dado por

$$p(y|x, w) = \frac{(x - w)^{2y}}{1 + (x - w)^2}, \quad w \in \mathbb{R}, x \in \mathbb{R}$$

- (a) Suponga que $w = 3$. Represente gráficamente, sobre la recta $\mathbb{R}$, las regiones de decisión del clasificador de mínima probabilidad de error (o MAP, de máximo a posterior).
- (b) Determine una expresión para la log-verosimilitud negativa del modelo, $L(w)$ para las observaciones en el conjunto $\mathcal{S}$.
- (c) Derive la regla de descenso por gradiente para determinar el estimador de w de mínima log-verosimilitud negativa, con paso de adaptación ρ . Para simplificar las expresiones, exprese la regla utilizando $q_{k,n} = \frac{(x_n - w_k)^2}{1 + (x_n - w_k)^2}$

Solution:

- (a) La regla de decisión MAP s

$$p(1|x, w) \underset{D=0}{\overset{D=1}{\geq}} \frac{1}{2}$$

luego

$$\frac{(x - w)^2}{1 + (x - w)^2} \underset{D=0}{\overset{D=1}{\geq}} \frac{1}{2}$$

es decir

$$(x - w)^2 \underset{D=0}{\overset{D=1}{\geq}} 1$$

Por tanto, se decide 1 para $w - 1 \leq x \leq w + 1$

(b) La log-verosimilitud negativa será

$$\begin{aligned}
 L(w) &= -\log \left(\prod_{n=1}^{100} p(y_n | x_n, w) \right) \\
 &= -\sum_{n=1}^{100} \log p(y_n | x_n, w) \\
 &= -\sum_{n=1}^{100} \log \frac{(x - w)^{2y}}{1 + (x - w)^2} \\
 &= -\sum_{n=1}^{100} \left(y_n \log \left((w - x_n)^2 \right) - \log \left(1 + (w - x_n)^2 \right) \right) \quad (1)
 \end{aligned}$$

(c) Derivando la expresión anterior, resulta

$$\begin{aligned}
 \frac{dL}{dw} &= -\sum_{n=1}^{100} \left(2y_n \frac{1}{w - x_n} - \frac{2(w - x_n)}{1 + (w - x_n)^2} \right) \\
 &= -\sum_{n=1}^{100} \frac{2}{w - x_n} \left(y_n - \frac{(x_n - w)^2}{1 + (x_n - w)^2} \right) \quad (2)
 \end{aligned}$$

Por tanto: $w_{k+1} = w_k - 2\rho \sum_{k=1}^{100} \frac{y_n - q_{k,n}}{w_k - x_n}$

- (20 %) 6. (a) Explique qué función de distorsión persigue minimizar el algoritmo k -medias.
 (b) Explique por qué el número de grupos del algoritmo k -medias no se puede determinar eligiendo el número de grupos que minimicen la función de distorsión.
 (c) Explique por qué se aplica el algoritmo k -medias en una de las etapas del algoritmo de clustering espectral.

Solution:

(a) El algoritmo k -medias persigue minimizar la distorsión cuadrática total

$$D = \sum_{k=1}^K \sum_{\mathbf{x} \in \mathcal{G}_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2$$

siendo K el número de grupos, $\mathcal{G}_k$ el grupo k y $\boldsymbol{\mu}_k$ es el centroide del grupo k .

- (b) Porque la distorsión cuadrática total se minimiza asignando un centroid a cada muestra (en cuyo caso $D = 0$). Dicha optimización no tendría interés práctico.
 (c) Los autovectores de la matriz de similitud con menores autovalores tienen dimensión igual al número de muestras, y tienden a tomar valores similares en las componentes relativas a las muestras similares (conectadas en un cluster). Los grupos de muestras con valores similares de estas componentes forman clusters conectados en el grafo original, y pueden descubrirse aplicando k -medias.