

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	20	10	10	25	25	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de muestras $\mathcal{D} = \{\mathbf{x}_k, 0 \leq k < K\}$, todas distintas, para aplicar un algoritmo de agrupamiento con N grupos, con $N \leq K$.

Se puede afirmar que

- (a) En una iteración del algoritmo k -means, la distorsión cuadrática total puede aumentar.
☐ Verdadero.
☒ **Falso.**
- (b) La mínima distorsión cuadrática total que puede alcanzar el algoritmo k -means decrece al aumentar N .
☒ **Verdadero.**
☐ Falso.
- (c) Cuando $N = K$, la mínima distorsión cuadrática total que puede alcanzar el algoritmo k -means es nula.
☒ **Verdadero.**
☐ Falso.
- (d) El algoritmo de clustering espectral permite obtener un agrupamiento con menor distorsión cuadrática total que la menor distorsión cuadrática alcanzable por el algoritmo k -medias con el mismo número de grupos.
☐ Verdadero.
☒ **Falso.**

- (20 %) 2. Considere el corpus formado por la siguiente lista de 3 documentos

- Doc 0: 'Un robot no hará daño a un ser humano o, por inacción, permitirá que un ser humano sufra daño'
- Doc 1: 'Un robot debe cumplir las órdenes dadas por los seres humanos, a excepción de aquellas que entrasen en conflicto con la primera ley'
- Doc 2: 'Un robot debe proteger su propia existencia en la medida en que esta protección no entre en conflicto con la primera o con la segunda ley'

- (a) Aplique sobre el corpus un procesado de texto estándar, que convierta cada documento en una lista de tokens apropiada para el análisis semántico.
- (b) Construya un modelo de bolsa de palabras (BoW) para el corpus dado, determinando la representación vectorial del documento 1.

- (c) Considere el siguiente modelo generativo del corpus: cada documento se ha generado estocásticamente como una secuencia aleatoria de palabras, donde cada palabra se ha generado aleatoriamente de acuerdo con una distribución de probabilidad común para todas las palabras. Dado el corpus, infiera una distribución de probabilidad para el corpus dado.

Solution:

- (a)
- Doc 0: ['robot', 'daño', 'ser humano', 'inacción', 'permitir', 'ser humano', 'sufrir', 'daño']
 - Doc 1: ['robot', 'deber', 'cumplir', 'orden', 'dar', 'ser humano', 'entrar', 'conflicto', 'primera', 'ley']
 - Doc 2: ['robot', 'deber', 'proteger', 'propia', 'existencia', 'protección', 'entrar', 'conflicto', 'primera', 'segunda', 'ley']
- (b) Un posible diccionario, junto con la representación vectorial del documento 1 se muestran en la tabla siguiente:

	Diccionario	Doc 1	Distrib. prob
0	'robot'	1	3/29
1	'daño'	0	2/29
2	'ser humano'	1	3/29
3	'inacción'	0	1/29
4	'permitir'	0	1/29
5	'sufrir'	0	1/29
6	'deber'	1	2/29
7	'cumplir'	1	1/29
8	'orden'	1	1/29
9	'dar'	1	1/29
10	'entrar'	1	2/29
11	'conflicto'	1	2/29
12	'primera'	1	2/29
13	'ley'	1	2/29
14	'proteger'	0	1/29
15	'propia'	0	1/29
16	'existencia'	0	1/29
17	'protección'	0	1/29
18	'segunda'	0	1/29

- (c) Una distribución de probabilidad basada en frecuencias de palabras se muestra también en la tabla anterior.

- (10 %) 3. Se dispone de un conjunto de K muestras de entrenamiento, $\mathcal{D} = \{(x_k, s_k), 0 \leq k < K\}$ y otro de K' muestras de validación, $\mathcal{D}' = \{(x_k, s_k), K \leq k < K + K'\}$, relativos a un problema de regresión unidimensional.

Considere el modelo de regresión polinómica de grado m dado por

$$s = \mathbf{w}^\top \mathbf{z} + \epsilon \quad (1)$$

siendo $\mathbf{z} = (1, x, x^2, \dots, x^m)$, y siendo $\epsilon \in \mathbb{R}$ ruido gaussiano de media 0 y varianza 1. Suponga que la distribución a priori de $\mathbf{w}$ es también gaussiana de media 0 y varianza $\sigma^2 \mathbf{I}$.

Sean $L_m(\mathbf{w})$ y $L'_m(\mathbf{w})$ las funciones de log-verosimilitud obtenidas con los datos de entrenamiento y de validación, respectivamente. Asimismo, sea $P_m(\mathbf{w} | \mathcal{D})$ la distribución a posteriori de $\mathbf{w}$ dado $\mathcal{D}$, de acuerdo con el modelo de grado m .

Sean $\mathbf{w}_{\text{ML},m}$ y $\mathbf{w}_{\text{MAP},m}$ los estimadores ML y MAP basados en los datos de entrenamiento, de acuerdo con el modelo de grado m .

Se puede afirmar que:

- (a) La log-verosimilitud de entrenamiento del estimador ML aumenta (o, al menos, no disminuye) con el grado del polinomio, es decir, $L_i(\mathbf{w}_{\text{ML},i}) \leq L_{i+1}(\mathbf{w}_{\\text{ML},i+1})$
☒ **Verdadero.**
☐ Falso.
- (b) La log-verosimilitud de entrenamiento del estimador MAP aumenta (o, al menos, no disminuye) con el grado del polinomio, es decir, $L_i(\mathbf{w}_{\text{MAP},i}) \leq L_{i+1}(\mathbf{w}_{\text{MAP},i+1})$
☐ Verdadero.
☒ **Falso.**
- (c) La log-verosimilitud de validación del estimador ML aumenta (o, al menos, no disminuye) con el grado del polinomio, es decir, $L'_i(\mathbf{w}_{\text{ML},i}) \leq L'_{i+1}(\mathbf{w}_{\text{ML},i+1})$
☐ Verdadero.
☒ **Falso.**
- (d) La densidad de probabilidad a posteriori del estimador MAP aumenta (o, al menos, no disminuye) con el grado del polinomio, es decir, $P_i(\mathbf{w}_{\text{MAP},i} | \mathcal{D}) \leq P_{i+1}(\mathbf{w}_{\text{MAP},i+1} | \mathcal{D})$
☐ Verdadero.
☒ **Falso.**

- (10 %) 4. Los datos de entrenamiento, $\mathcal{D} = \{(\mathbf{x}_k, y_k), 0 \leq k < K\}$ para un problema de clasificación son linealmente separables.

Considere estos tres clasificadores:

- Un clasificador 1-NN
- El clasificador lineal SVM para el caso separable.
- Un clasificador lineal basado en regresión logística y estimación MAP del vector de parámetros $\mathbf{w}$, suponiendo una distribución a priori $p(\mathbf{w})$ arbitraria.

Sean M_{1NN} , M_{SVM} y M_{RL} los márgenes respectivos de los clasificadores anteriores, definidos como la mínima distancia euclídea entre una muestra de entrenamiento y la frontera de clasificación

Se puede afirmar que:

- (a) $M_{\text{1NN}} \geq M_{\text{SVM}}$
☒ **Verdadero.**
☐ Falso.
- (b) $M_{\text{SVM}} \geq M_{\text{RL}}$
☒ **Verdadero.**

- ☐ Falso.
 (c) $M_{\text{INN}} \geq M_{\text{RL}}$
☒ **Verdadero.**
☐ Falso.
 (d) La tasa de error de entrenamiento de los tres clasificadores es 0.
☐ Verdadero.
☒ **Falso.**

(25 %) 5. Considere el conjunto de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, s_k), 0 \leq k < K\}$ para un problema de regresión. Se sabe que la función de verosimilitud se ajusta a una distribución log-normal de la forma

$$p(s|\mathbf{x}, \mathbf{w}) = \frac{1}{s\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{\log(s)}{\mathbf{w}^\top \mathbf{x}} \right)^2 \right], \quad s \geq 0$$

- (a) Determine el predictor MAP de s para una entrada $\mathbf{x}$, $\hat{s}_{\text{MAP}}$.
 (b) Determine una regla de aprendizaje mediante descenso por gradiente para aproximarse iterativamente al estimador de máxima verosimilitud de $\mathbf{w}$, $\hat{\mathbf{w}}_{\text{ML}}$
 (c) Comparando la función de verosimilitud de un vector de parámetros $\mathbf{w}$ con su opuesto $-\mathbf{w}$, discuta la unicidad del estimador de máxima verosimilitud.

Solution:

(a)

$$\begin{aligned}
 \hat{s}_{\text{MAP}} &= \underset{s}{\operatorname{argmax}} \log p(s|\mathbf{x}, \mathbf{w}) = \\
 &= \underset{s}{\operatorname{argmax}} \log \left(\frac{1}{s\sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{\log(s)}{\mathbf{w}^\top \mathbf{x}} \right)^2 \right) \right) \\
 &= \underset{s}{\operatorname{argmin}} \left(\log(s) + \frac{1}{2} \frac{(\log(s))^2}{(\mathbf{w}^\top \mathbf{x})^2} \right) \\
 &= \exp \left(-(\mathbf{w}^\top \mathbf{x})^2 \right)
 \end{aligned} \tag{2}$$

(b)

$$\begin{aligned}
 L(\mathbf{w}) &= \log \left(\prod_{k=0}^{K-1} \frac{1}{s^{(k)}\sqrt{2\pi}} \exp \left(-\frac{(\log(s^{(k)}))^2}{2(\mathbf{w}^\top \mathbf{x}^{(k)})^2} \right) \right) \\
 &= -\frac{K}{2} \log(2\pi) - \sum_{k=0}^{K-1} \log(s^{(k)}) - \sum_{k=0}^{K-1} \frac{(\log(s^{(k)}))^2}{2(\mathbf{w}^\top \mathbf{x}^{(k)})^2}
 \end{aligned} \tag{3}$$

thus


$$\nabla_{\mathbf{w}} L(\mathbf{w}) = \sum_{k=0}^{K-1} \frac{(\log(s^{(k)}))^2}{(\mathbf{w}^\top \mathbf{x}^{(k)})^3} \mathbf{x}^{(k)} \tag{4}$$

and

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \rho \cdot \sum_{k=0}^{K-1} \frac{(\log(s^{(k)}))^2}{(\mathbf{w}_n^\top \mathbf{x}^{(k)})^3} \mathbf{x}^{(k)} \tag{5}$$

- (c) El estimador ML no es único: dado que $p(s|\mathbf{x}, \mathbf{w}) = p(s|\mathbf{x}, -\mathbf{w})$, resulta $L(\mathbf{w}) = L(-\mathbf{w})$. Por tanto, si $\mathbf{w}_{\text{ML}}$ es un estimador ML, $-\mathbf{w}_{\text{ML}}$ también lo es.


- (25 %) 6. Considere el conjunto de datos de entrenamiento de la figura, para un problema de clasificación binaria.



- (a) Dibuje de forma aproximada la frontera de clasificación 1-NN.
- (b) Determine las decisiones del clasificador k -NN para una entrada $\mathbf{x} = (2.5, 3.5)^\top$, para todos los valores impares y positivos de k , con $k < 12$.
- (c) Determine la estimación de la probabilidad a posteriori de la clase 1, para entrada $\mathbf{x} = (2.5, 3.5)^\top$, de acuerdo con el algoritmo k -NN, para todos los valores impares de k , con $k < 12$.

Solution:

- (a) La frontera se muestra en la figura:



- (b) El clasificador k -NN asigna la muestra a la clase +1 para todos los valores impares de k .
- (c) Las estimaciones son

k	1	3	5	7	9	11
Prob	1	1	$\frac{4}{5}$	$\frac{4}{7}$	$\frac{5}{9}$	$\frac{7}{11}$