

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	7	Total
Points:	10	10	10	25	15	10	20	100
Score:								

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de K muestras de entrenamiento, $\mathcal{D} = \{(x_k, s_k), 0 \leq k < K - 1\}$ y otro de K' muestras de validación, $\mathcal{D}' = \{(x_k, s_k), K \leq k < K + K' - 1\}$, relativos a un problema de regresión unidimensional.

Se puede afirmar que:

- (a) Si no existen muestras de entrenamiento repetidas, i.e., $x_k \neq x'_k$, para cualesquiera $x_k, x'_k \in \mathcal{D}$, el MSE de entrenamiento de un regresor 1-NN es menor o igual que el que podría obtenerse con cualquier otro procedimiento de regresión.
☒ Verdadero. ☐ Falso.
- (b) Si no existen muestras de entrenamiento repetidas, i.e., $x_k \neq x'_k$, para cualesquiera $x_k, x'_k \in \mathcal{D}$, el MSE de validación de un regresor 1-NN es menor o igual que el que podría obtenerse para cualquier otro regresor K-NN (i.e., con un número de vecinos mayor que 1).
☐ Verdadero. ☒ Falso.
- (c) Considerando un modelo de regresión polinómica de mínimos cuadrados $\hat{s} = w_0 + w_1x + w_2x^2 + \dots + w_lx^l$, el MSE promediado sobre el conjunto de validación no puede crecer al aumentar el grado del polinomio, siempre que el grado del polinomio no supere el número de muestras del conjunto de validación.
☐ Verdadero. ☒ Falso.
- (d) La estimación bayesiana permite obtener una expresión analítica cerrada para la solución de máxima verosimilitud del vector de pesos, $\mathbf{w}_{ML}$, independientemente de la función de verosimilitud empleada, $p(s|\mathbf{w}, x)$.
☐ Verdadero. ☒ Falso.

- (10 %) 2. Considere la resolución de un problema de clasificación logística con función de log-verosimilitud negativa $NNL(\mathbf{w})$.

Se puede afirmar que:

- (a) El uso de gradiente estocástico garantiza convergencia a la solución de máxima verosimilitud con independencia de la existencia de máximos o mínimos locales en $NNL(\mathbf{w})$, siempre que el número de iteraciones empleado sea suficientemente elevado.
☐ Verdadero. ☒ Falso.
- (b) Si $NNL(\mathbf{w})$ es convexa, el algoritmo de Newton permite la convergencia al mínimo de dicha función de coste en un único paso (empleando paso de adaptación unitario).
☐ Verdadero. ☒ Falso.

- (c) Si asumimos una distribución a priori para el vector de pesos, $p(\mathbf{w})$, la solución de máximo a posteriori, $\mathbf{w}_{\text{MAP}}$, presenta además un mayor valor de la verosimilitud evaluada sobre el conjunto de datos de entrenamiento que la solución ML, $\mathbf{w}_{\text{ML}}$.

☐ Verdadero. ☒ **Falso.**

- (d) El método de Newton para minimización de $\text{NNL}(\mathbf{w})$ incurre en mayor coste computacional por iteración que los métodos de gradiente y de gradiente estocástico.

☒ **Verdadero.** ☐ Falso.

- (10 %) 3. Considere un problema de modelado de tópicos en el que se extraen un total de 100 tópicos sobre un corpus de 10000 documentos empleando LDA (*Latent Dirichlet Allocation*).

Se puede afirmar que

- (a) Cada tópico queda caracterizado por un vector β_k de longitud 10000 (igual al número de documentos del corpus)

☐ Verdadero. ☒ **Falso.**

- (b) Cada documento queda caracterizado por un vector θ_d de longitud 100 (igual al número de tópicos del modelo).

☒ **Verdadero.** ☐ Falso.

- (c) La suma de las componentes del vector anterior θ_d siempre es igual a 1.

☒ **Verdadero.** ☐ Falso.

- (d) El modelo generativo del LDA asume que todas las apariciones de una palabra del vocabulario han de ser generadas por un mismo tópico.

☐ Verdadero. ☒ **Falso.**

- (25 %) 4. Considere el conjunto de entrenamiento $\mathcal{D} = \{(x_k, s_k), 0 \leq k < K - 1\}$ para un problema de regresión. Se asume que la función de verosimilitud es

$$p(s|x, w) = \frac{1}{(wxs)^2} \exp \left[-\frac{1}{(wx)^2 s} \right], \quad s \geq 0$$

- (a) Determine el predictor MAP de s para una entrada $\mathbf{x}$, $\hat{s}_{\text{MAP}}$, supuesto conocido w .

- (b) Determine una regla de aprendizaje mediante descenso por gradiente para aproximar iterativamente al estimador de máxima verosimilitud de w , $\hat{w}_{\text{ML}}$

Solution:

(a)

$$\hat{s}_{\text{MAP}} = \arg \max_s \log p(s|x, w) = \arg \max_s \left[-2 \log(s) - \frac{1}{(wx)^2 s} \right]$$

$$\frac{\partial \log p(s|x, w)}{\partial s} = -\frac{2}{s} + \frac{1}{(wx)^2 s^2}$$

$$\hat{s}_{\text{MAP}} = \frac{1}{2(wx)^2}$$

(b)

$$\text{NLL}(w) = - \sum_{k=0}^{K-1} \log p(s_k|x_k, w) = \sum_{k=0}^{K-1} 2 \log(wx_k) + 2 \log s_k + \frac{1}{(wx_k)^2 s_k}$$

$$\frac{\partial \text{NLL}(w)}{\partial w} = \sum_{k=0}^{K-1} \frac{2}{w} - \frac{2x_k}{(wx_k)^3 s_k}$$

$$w(n+1) = w(n) + \rho(n) \frac{\partial \text{NLL}(w)}{\partial w} \Big|_{w=w(n)}$$

- (15 %) 5. Considere un conjunto de muestras unidimensionales $\{(x_k, y_k), i = 1, \dots, 8\}$ para la resolución de un problema de clasificación:

k	1	2	3	4	5	6	7	8
x_k	-13	-12	-5	-3	1	2	3	5
y_k	0	0	1	1	0	1	1	1

- (a) Represente las regiones de decisión de un clasificador 1-NN.
(b) Estime la probabilidad a posteriori de la clase 1 en $x = -0.25$ que proporcionaría un clasificador 3-NN.

Solution:

$$(a) \hat{y} = \begin{cases} 0, & x \in [-1, 0.5] \text{ or } x < -8.5 \\ 1 & x \in [-8.5, -1] \text{ or } x > 0.5 \end{cases}$$

$$(b) P_{H|x}(1 | -0.25) = \frac{2}{3}$$

- (10 %) 6. La consistencia de un clasificador es una propiedad asociada a su comportamiento conforme aumenta el número de muestras de entrenamiento. Proponga un ejemplo que ilustre que el clasificador 1-NN no es consistente. Justifique su respuesta comparando la tasa de error que en dicho ejemplo obtendría el clasificador de Bayes con la tasa de error del clasificador 1-NN conforme el número de muestras de entrenamiento tiende a infinito.
- (20 %) 7. (a) Explique cuáles son los pasos de un algoritmo de agrupamiento espectral.
(b) Ponga un ejemplo de un conjunto de datos en el que un algoritmo de agrupamiento espectral y un algoritmo tipo k -means proporcionan resultados cualitativamente diferentes.