

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	20	10	10	25	25	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10%) 1. Aplicando técnicas de procesamiento de textos, se han vectorizado los d documentos de un corpus, donde cada documento se ha caracterizado por un vector de frecuencias de palabras (tf) para un vocabulario de w palabras o tokens. De este modo, se ha obtenido una matriz $\mathbf{B}$, de dimensión $w \times d$.

A continuación, se han obtenido modelos de t tópicos ($t \ll w$) partiendo de $\mathbf{B}$ y aplicando los algoritmos LDA y LSI. Como resultado, se han obtenido, respectivamente, las matrices de tópicos $\mathbf{T}_{\text{LDA}}$ y $\mathbf{T}_{\text{LSI}}$, con dimensión $w \times t$, así como las correspondientes matrices de documentos $\mathbf{D}_{\text{LDA}}$ y $\mathbf{D}_{\text{LSI}}$, con dimensión $d \times t$.

Se puede afirmar que

- (a) Las componentes de $\mathbf{T}_{\text{LSI}}$ pueden tomar valores negativos.
☒ **Verdadero.**
☐ Falso.
- (b) Cada columna de $\mathbf{D}_{\text{LDA}}$ tiene componentes no negativas que suman 1.
☐ Verdadero.
☒ **Falso.**
- (c) $\mathbf{B} = \mathbf{T}_{\text{LDA}} \cdot \mathbf{D}_{\text{LDA}}^\top$
☐ Verdadero.
☒ **Falso.**
- (d) $\mathbf{B} = \mathbf{T}_{\text{LSI}} \cdot \mathbf{D}_{\text{LSI}}^\top$
☐ Verdadero.
☒ **Falso.**

- (20%) 2. Indique si las siguientes afirmaciones son verdaderas o falsas. Justifique su respuesta.

- (a) El algoritmo de agrupamiento K -medias converge siempre a la solución de mínima distorsión global.
- (b) Durante la ejecución del agrupamiento K -medias la distorsión global no puede crecer de forma puntual en alguna iteración.
- (c) Un criterio adecuado para elegir el valor de K (número de grupos) al aplicar el algoritmo K -medias es seleccionar el valor de K que permite alcanzar la mínima distorsión global medida sobre el conjunto de entrenamiento.
- (d) La aplicación de un algoritmo de clustering espectral requiere que las muestras estén ordenadas según el grupo al que pertenecen.

Puede utilizar un máximo de una cara para responder a las cuatro subpreguntas.

Solution:

- (a) Falso. El algoritmo converge cuando la asignación de muestras a centroides no cambia, pero eso no implica necesariamente que dicha solución sea la de mínima distorsión global. En general, la convergencia a una solución u otra depende de la inicialización. A modo de ejemplo, si en la aplicación de un 2-means con inicialización aleatoria los centroides caen de manera que uno de los dos centroides iniciales captura la totalidad de las muestras, la solución no cambia, pero existen otras soluciones mejores.
- (b) Verdadero. Los dos pasos de que consta el K-medias son óptimos para una asignación dada / para una posición determinada de los centroides. Puesto que ambos pasos garantizan que la distorsión global no crece, no puede hacerlo en ningún momento durante la aplicación del algoritmo.
- (c) Falso. Si se fija K igual al número de muestras de entrenamiento, se puede alcanzar distorsión global nula, pero situar un centroide sobre cada muestra no constituye una solución deseable del problema de agrupamiento.
- (d) Falso. Precisamente, el objetivo del problema de agrupamiento espectral consiste en encontrar “columnas similares” en la matriz de adyacencia, independientemente del orden en que estén dichas columnas. Asumir que las muestras ya están ordenadas según el grupo equivale a asumir que el problema de agrupamiento está resuelto de antemano.

- (10 %) 3. Se dispone de un conjunto de K muestras de entrenamiento, $\mathcal{D} = \{(\mathbf{x}_k, s_k), 0 \leq k < K\}$, relativos a un problema de regresión N -dimensional (es decir, $\mathbf{x}_k \in \mathbb{R}^N$). Se aplica el procedimiento habitual de normalización a los datos de entrada, de tal manera que todas las componentes de la entrada tengan media 0 y varianza unidad, resultando el conjunto de entrenamiento normalizado $\mathcal{D}' = \{(\mathbf{x}'_k, s_k), 0 \leq k < K\}$.

Se aplica el algoritmo de regresión k -NN sobre $\mathcal{D}$ y también sobre $\mathcal{D}'$.

Asimismo, considere los estimadores ML de los modelos de regresión lineal con ruido gaussiano, basados en los datos normalizados y sin normalizar, es decir

$$\mathbf{w}_{\text{ML}} = (\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{X}\mathbf{s}$$

$$\mathbf{w}'_{\text{ML}} = (\mathbf{X}'\mathbf{X}'^\top)^{-1}\mathbf{X}'\mathbf{s}$$

siendo $\mathbf{s} = (s_0, \dots, s_{K-1})$ y siendo $\mathbf{X}$ y $\mathbf{X}'$ las matrices de datos sin y con normalización, respectivamente, donde los datos están organizados por filas (es decir, $\mathbf{X} = (\mathbf{x}_0^\top, \dots, \mathbf{x}_{K-1}^\top)$, y lo mismo para $\mathbf{X}'$).

Se puede afirmar que:

- (a) $\mathbf{X}' \cdot \mathbf{1} = 0$, siendo $\mathbf{1}$ un vector columna de todo unos.
☒ Verdadero.
☐ Falso.
- (b) La normalización no afecta a las prestaciones del algoritmo k -NN, porque los k vecinos más próximos de una muestra son los mismos, independientemente de que se aplique la normalización o no.
☐ Verdadero.
☒ Falso.
- (c) $\mathbf{w}_{\text{ML}} = \mathbf{w}'_{\text{ML}}$
☐ Verdadero.
☒ Falso.
- (d) El error cuadrático total de entrenamiento de los modelos de regresión lineal no depende de que los datos estén normalizados o no, es decir

$$\sum_{k=0}^{K-1} (s_k - \mathbf{w}_{\text{ML}}^\top \mathbf{x}_k)^2 = \sum_{k=0}^{K-1} (s_k - \mathbf{w}'_{\text{ML}}^\top \mathbf{x}'_k)^2$$

- ☒ Verdadero.
☐ Falso.

- (10 %) 4. Considere un problema de clasificación con 5 clases, $y \in \{0, \dots, 4\}$. Para dicho problema, denotamos como $N_i, i \in \{0, \dots, 4\}$, el número de muestras de entrenamiento que pertenecen a cada clase. Denotaremos asimismo como $\mathbf{C}$ a la matriz de confusión asociada a un determinado clasificador, que contiene en su componente $c_{\ell k}$ (fila ℓ y columna k , con $\ell, k \in \{0, \dots, 4\}$) el **porcentaje** de muestras de entrenamiento de clase ℓ que dicho clasificador asigna a la clase k .

Se puede afirmar que:

- (a) El clasificador *baseline* que asigna cualquier muestra a la clase mayoritaria del conjunto de entrenamiento, tiene una tasa de acierto (medida sobre el conjunto de test) del 20%.
☐ Verdadero.
☒ Falso.

- (b) La matriz de confusión correspondiente al clasificador *baseline* tiene cuatro columnas con todos sus elementos nulos.

✓ **Verdadero.**

☐ Falso.

- (c) El promedio de los elementos de la diagonal de $\mathbf{C}$ es igual a la tasa de acierto del clasificador (medida sobre el conjunto de test)

☐ Verdadero.

✓ **Falso.**

- (d) Si se permutan las regiones de clasificación correspondientes a las clases 2 y 3, la nueva matriz de confusión se obtendría permutando las filas segunda y tercera de la matriz de confusión del clasificador de partida.

☐ Verdadero.

✓ **Falso.**

(25 %) 5. Considere el siguiente conjunto de entrenamiento para un problema de regresión:

$$\mathcal{D} = \{(x_k, y_k)\}_{k=0}^3 = \{(-3, -5), (-1, -2), (1, 6), (3, 9)\}$$

- (a) Obtenga y represente gráficamente la función de regresión asociada a un modelo 2-NN.

Considere para el resto del problema el siguiente modelo paramétrico para la generación de los datos

$$s_k = w_1 x_k + w_2 x_k^2 + \varepsilon_k,$$

en el que las muestras de ruido ε_k , $i = 0, \dots, 3$, son realizaciones independientes entre sí e independientes de los parámetros del modelo. Asumiendo además las distribuciones a priori $\mathbf{w} = [w_1, w_2]^\top \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ y $\varepsilon \sim \mathcal{N}(0, 2)$, calcule:

- (b) La solución de máxima verosimilitud, $\hat{\mathbf{w}}_{\text{ML}}$.

- (c) La solución de máxima a posteriori, $\hat{\mathbf{w}}_{\text{MAP}}$.

Solution:

(a)

$$\hat{y} = \begin{cases} -3, 5, & x \in [-\infty, -1] \\ 2, & x \in [-1, 1] \\ 7, 5, & x \in [1, \infty] \end{cases}$$

(b)

$$\hat{s}_{\text{ML}} = \mathbf{w}_{\text{ML}}^\top \begin{bmatrix} x \\ x^2 \end{bmatrix}$$

$$\mathbf{w}_{\text{ML}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{s}$$

donde se han definido las matrices

$$\mathbf{Z} = \begin{bmatrix} -3 & 9 \\ -1 & 1 \\ 1 & 1 \\ 3 & 9 \end{bmatrix} \quad \mathbf{s} = \begin{bmatrix} -5 \\ -2 \\ 6 \\ 9 \end{bmatrix}$$

La solución final es

$$\hat{s}_{\text{ML}} = \frac{5}{2}x + \frac{10}{41}x^2$$

(c)

$$\begin{aligned}\hat{s}_{\text{MAP}} &= \mathbf{w}_{\text{MAP}}^\top \begin{bmatrix} x \\ x^2 \end{bmatrix} \\ \mathbf{w}_{\text{MAP}} &= \frac{1}{2} \left(\frac{1}{2} \mathbf{Z}^\top \mathbf{Z} + \mathbf{I} \right)^{-1} \mathbf{Z}^\top \mathbf{s} \\ \hat{s}_{\text{MAP}} &= \frac{25}{11}x + \frac{4}{33}x^2\end{aligned}$$

- (25 %) 6. Considere el conjunto $\{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^N$. Las variables binarias $y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$P(y|\mathbf{x}, \mathbf{w}) = [\sin(\mathbf{w}^\top \mathbf{x})]^{2(1-y)} \cdot [\cos(\mathbf{w}^\top \mathbf{x})]^{2y}, \quad \mathbf{w} \in \mathbb{R}^N, \quad \mathbf{x} \in \mathbb{R}^N$$

- Suponiendo conocido $\mathbf{w}$, determine una regla de clasificación MAP para este modelo.
- Suponiendo dimensión $N = 2$ y $\mathbf{w} = [0, 2]^\top$, represente gráficamente de forma aproximada sobre $\mathbb{R}^2$ las regiones de decisión del decisor MAP.
- Determine una expresión para la log-verosimilitud negativa, $NLL(\mathbf{w})$.
- Determine una regla de aprendizaje de descenso por gradiente con paso de aprendizaje η para estimación del parámetro $\mathbf{w}$ de máxima verosimilitud.
- Sabiendo que la distribución a priori del vector de coeficientes tiene la forma

$$P_{\mathbf{w}}(\mathbf{w}) = \frac{1}{(2\pi)^{N/2}\sigma^N} \exp\left(-\frac{\|\mathbf{w}\|^2}{2\sigma^2}\right)$$

determine una regla de descenso por gradiente para estimación MAP de $\mathbf{w}$.

Solution:

- (a) El decisor MAP tiene la forma

$$P(1|\mathbf{x}, \mathbf{w}) \underset{D=0}{\overset{D=1}{\geq}} P(0|\mathbf{x}, \mathbf{w})$$

es decir

$$\cos^2(\mathbf{w}^\top \mathbf{x}) \underset{D=0}{\overset{D=1}{\geq}} \sin^2(\mathbf{w}^\top \mathbf{x})$$

- (b) Para $\mathbf{w} = [0, 2]^\top$, el clasificador para entrada $\mathbf{x} = [x_0, x_1]^\top$ tiene la forma

$$\cos^2(w_1 x_1) \underset{D=0}{\overset{D=1}{\geq}} \sin^2(w_1 x_1)$$

Por tanto se decidirá $D = 1$ siempre que $-\frac{\pi}{4} - n\pi \leq w_1 x_1 - n\pi \leq \frac{\pi}{4}$ para algún entero n . Es decir, las regiones de decisión son bandas horizontales de anchura $\frac{\pi}{2}$ centradas en los múltiplos de π .

(c)

$$\begin{aligned}
\text{NLL}(\mathbf{w}) &= \sum_{k=0}^{K-1} \log \left(\sin^{2(1-y_k)}(\mathbf{w}^\top \mathbf{x}_k) \cdot \cos^{2y_k}(\mathbf{w}^\top \mathbf{x}_k) \right) \\
&= \sum_{k=0}^{K-1} ((1-y_k) \log(\sin^2(\mathbf{w}^\top \mathbf{x}_k)) + y_k \log(\cos^2(\mathbf{w}^\top \mathbf{x}_k)))
\end{aligned}$$

(d) La regla de descenso por gradiente será

$$\begin{aligned}
\mathbf{w}_{n+1} &= \mathbf{w}_n - \eta \sum_{k=0}^{K-1} ((1-y_k) \nabla_{\mathbf{w}} \log(\sin^2(\mathbf{w}^\top \mathbf{x}_k)) + y_k \nabla_{\mathbf{w}} \log(\cos^2(\mathbf{w}^\top \mathbf{x}_k))) \\
&= \mathbf{w}_n - \eta \sum_{k=0}^{K-1} \left((1-y_k) \frac{2 \sin(\mathbf{w}^\top \mathbf{x}_k) \cos(\mathbf{w}^\top \mathbf{x}_k)}{\sin^2(\mathbf{w}^\top \mathbf{x}_k)} - y_k \frac{2 \sin(\mathbf{w}^\top \mathbf{x}_k) \cos(\mathbf{w}^\top \mathbf{x}_k)}{\cos^2(\mathbf{w}^\top \mathbf{x}_k)} \right) \mathbf{x}_k \\
&= \mathbf{w}_n - 2\eta \sum_{k=0}^{K-1} ((1-y_k) \cot(\mathbf{w}^\top \mathbf{x}_k) - y_k \tan(\mathbf{w}^\top \mathbf{x}_k)) \mathbf{x}_k
\end{aligned}$$

(e)

$$\begin{aligned}
\mathbf{w}_{n+1} &= \mathbf{w}_n - \eta (\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) - \log(p_{\mathbf{w}}(\mathbf{w})) \\
&= \left(1 - \frac{2\eta}{\sigma^2} \right) \mathbf{w}_n - 2\eta \sum_{k=0}^{K-1} ((1-y_k) \cot(\mathbf{w}^\top \mathbf{x}_k) - y_k \tan(\mathbf{w}^\top \mathbf{x}_k)) \mathbf{x}_k
\end{aligned}$$