

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de dos conjuntos de muestras de entrenamiento, $\mathcal{D}_a = \{(\mathbf{x}_k, s_k), 0 \leq k \leq 999\}$, $\mathcal{D}_b = \{(\mathbf{x}'_k, s'_k), 0 \leq k \leq 999\}$, relativos a un problema de regresión. Se sabe que cada dataset está formado por muestras i.i.d. (independientes e idénticamente distribuidas), siendo también ambos datasets estadísticamente independientes entre sí, y dados por modelos gaussianos

$$s_k = \mathbf{w}^\top \mathbf{x}_k + \epsilon_{a,k}, \quad 0 \leq k \leq 999$$

$$s'_k = \mathbf{w}^\top \mathbf{x}'_k + \epsilon_{b,k}, \quad 0 \leq k \leq 999$$

siendo ϵ_a y ϵ_b variables gaussianas de media cero y varianzas 0.1 y 0.01, respectivamente. Asimismo, $\mathbf{w}$ sigue una distribución a priori gaussiana.

Sea el dataset combinado, $\mathcal{D} = \mathcal{D}_a \cup \mathcal{D}_b$

Considere los estimadores de mínimo error cuadrático medio (MSE) de $\mathbf{w}$ utilizando $\mathcal{D}_a$, $\mathcal{D}_b$ ó $\mathcal{D}$.

Se puede afirmar que:

- (a) El dataset $\mathcal{D}$ está formado por muestras i.i.d.
☐ Verdadero.
☒ **Falso.**
- (b) El MSE del estimador basado en $\mathcal{D}_b$ será menor que el de aquél basado en $\mathcal{D}_a$
☒ **Verdadero.**
☐ Falso.
- (c) El MSE del estimador basado en $\mathcal{D}$ es menor que el de los estimadores basados en $\mathcal{D}_a$ o $\mathcal{D}_b$.
☒ **Verdadero.**
☐ Falso.
- (d) Se verifica la relación $\epsilon_{a,k} = 10 \cdot \epsilon_{b,k}$, para $0 \leq k \leq 999$.
☐ Verdadero.
☒ **Falso.**

- (10 %) 2. Para la resolución de un problema de clasificación binaria se decide entrenar una red neuronal del tipo perceptrón monocapa o multicapa.

Se puede afirmar que:

- (a) Si entrenamos una red monocapa con función de activación lineal la frontera obtenida es lineal.

✓ **Verdadero.**

☐ Falso.

- (b) Si entrenamos una red monocapa con función de activación softmax la frontera obtenida puede ser no lineal.

☐ Verdadero.

✓ **Falso.**

- (c) Para garantizar una adecuada generalización conviene aplicar una estrategia de “early stopping”, consistente en detener la actualización de los pesos cuando el valor de la función objetivo, evaluada sobre los datos de entrenamiento, alcanza un mínimo.

☐ Verdadero.

✓ **Falso.**

- (d) La inclusión de un término proporcional a $\|\mathbf{w}\|^2$ en la función objetivo no es viable puesto que impediría el cálculo de los gradientes.

☐ Verdadero.

✓ **Falso.**

(10 %) 3. Se puede afirmar que

- (a) El uso de la lematización como parte del preprocesado de textos aumenta el tamaño del vocabulario.

☐ Verdadero.

✓ **Falso.**

- (b) Cuanto mayor sea la longitud de un documento, mayor será la suma de las componentes de su vector TFIDF.

☐ Verdadero.

✓ **Falso.**

- (c) Considerando la resolución del algoritmo LDA mediante maximización de la verosimilitud del modelo, la verosimilitud de la solución óptima no puede disminuir al aumentar el número de tópicos del modelo.

✓ **Verdadero.**

☐ Falso.

- (d) Tras la aplicación del algoritmo LDA es posible calcular la representación de bolsa de palabras asociada a un documento concreto a partir del vector de tópicos de dicho documento y los vectores de tópicos asociados a sus tópicos no nulos.

☐ Verdadero.

✓ **Falso.**

- (25 %) 4. Considere el conjunto $\{(x_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $x_k \in \mathbb{R}$ y $s_k \in [0, 1]$. Para la resolución del problema de regresión unidimensional se asume el siguiente modelo paramétrico

$$p(s|x, w) = \exp(w \cdot x) s^{\exp(w \cdot x)-1}, \quad w, x \in \mathbb{R}, \quad s \in [0, 1]$$

- (a) Suponiendo conocido w , determine el estimador MMSE para este modelo, $\hat{s}_{\text{MMSE}}$.
 (b) Represente el valor del estimador obtenido como función de $w \cdot x$.
 (c) Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(w)$.
 (d) Determine una regla de aprendizaje de descenso por gradiente con paso de aprendizaje μ para estimación del parámetro w de máxima verosimilitud.

Solution: El problema puede extenderse de forma directa a multidimensional, reemplazando $w \cdot x$ por $\mathbf{w}^\top \mathbf{x}$. Lo he puesto en unidimensional para que el cálculo de las derivadas sea (ligeramente) más sencillo.

(a)

$$\hat{s}_{\text{MMSE}} = \int_0^1 s \cdot p(s|x, w) ds = \int_0^1 \exp(w \cdot x) s^{\exp(w \cdot x)-1} ds = \frac{\exp(w \cdot x)}{1 + \exp(w \cdot x)}$$

(b) Se trata de la función sigmoide.

(c)

$$\begin{aligned} \text{NLL}(w) &= - \sum_{k=0}^{K-1} \log p(s_k|x_k, w) \\ &= - \sum_{k=0}^{K-1} w \cdot x_k + [\exp(w \cdot x_k) - 1] \log s_k \end{aligned}$$

(d) Comenzamos calculando la derivada

$$\frac{d\text{NLL}(w)}{dw} = - \sum_{k=0}^{K-1} x_k + \exp(w \cdot x_k) x_k \log s_k = - \sum_{k=0}^{K-1} x_k [1 + \exp(w \cdot x_k) \log s_k]$$

Por lo que la regla de descenso por gradiente queda

$$w^{(n+1)} = w^{(n)} + \mu \sum_{k=0}^{K-1} x_k [1 + \exp(w \cdot x_k) \log s_k]$$

- (25 %) 5. Considere el conjunto $\{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, siendo $\mathbf{x}_k = (x_{k0}, x_{k1})^T$ observaciones bidimensionales. Las variables binarias $y_k \in \{0, 1\}$ se han generado de acuerdo con el modelo

$$\begin{aligned} p(y|\mathbf{x}, \mathbf{w}) &= \exp(-y\mathbf{w}^\top \mathbf{x}) \cdot (1 - (1 - y) \exp(-\mathbf{w}^\top \mathbf{x})), \\ w_0 &\geq 0, \quad w_1 \geq 0, \quad x_0 \geq 0, \quad x_1 \geq 0 \end{aligned}$$

Se desea determinar el estimador ML del vector de parámetros $\mathbf{w} = (w_0, w_1)^T$. Para ello, se minimiza la log-verosimilitud negativa

$$\text{NLL}(\mathbf{w}) = -\ln(p(y_0, \dots, y_{K-1}|\mathbf{x}_0, \dots, \mathbf{x}_{K-1}, \mathbf{w}))$$

- (a) Determine el gradiente de $\ln p(y|\mathbf{x}, \mathbf{w})$ respecto de $\mathbf{w}$
- (b) Determine la regla de descenso por gradiente con paso de aprendizaje η para minimización de $\text{NLL}(\mathbf{w})$
- (c) Sabiendo que la distribución a priori del vector de coeficientes es

$$p_{\mathbf{W}}(\mathbf{w}) = w_0 w_1 \exp(-w_0 - w_1) \quad w_0 \geq 0, w_1 \geq 0$$

determine una regla de descenso por gradiente estocástico para estimación MAP de los parámetros del modelo.

Solution:

- (a) Dado que

$$\ln p(y|\mathbf{x}, \mathbf{w}) = -y\mathbf{w}^T \mathbf{x} + \ln(1 - (1 - y) \exp(-\mathbf{w}^T \mathbf{x}))$$

resulta

$$\begin{aligned} \mathbf{g}(\mathbf{w}) &= -y\mathbf{x} + \frac{(1 - y) \exp(-\mathbf{w}^T \mathbf{x}) \mathbf{x}}{1 - (1 - y) \exp(-\mathbf{w}^T \mathbf{x})} \\ &= -\left(y - \frac{1 - y}{\exp(\mathbf{w}^T \mathbf{x}) - 1}\right) \mathbf{x} \\ &= -\frac{y - \exp(-\mathbf{w}^T \mathbf{x})}{1 - \exp(-\mathbf{w}^T \mathbf{x})} \mathbf{x} \end{aligned} \quad (1)$$

- (b)

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \eta \sum_{k=0}^{K-1} \frac{y_k - \exp(-\mathbf{w}_n^T \mathbf{x}_k)}{1 - \exp(-\mathbf{w}_n^T \mathbf{x}_k)} \mathbf{x}_k$$

- (c) El gradiente del logaritmo de la distribución a priori es

$$\begin{aligned} \nabla_{\mathbf{w}} (\ln p_{\mathbf{W}}(\mathbf{w})) &= \nabla_{\mathbf{w}} (\ln w_0 + \ln w_1 - w_0 - w_1) \\ &= \nabla_{\mathbf{w}} (\ln w_0 + \ln w_1 - w_0 - w_1) \\ &= \begin{pmatrix} \frac{1}{w_0} - 1 \\ \frac{1}{w_1} - 1 \end{pmatrix} \end{aligned} \quad (2)$$

y teniendo en cuenta que debe minimizarse

$$\sum_{k=0}^{K-1} \left(-\ln p(y_k|\mathbf{x}_k, \mathbf{w}) - \frac{1}{K} \ln p(\mathbf{w}) \right) \quad (3)$$

la regla de gradiente estocástico será

$$\mathbf{w}_{n+1} = \mathbf{w}_n - \frac{\eta}{K} \begin{pmatrix} \frac{1}{w_{0,n}} - 1 \\ \frac{1}{w_{1,n}} - 1 \end{pmatrix} - \eta \frac{y_n - \exp(-\mathbf{w}_n^T \mathbf{x}_n)}{1 - \exp(-\mathbf{w}_n^T \mathbf{x}_n)} \mathbf{x}_n$$

- (20 %) 6. (a) Explique la secuencia de pasos de un algoritmo de extracción de las m componentes principales del conjunto de observaciones N -dimensionales, $\mathcal{D} = \{\mathbf{x}_k, k = 0, \dots, K-1\}$, con $m < K$.
- (b) Sea $\mathbf{v}_k$ el vector de las m componentes principales de la muestra $\mathbf{x}_k$, y considere el conjunto de datos $\mathcal{D}' = \{\mathbf{x}'_k, k = 0, \dots, K-1\}$, con $m < K$, siendo $\mathbf{x}'_k = 10\mathbf{x}_k$, para todo k . Se

aplica un análisis PCA sobre $\mathcal{D}'$, resultando las componentes principales $\mathbf{v}'_k$. ¿Qué relación existe entre $\mathbf{v}_k$ y $\mathbf{v}'_k$? Justifique la respuesta.

Solution:

- (a)
1. Arrange data into matrix $\mathbf{X}$.
 2. Compute the m unitary eigenvectors $\mathbf{w}_0, \mathbf{w}_1, \dots, \mathbf{w}_{l-1}$ from matrix $\mathbf{X}^\top \mathbf{X}$ with the m largest eigenvalues.
 3. Arrange the eigenvectors columnwise into an $N \times m$ weight matrix

$$\mathbf{W} = (\mathbf{w}_0 | \mathbf{w}_1 | \dots | \mathbf{w}_{m-1})$$

4. Compute the principal components for all samples in data matrix $\mathbf{X}$ as $\mathbf{T} = \mathbf{X}\mathbf{W}$
- (b) $\mathbf{v}'_k = 10\mathbf{v}_k$. Esto es debido a que los autovectores unitarios de $\mathbf{X}^\top \mathbf{X}$ coinciden con los de $\mathbf{X}'^\top \mathbf{X}' = 100\mathbf{X}^\top \mathbf{X}$, y por tanto las direcciones principales no cambian (es decir, la matriz de transformación $\mathbf{T}$ es la misma).