

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Para la resolución de un problema de regresión se decide entrenar una red neuronal del tipo perceptrón monocapa o multicapa, utilizando el error cuadrático promedio como criterio de diseño.

Se puede afirmar que:

- (a) Si entrenamos una red monocapa con función de activación lineal existe una expresión cerrada que puede utilizarse para el cálculo del vector de pesos, sin necesidad de aplicar ningún procedimiento basado en gradiente.
☒ **Verdadero.**
☐ Falso.
- (b) El único procedimiento que permite evitar el sobreajuste de la red es utilizar un número de capas ocultas razonablemente pequeño.
☐ Verdadero.
☒ **Falso.**
- (c) Si aplicamos optimización mediante descenso por gradiente estocástico, el peso de adaptación afecta a la velocidad de convergencia de la red, pero no a la precisión final de la misma.
☐ Verdadero.
☒ **Falso.**
- (d) Si añadimos un término de regularización a la función objetivo, el error cuadrático de la red, medido sobre el conjunto de entrenamiento, será en general mayor que en ausencia de regularización.
☒ **Verdadero.**
☐ Falso.

- (10 %) 2. Se dispone de un conjunto de entrenamiento de 1000 muestras para ajustar un clasificador binario. Indique cuáles de los siguientes clasificadores pueden dar lugar a fronteras de clasificación no lineales (es decir, distintas a un hiperplano).

- (a) Un clasificador 1-NN.
☒ **Verdadero.**
☐ Falso.
- (b) Un clasificador basado en un modelo de regresión logística $p(1|\mathbf{x}) = \phi(\mathbf{w}^T \mathbf{x})$ (siendo ϕ la función logística).

☐ Verdadero.

✓ **Falso.**

- (c) Un perceptron simple (single-layer perceptron) formado por una sola neurona, con una función de activación logística, y con entrada $\mathbf{x}$.

☐ Verdadero.

✓ **Falso.**

- (d) Una perceptron multicapa con una capa oculta de dos neuronas y función de activación logística.

✓ **Verdadero.**

☐ Falso.

- (10%) 3. Sea $\mathbf{X}$ la matriz correspondiente al conjunto de datos $\mathcal{D} = \{\mathbf{x}_k, k = 0, \dots, K-1\}$, de dimensión 100, donde las muestras están organizadas por filas, de tal modo que la fila k -ésima de $\mathbf{X}$ contiene $\mathbf{x}_k^T$. Los datos ya están normalizados mediante un escalado estándar, de modo que tienen media nula. Se aplica sobre $\mathbf{X}$ un análisis por componentes principales (PCA), para obtener las 10 componentes principales. Para ello, se obtienen los 10 autovectores principales de $\mathbf{X}^T \mathbf{X}$, $\mathbf{w}_0, \dots, \mathbf{w}_9$, que se organizan por columnas en la matriz $\mathbf{W} = (\mathbf{w}_0 | \mathbf{w}_1 | \dots | \mathbf{w}_9)$, que permite obtener la nueva matriz de datos $\mathbf{T} = \mathbf{XW}$ y, por tanto, el conjunto de datos transformado $\mathcal{D}' = \{\mathbf{t}_k, k = 0, \dots, K-1\}$

Se puede afirmar que

- (a) Los vectores $\mathbf{w}_0, \dots, \mathbf{w}_9$ son ortogonales entre sí

✓ **Verdadero.**

☐ Falso.

- (b) Los datos en $\mathcal{D}'$ son ortogonales entre sí.

☐ Verdadero.

✓ **Falso.**

- (c) Los datos en $\mathcal{D}'$ también tienen media nula.

✓ **Verdadero.**

☐ Falso.

- (d) Todas las componentes de los datos en $\mathcal{D}'$ también tienen varianza unidad.

☐ Verdadero.

✓ **Falso.**

(25 %) 4. Considere el modelo paramétrico dado por

$$s_k = w_0\sqrt{x_k} + w_1(x_k - 4) + \varepsilon_k,$$

en el que las muestras de ruido ε_k , $i = 0, \dots, 3$, son gaussianas de media nula y varianza 2, independientes entre sí e independientes de los parámetros del modelo.

El vector de parámetros $\mathbf{w} = (w_1, w_2)^\top$ es desconocido, pero se sabe que su distribución a priori es $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \frac{1}{5}\mathbf{I})$.

Para estimar $\mathbf{w}$, se dispone solamente de un conjunto de tres muestras de entrenamiento

$$\mathcal{D} = \{(x_k, s_k), k = 0, \dots, 2\} = \{(0, 1), (1, 0), (9, 1)\}$$

- (a) Determine $\mathbb{E}\{s^2\}$ para una observación $x = 4$.
- (b) Determine la matriz de varianzas de la distribución a posteriori de $\mathbf{w}$ dados los datos.
- (c) Determine el estimador de mínimo error cuadrático medio de $\mathbf{w}$, $\mathbf{w}_{\text{MSE}}$.
- (d) Determine la predicción de mínimo error cuadrático medio $\hat{s}_{\text{MSE}}$ para una observación $x = 4$
- (e) Determine $\mathbb{E}\{s^2|\mathcal{D}\}$ para una observación $x = 4$.

Solution:

(a)

$$s = w_0\sqrt{x} + w_1(x - 4) + \varepsilon = 2w_0 + \varepsilon$$

por tanto, dado que $\mathbf{w}_0$ y el ruido son independientes,

$$\mathbb{E}\{s^2\} = 4\mathbb{E}\{w_0^2\} + \sigma_\varepsilon^2$$

y, teniendo en cuenta la distribución a priori de $\mathbf{w}$, resulta

$$\mathbb{E}\{s^2\} = \frac{4}{5} + 2 = 2.8$$

(b)

$$\mathbf{V}_{\mathbf{w}} = \left(\frac{1}{\sigma_\varepsilon^2} \mathbf{Z}^\top \mathbf{Z} + \mathbf{V}_p^{-1} \right)^{-1}$$

siendo

$$\mathbf{Z} = \begin{pmatrix} 0 & -4 \\ 1 & -3 \\ 3 & 5 \end{pmatrix}$$

de modo que

$$\begin{aligned} \mathbf{V}_{\mathbf{w}} &= \left(\frac{1}{2} \begin{pmatrix} 10 & 12 \\ 12 & 50 \end{pmatrix} + 5\mathbf{I} \right)^{-1} \\ &= \begin{pmatrix} 10 & 6 \\ 6 & 30 \end{pmatrix}^{-1} = \frac{1}{264} \begin{pmatrix} 30 & -6 \\ -6 & 10 \end{pmatrix} \\ &= \frac{1}{132} \begin{pmatrix} 15 & -2 \\ -2 & 5 \end{pmatrix} \end{aligned}$$

(1)

(c)

$$\mathbf{w}_{\text{MSE}} = \frac{1}{\sigma_\varepsilon^2} \mathbf{V}_w \mathbf{Z}^\top \mathbf{s}$$

siendo

$$\mathbf{s} = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

de modo que

$$\begin{aligned} \mathbf{w}_{\text{MSE}} &= \frac{1}{2} \frac{1}{142} \begin{pmatrix} 30 & -4 \\ -4 & 10 \end{pmatrix} \begin{pmatrix} 0 & -4 \\ 1 & -3 \\ 3 & 5 \end{pmatrix}^\top \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \\ &= \frac{1}{284} \begin{pmatrix} 15 & -2 \\ -2 & 5 \end{pmatrix} \begin{pmatrix} 3 \\ 1 \end{pmatrix} \\ &= \frac{1}{284} \begin{pmatrix} 43 \\ -1 \end{pmatrix} \end{aligned} \quad (2)$$

(d)

$$\hat{s}_{\text{MSE}} = \mathbf{w}_{\text{MSE}}^\top \begin{pmatrix} \sqrt{x} \\ x - 4 \end{pmatrix} = \frac{43}{284} \sqrt{x} - \frac{1}{284} (x - 4)$$

(e) En este caso:

$$\mathbb{E}\{s^2|\mathcal{D}\} = 4\mathbb{E}\{w_0^2|\mathcal{D}\} + \sigma_\varepsilon^2 = 4(\text{var}\{w_0|\mathcal{D}\} + \mathbb{E}\{w_0|\mathcal{D}\}^2) + \sigma_\varepsilon^2 \quad (3)$$

y, teniendo en cuenta las expresiones de la media y la varianza a posteriori obtenidas en los apartados anteriores, resulta

$$\mathbb{E}\{s^2|\mathcal{D}\} = 4 \left(\frac{15}{142} + \frac{43^2}{284^2} \right) + 2 \quad (4)$$

(25 %) 5. (a) Demuestre la siguiente propiedad de la derivada de la función logística $g(t) = \text{logistic}(t)$:

$$g'(t) = g(t) \cdot [1 - g(t)].$$

- (b) Justifique el uso de la función logística para la activación de la capa de salida de una red neuronal para la resolución de un problema de clasificación binaria.
- (c) Explique cómo modificaría la función de activación de la capa de salida de la red neuronal para un problema multiclase, de manera que las salidas de la red puedan interpretarse como las probabilidades de pertenencia a cada una de las clases.
- (d) Represente de forma gráfica una red neuronal para la resolución de un problema de clasificación con tres clases, con los siguientes datos sobre su topología: *i*) una única capa oculta con 4 neuronas, y *ii*) patrones de entrada de 2 dimensiones. Si necesita alguna información adicional, tome las decisiones que estime oportuno indicándolo en su respuesta.
- (e) Proponga una función objetivo para la optimización de la red anterior.

(20 %) 6. Se desea comprimir una imagen de 1024×1024 píxeles, y tres canales (RGB) de 8 bits de resolución (i.e., valores 0-255). Para ello, se decide aplicar cuantificación vectorial, de manera que se seleccionan 64 centroides y cada píxel se representa utilizando el centroide más cercano. Responda a las siguientes cuestiones utilizando un máximo de una cara. Debe justificar todas sus respuestas.

- (a) Calcule el número de bits utilizado para representar la imagen original y la imagen comprimida.
- (b) Explique cómo seleccionaría los centroides aplicando un algoritmo de clustering K-medias. Indique de manera explícita cómo formaría la matriz de datos para la aplicación del algoritmo.
- (c) Enumere de forma concisa los dos pasos de que consta el algoritmo K-medias.
- (d) Si se necesita comprimir 100 imágenes, justifique las ventajas e inconvenientes que tendría emplear los centroides obtenidos para la imagen original *vs* calcular nuevos centroides para cada imagen a comprimir. ¿Cuál de las dos estrategias aconsejaría?

Solution: TBD
