

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	20	25	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10%) 1. Se dispone de un conjunto de muestras de entrenamiento, $\mathcal{D} = \{(x_n, s_n), 0 \leq n \leq 999\}$, relativo a un problema de regresión unidimensional ($x_n \in \mathbb{R}$). Sea $f_k(\mathbf{x})$ la función de regresión resultante de aplicar el algoritmo k -NN sobre estos datos. Suponga que todas las muestras de entrada son distintas, es decir, $x_n \neq x_m$, para todo $n \neq m$

Se puede afirmar que:

- (a) $f_1(x)$ es una función constante por intervalos.

☒ **Verdadero.**☐ Falso.

- (b) $f_k(x)$ es constante por intervalos, para $k = 2, 3, \dots, 999$.

☒ **Verdadero.**☐ Falso.

- (c) $f_{1000}(x)$ es constante

☒ **Verdadero.**☐ Falso.

- (d) El error cuadrático promedio, calculado sobre los datos de entrenamiento, decrece al aumentar k .

☐ Verdadero.☒ **Falso.**

(10 %) 2. Se puede afirmar que:

- (a) La función de activación softmax ($\mathbf{y} = \text{softmax}(\mathbf{x})$) proporciona salidas probabilísticas ($y_i \in [0, 1]$, así como $\sum_i y_i = 1$) cualquiera que sea el valor de la entrada, $\mathbf{x}$.

✓ Verdadero.

☐ Falso.

- (b) Para entrenar un perceptrón multicapa mediante algoritmos de gradiente, todas las neuronas de las capas ocultas deben tener la misma función de activación.

☐ Verdadero.

✓ Falso.

- (c) Aumentar el número de capas de un perceptrón multicapa para clasificación reduce necesariamente la tasa de error de test

☐ Verdadero.

✓ Falso.

- (d) El cálculo de la probabilidad a posteriori de una clase, de acuerdo con un modelo de regresión logística (es decir, $P(y|\mathbf{w}, \mathbf{x}) = (1 + \exp(-y\mathbf{w}^\top \mathbf{x}))^{-1}$) se puede implementar en una red neuronal de una sola capa y una sola neurona, con función de activación logística.

✓ Verdadero.

☐ Falso.

(10 %) 3. Se desea aplicar el algoritmo PCA para reducir la dimensionalidad de la representación de las muestras de entrada a un algoritmo de aprendizaje automático. Las muestras sobre las que se quiere aplicar PCA, $\{\mathbf{x}_k, 0 \leq k \leq 99\}$, han sido previamente centradas y se disponen por filas en una matriz $\mathbf{X}$. Los autovectores extraídos por el algoritmo PCA se denotan como $\mathbf{w}_\ell$, con $\ell = 0$ para la primera componente, $\ell = 1$ para la segunda, y así sucesivamente.

Se puede afirmar que

- (a) $\mathbf{w}_\ell^\top \mathbf{X}^\top \mathbf{X} \mathbf{w}_{\ell'} = 1$ para todos ℓ, ℓ' .

☐ Verdadero.

✓ Falso.

- (b) $\mathbf{w}_\ell^\top \mathbf{X}^\top \mathbf{X} \mathbf{w}_\ell$ no puede crecer al aumentar el valor de ℓ .

✓ Verdadero.

☐ Falso.

- (c) Si se sabe que las $\mathbf{x}_k$ tienen dimensión 4, y que la última componente de cada muestra se obtiene como suma de las tres primeras, seleccione el mínimo valor de ℓ para el que se puede afirmar que $\mathbf{w}_\ell^\top \mathbf{X}^\top \mathbf{X} \mathbf{w}_\ell = 0$ (recuerde que la primera componente se obtiene para $\ell = 0$).

☐ 2

✓ 3

☐ 4

☐ 100

- (d) Si se sabe que las $\mathbf{x}_k$ tienen dimensión 4 y que todas las componentes de la matriz $\mathbf{X}$ se toman de manera independiente de una distribución $\mathcal{N}(0, 1)$, seleccione el mínimo valor de ℓ para el que se puede afirmar que $\mathbf{w}_\ell^\top \mathbf{X}^\top \mathbf{X} \mathbf{w}_\ell = 0$.

☐ 2

☐ 3

✓ 4

☐ 100

- (25 %) 4. Considere el conjunto $\{(\mathbf{x}_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^2$ y $s_k \in [0, 1]$. Para la resolución del problema de regresión unidimensional se asume el siguiente modelo paramétrico

$$p(s|\mathbf{x}, \mathbf{w}) = \exp(\mathbf{w}^\top \mathbf{x}) s^{\exp(\mathbf{w}^\top \mathbf{x})-1}, \quad w, x \in \mathbb{R}^2, \quad s \in [0, 1]$$

- (a) Suponiendo conocido $\mathbf{w}$, determine el estimador MAP para este modelo, $\hat{s}_{\text{MAP}}$.
 (b) Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(\mathbf{w})$.
 (c) Calcule la regla de gradiente estocástico que permite aproximar la solución ML.
 (d) Determine el valor $\hat{\mathbf{w}}_{\text{MAP}}$, asumiendo que la distribución a priori de $\mathbf{w}$ es

$$P(\mathbf{w}) = \begin{cases} q, & \text{si } \mathbf{w} = [1, 0]^\top \\ 1 - q, & \text{si } \mathbf{w} = [0, 1]^\top \end{cases}$$

con $0 \leq q \leq 1$.

Solution:

- (a) $p(s|\mathbf{x}, \mathbf{w})$ será una función creciente en s cuando el exponente de s sea positivo, y decreciente en caso contrario. Teniendo en cuenta que $s \in [0, 1]$, se tiene que

$$\hat{s}_{\text{MAP}} = \begin{cases} 1, & \text{si } \mathbf{w}^\top \mathbf{x} > 0 \\ 0, & \text{si } \mathbf{w}^\top \mathbf{x} < 0 \end{cases}$$

Para $\mathbf{w}^\top \mathbf{x} = 0$ el estimador MAP será cualquier valor del intervalo.

- (b)

$$\begin{aligned} \text{NLL}(\mathbf{w}) &= - \sum_{k=0}^{K-1} \log p(s_k|\mathbf{x}_k, \mathbf{w}) \\ &= - \sum_{k=0}^{K-1} \mathbf{w}^\top \mathbf{x}_k + [\exp(\mathbf{w}^\top \mathbf{x}_k) - 1] \log s_k \end{aligned}$$

- (c) Comenzamos calculando el gradiente

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = - \sum_{k=0}^{K-1} \mathbf{x}_k + \exp(\mathbf{w}^\top \mathbf{x}_k) \mathbf{x}_k \log s_k = - \sum_{k=0}^{K-1} \mathbf{x}_k [1 + \exp(\mathbf{w}^\top \mathbf{x}_k) \log s_k]$$

Por lo que la regla de descenso por gradiente queda

$$\mathbf{w}^{(n+1)} = \mathbf{w}^{(n)} + \mu \sum_{k=0}^{K-1} \mathbf{x}_k [1 + \exp(\mathbf{w}^{(n)\top} \mathbf{x}_k) \log s_k]$$


- (d) En este caso, $\hat{\mathbf{w}}_{\text{MAP}}$ únicamente puede tomar los dos valores permitidos por el prior, por lo que el criterio MAP puede expresarse como

$$\begin{aligned} \hat{\mathbf{w}}_{\text{MAP}} &= [0, 1]^\top \\ \text{NLL}([1, 0]^\top) - \log q &\geq \text{NLL}([0, 1]^\top) - \log(1 - q) \\ \hat{\mathbf{w}}_{\text{MAP}} &= [1, 0]^\top \\ - \sum_{k=0}^{K-1} x_{k0} + [\exp(x_{k0}) - 1] \log s_k - \log q &\geq - \sum_{k=0}^{K-1} x_{k1} + [\exp(x_{k1}) - 1] \log s_k - \log(1 - q) \\ \hat{\mathbf{w}}_{\text{MAP}} &\geq [0, 1]^\top \\ \hat{\mathbf{w}}_{\text{MAP}} &= [1, 0]^\top \end{aligned}$$

- (20 %) 5. (a) Explique brevemente qué parámetros libres (hiperparámetros) tiene el algoritmo LDA, y su significado.
- (b) Explique brevemente qué resultado produce el algoritmo LDA; indicando qué dimensiones tienen las matrices de salida del algoritmo.
- (c) Suponga que se ha aplicado el algoritmo LDA sobre un corpus de 10000 documentos para obtener una representación en un espacio de 5 tópicos. Explique brevemente cómo utilizaría el modelo generativo del LDA para generar, de forma sintética, un documento artificial de 100 tokens del tópico 0.
- (d) Explique brevemente cómo utilizaría el modelo generativo del apartado anterior LDA para generar, de forma sintética, un documento artificial de 100 tokens, cuyo vector de tópicos es $(0.2, 0.8, 0, 0, 0)$.

Solution: TBD

- (25 %) 6. Considere el conjunto de 20 muestras de entrenamiento de la figura, para un problema de clasificación binaria.



- Determine la decisión de los clasificador k -NN para una entrada $\mathbf{x} = (4, 3)^\top$, para todos los valores impares y positivos de k , con $k \leq 9$.
- Determine la estimación de la probabilidad a posteriori de la clase 1, para entrada $\mathbf{x} = (4, 3)^\top$, de acuerdo con el algoritmo k -NN, para todos los valores impares de k , con $k \leq 9$.
- Determine la tasa de error de validación que resulta de aplicar validación cruzada por Leave-One-Out (LOO) sobre estos datos, al emplear el clasificador 1-NN.
- Considere el clasificador dado por el modelo de regresión logística

$$P(1|\mathbf{x}, \mathbf{w}) = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{z})}$$

siendo $\mathbf{z} = (x_0, x_1, 1)^\top$. Determine el número de errores del clasificador dado por $\mathbf{w} = (2, 0, -9)^\top$, calculados sobre el conjunto de entrenamiento.

Solution:

(a)

k	1	3	5	7	9
$\hat{y}$	0	0	1	0	1

(b)

k	1	3	5	7	9
Prob	0	$\frac{1}{3}$	$\frac{3}{5}$	$\frac{3}{7}$	$\frac{5}{9}$

- Dado que 7 muestras tienen su vecino más próximo de la otra categoría, la tasa de error de validación LOO es $\frac{7}{20}$.
- El clasificador decide 1 cuando $\mathbf{w}^\top \mathbf{z} > 0$, es decir, $2x_0 - 9 > 0$ o, equivalentemente, $x_0 > 4.5$. Observando la figura se comprueba que dicho clasificador clasifica 3 muestras erróneamente, luego la tasa de error es de $\frac{3}{20} = 0.15$