

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de datos de entrenamiento para la resolución de un problema de regresión unidimensional, $\mathcal{D} = \{(x_k, s_k), k = 1, \dots, K\}$, con $s \in \mathbb{R}$ y $x \in \mathbb{R}$.

La estimación de S a partir de X se realiza por máxima verosimilitud considerando para ello dos modelos alternativos:

$$\text{Modelo 1: } p(s|w, x) = \frac{1}{\sqrt{2\pi}\sigma_\epsilon} \exp\left(-\frac{(s-w)^2}{2\sigma_\epsilon^2}\right)$$

$$\text{Modelo 2: } p(s|w, x) = \frac{1}{\sqrt{2\pi}\sigma_\epsilon} \exp\left(-\frac{(s-w \cdot x)^2}{2\sigma_\epsilon^2}\right)$$

donde σ_ϵ , es una constante conocida.

Se puede afirmar que:

- (a) $\hat{s}_{\text{MSE}}(x)$ es independiente de x para cualquiera de los dos modelos.

☐ Verdadero.

✓ **Falso.**

- (b) Para el modelo 1, $\hat{w}_{\text{ML}} = \frac{1}{K} \sum_k s_k$

✓ **Verdadero.**

☐ Falso.

- (c) Para el modelo 2, $\hat{w}_{\text{ML}} = \frac{1}{K} \sum_k s_k \cdot x_k$

☐ Verdadero.


✓ **Falso.**

- (d) El estimador ML asociado al modelo 2 incurre en un menor error cuadrático medio, medido sobre el conjunto de entrenamiento, que el estimador ML asociado al modelo 1.

☐ Verdadero.

✓ **Falso.**

- (10%) 2. Considere el problema de clasificación binario con datos bidimensionales, con el conjunto de 12 muestras de entrenamiento que se muestra en la figura



Se puede afirmar que:

- (a) El clasificador 1-NN tiene cero errores de entrenamiento
 - ☒ **Verdadero.**
 - ☐ Falso.
- (b) El clasificador 3-NN tiene cero errores de entrenamiento
 - ☐ Verdadero.
 - ☒ **Falso.**
- (c) El clasificador 12-NN tiene cero errores de entrenamiento
 - ☐ Verdadero.
 - ☒ **Falso.**
- (d) Aplicando validación cruzada por Leave-One-Out (LOO) sobre este dataset, la tasa de errores de validación del 1-NN es $1/6$
 - ☒ **Verdadero.**
 - ☐ Falso.

- (10 %) 3. Un corpus contiene documentos que hablan de atletismo, ajedrez y fútbol. El vocabulario asociado a dicho corpus está dado por $\mathcal{D} = \{\text{pértiga, jabalina, salto, alfil, torre, jaque, gol, balón, penalty, ganar, perder}\}$. Considere el modelo de tres tópicos dado por la siguiente matriz de tópicos:

$$\mathbf{T} = \begin{pmatrix} 0.3 & 0.3 & 0.3 & 0 & 0 & 0 & 0 & 0 & 0 & 0.05 & 0.05 \\ 0 & 0 & 0 & 0.3 & 0.3 & 0.3 & 0 & 0 & 0 & 0.05 & 0.05 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.3 & 0.3 & 0.3 & 0.05 & 0.05 \end{pmatrix}^T \quad (1)$$

Se puede afirmar que

- (a) De acuerdo con este modelo, un documento del corpus puede tratar sobre atletismo, ajedrez o fútbol, pero no de varios deportes a la vez.
☐ Verdadero.
☒ **Falso.**
- (b) Cabe esperar que un documento de pesos $(0, 0.8, 0.2)$ hable más de ajedrez que de atletismo.
☒ **Verdadero.**
☐ Falso.
- (c) De acuerdo con el modelo generativo de documentos del algoritmo LDA, la distribución de tokens del vocabulario asociada al documento de pesos $(2/3, 1/3, 0)$ está dada por el vector de probabilidades

$$\mathbf{p} = (0.2 \quad 0.2 \quad 0.2 \quad 0.1 \quad 0.1 \quad 0.1 \quad 0 \quad 0 \quad 0 \quad 0.05 \quad 0.05)^T \quad (2)$$

- ☒ **Verdadero.**
☐ Falso.
- (d) Todos los documentos del corpus contienen los tokens “ganar” y “perder”.
☐ Verdadero.
☒ **Falso.**

- (25 %) 4. Se pretende resolver un problema de clasificación binaria para el que se dispone de un conjunto de N muestras de entrenamiento, $\mathcal{D} = \{(\mathbf{x}_n, y_n), n = 0, \dots, N-1\}$. Las entradas $\mathbf{x}_n$ tienen dimensión D . Para ello se consideran las siguientes alternativas:

- Una implementación básica del clasificador k -NN, optimizando el parámetro k para todos los valores en el rango $1 \leq k \leq 100$ mediante validación cruzada (10-fold).
- Un modelo de regresión logística, con transformación polinómica, incluyendo todos (y solamente) los términos polinómicos de grado 1 y 2 (esto es, $x_0, x_1, \dots, x_{D-1}, x_0^2, x_0x_1, x_0x_2, \dots$), entrenado con la regla de aprendizaje por gradiente estocástico para estimación de máxima verosimilitud, durante un sólo ciclo de entrenamiento (es decir, aplicando la regla de aprendizaje una sola vez por muestra de entrenamiento), y con un valor prefijado del paso de aprendizaje (learning step).

Discuta las ventajas e inconvenientes de ambas alternativas desde el punto de vista de la carga computacional. Para ello, determine, de forma aproximada, el número de multiplicaciones requerido para

- (a) Clasificar una entrada arbitraria, $\mathbf{x}$, tras el entrenamiento, mediante regresión logística.
 (b) Clasificar una entrada arbitraria, $\mathbf{x}$, mediante k -NN, para un valor arbitrario de k .
 (c) Ajustar el modelo de regresión logística con los datos de entrenamiento.
 (d) Ajustar el hiperparámetro k , del k -NN.

No es necesario realizar un cálculo exacto. Principalmente, se debe determinar cómo depende la carga computacional, en cada caso, de la dimensión D y del tamaño del dataset, N :

Solution:

- (a) Dado que la transformación polinómica extiende las D variables de entrada con $\frac{1}{2}D(D+1)$ términos de grado 2, la entrada transformada tiene dimensión $\frac{1}{2}D(D+3)$. Por tanto, se requieren:

- Para calcular la transformación polinómica: $\frac{1}{2}D(D+1)$ multiplicaciones.
- Para multiplicar por los pesos del modelo: $\frac{1}{2}D(D+3)$ multiplicaciones

Por tanto, se requieren $D(D+2)$ multiplicaciones (aproximadamente, $\sim D^2$)

- (b) En una implementación básica, se calcula la distancia a todas las muestras de entrenamiento. Cada distancia requiere D multiplicaciones, por tanto se necesitan DN multiplicaciones.

- (c) La regla de gradiente sobre una muestra requiere:

- Aplicar el modelo a una muestra: $D(D+2)$ (como se ha visto en (a))
- Aplicar la regla de gradiente estocástico: $\frac{1}{2}D(D+3) + 1$ multiplicaciones

Por tanto, se requieren $\frac{1}{2}D(3D+7)N + N$ multiplicaciones (de forma aproximada, $\sim \frac{3}{2}D^2N$ multiplicaciones, o del orden de D^2N).

- (d) En una implementación básica, por cada valor de k y cada paso de validación (*fold*), se requiere calcular la distancia del 10 % de las muestras al restante 90 %, es decir, $0.1N \cdot 0.9 \cdot DN = 0.09DN^2$ multiplicaciones. Para los 10 pasos, se precisarán $0.9DN^2$ multiplicaciones. Dado que las distancias son simétricas, este número se puede reducir a la mitad ($0.45DN^2$).

Para el resto de valores de k , se requieren las mismas distancias, y por lo tanto no es necesario recalcularlas, de modo que el número total de multiplicaciones es $0.45DN^2$ (o del orden de DN^2).

- (25 %) 5. Considere que el conjunto $\mathcal{D} = \{(x_k, s_k), k = 0, \dots, K-1\}$ contiene muestras i.i.d. provenientes de una distribución

$$p(s|w, x) = \frac{wx}{s} \exp(-wx \ln(s)), \quad s \geq 1, w > 0, x > 0$$

El parámetro w está dado por una distribución a priori exponencial

$$p(w) = \exp(-w), \quad w \geq 0$$

- (a) Suponiendo conocido w , determine la predicción de mínimo error cuadrático medio de S , $\hat{s}_{\text{MSE}}$, para $w > 1$, $x > 1$.
- (b) Determine una expresión de la función de verosimilitud del parámetro w para el conjunto de datos observados, $\mathcal{D}$. Exprese la solución en función de los estadísticos

$$r_K = \prod_{k=0}^{K-1} \frac{x_k}{s_k}$$

$$t_K = \sum_{k=0}^{K-1} x_k \ln(s_k)$$

(c) Determine la distribución a posteriori del parámetro w dados los datos, $p(w|\mathbf{s})$. Utilice de nuevo los estadísticos r_K y/o t_K si le resultan convenientes para simplificar las expresiones.

(d) Determine el estimador de mínimo error cuadrático medio de w dados los datos, $\hat{w}_{\text{MSE}}$

Indicación: para todo entero $n > 0$ y todo número real $z > 0$

$$\int_0^\infty w^n \exp(-wz) dw = \frac{n!}{z^{n+1}}$$

Solution:

(a)

$$\begin{aligned} \hat{s}_{\text{MSE}} &= \mathbb{E}\{S|x, w\} \\ &= \int_1^\infty wx \exp(-wx \ln(s)) ds \\ &= wx \int_1^\infty s^{-wx} ds = wx \left[\frac{s^{1-wx}}{1-wx} \right]_1^\infty \\ &= \frac{wx}{wx-1} \end{aligned}$$

donde la última igualdad es correcta dado que $wx > 1$.

(b) La función de verosimilitud es

$$\begin{aligned} p(\mathbf{s}|w) &= \frac{w^K \prod_{k=0}^{K-1} x_k}{\prod_{k=0}^{K-1} s_k} \exp\left(-w \sum_{k=0}^{K-1} x_k \ln(s_k)\right) \\ &= r_K w^K \exp(-w \cdot t_K), \quad \min_k s_k \geq 1 \end{aligned}$$

(c) Sabiendo que

$$\begin{aligned} p(\mathbf{s}) &= \int p(\mathbf{s}|w)p(w)dw \\ &= \int_0^\infty r_K w^K \exp(-t_K w) \exp(-w) dw \\ &= r_K \int_0^\infty w^K \exp(-(1+t_K)w) dw \\ &= r_K \frac{K!}{(1+t_K)^{K+1}} \end{aligned}$$

la distribución a posteriori será

$$\begin{aligned} p(w|\mathbf{s}) &= \frac{p(w)p(\mathbf{s}|w)}{p(\mathbf{s})} \\ &= \frac{r_K w^K \exp(-(1+t_K)w)}{r_K} \frac{(1+t_K)^{K+1}}{K!} \\ &= \frac{(1+t_K)^{K+1}}{K!} w^K \exp(-(1+t_K)w), \quad w \geq 0 \end{aligned}$$

(d) El estimador de mínimo MSE de w será

$$\begin{aligned}\hat{w}_{\text{MSE}} &= \mathbb{E}\{w|\mathbf{s}\} \\ &= \frac{(1+t_K)^{K+1}}{K!} \int_0^\infty w^{K+1} \exp(-(1+t_K)w) dw \\ &= \frac{(1+t_K)^{K+1}}{K!} \frac{(K+1)!}{(1+t_K)^{K+2}} \\ &= \frac{K+1}{1+t_K}\end{aligned}$$

- (20%) 6. Se dispone de un conjunto de K datos d dimensionales, dispuestos por filas en una matriz $\mathbf{X}$. Se desea disminuir la dimensión de dicho conjunto de datos aplicando PCA. Como primer paso del PCA, los datos son centrados, de manera que la media de todos los datos de entrenamiento sea el vector nulo. Posteriormente, se extraen las primeras m proyecciones de los datos, con $m < d$, de manera que la matriz de datos proyectados es $\tilde{\mathbf{X}}$.

Discuta la verdad o falsedad de las siguientes afirmaciones.

- (a) Si sobre $\tilde{\mathbf{X}}$ se vuelve a ejecutar otra vez el PCA extrayendo únicamente m' proyecciones, con $m' < m$, el resultado final es equivalente al que se obtendría haciendo PCA sobre la matriz $\mathbf{X}$ original y extrayendo únicamente las primeras m' proyecciones, salvo por el hecho de que varias de sus columnas pueden quedar multiplicadas por -1 .
- (b) Si se extienden los datos originales, añadiendo una componente con valor constante igual a 1 al final de cada vector, la matriz de datos proyectados $\tilde{\mathbf{X}}$ no cambia, salvo por el hecho de que varias de sus columnas pueden quedar multiplicadas por -1 .
- (c) Si se realizase el PCA sobre la matriz $-\mathbf{X}$, la matriz de datos proyectados $\tilde{\mathbf{X}}$ no cambia, salvo por el hecho de que varias de sus columnas pueden quedar multiplicadas por -1 .

Solution: Todas son verdaderas, con alguna excepción.

- (a) Utilizando los autovalores y autovectores principales de la matriz de covarianzas (muestrales) de los datos, dicha matriz puede descomponerse como

$$\mathbf{C}_{\mathbf{X}} = \frac{1}{K} \mathbf{X}^\top \mathbf{X} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$$

donde se ha considerado ya que los datos $\mathbf{X}$ han sido centrados, $\mathbf{\Lambda}$ es una matriz diagonal con los autovalores de $\mathbf{C}_{\mathbf{X}}$ dispuestos según valor decreciente, y las columnas de $\mathbf{U}$ contienen los autovectores asociados a cada autovalor.

El algoritmo PCA proyecta los datos utilizando los autovectores asociados a los mayores autovalores de $\mathbf{C}_{\mathbf{X}}$, de manera que

$$\mathbf{C}_{\tilde{\mathbf{X}}} = \frac{1}{K} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} = \mathbf{U}^{(m)} \mathbf{\Lambda}^{(m)} \mathbf{U}^{(m)\top}$$

donde $\mathbf{U}^{(m)}$ es la matriz que conserva únicamente las primeras m columnas de $\mathbf{U}$, y $\mathbf{\Lambda}^{(m)}$ es una matriz diagonal cuadrada de dimensión m , que contiene únicamente los primeros autovalores de $\mathbf{\Lambda}$, ordenados nuevamente en orden decreciente.

Hacer un nuevo PCA sobre $\tilde{\mathbf{X}}$ equivale a proyectar los datos utilizando las m' primeras columnas de $\mathbf{U}^{(m)}$, que es equivalente a proyectar $\mathbf{X}$ según las primeras m' columnas de $\mathbf{U}$, por lo que la afirmación es cierta.

Hay dos argumentos adicionales que pueden tenerse en cuenta:

- La descomposición no es única, ya que no cambia si cualquier autovector se multiplica por -1 . La consecuencia de esto sería que la correspondiente proyección queda multiplicada por -1 , que es una eventualidad que ya considera el enunciado.
 - La segunda consideración es que en el caso en que haya dos (o más) autovectores con exactamente el mismo autovalor, la descomposición del PCA no es única, y en dicho caso la afirmación del enunciado no tendría por qué ser cierta.
- (b) El centrado de los datos hace que la componente que hemos añadido se haga igual a 0, por lo que la matriz de covarianzas no cambia. El único efecto es que en la descomposición de $\mathbf{C}_\mathbf{x}$ aparece un nuevo autovalor nulo que no afecta a la extracción de las primeras componentes del PCA. Por lo tanto, la afirmación es cierta.
- (c) Al multiplicar la matriz de datos por -1 la matriz de covarianzas no cambia, por lo que tampoco lo hace su descomposición. Por tanto, los vectores de proyección no cambian, salvo por el eventual cambio de signo, que provocará a su vez el cambio de signo en la correspondiente proyección. Por lo tanto, la afirmación es verdadera.