

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	20	25	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de K muestras de entrenamiento, $\mathcal{D} = \{(\mathbf{x}_n, s_n), n = 0, \dots, K-1\}$, relativo a un problema de regresión bidimensional, i.e., $\mathbf{x}_n \in \mathbb{R}^2$. Para poder estimar las prestaciones de los modelos construidos se dispone además de un conjunto de datos de test: $\mathcal{D}_{\text{test}}$.

Para la resolución del problema se plantean dos modelos de regresión diferentes:

- regresión lineal ($\hat{s} = \mathbf{w}^\top \mathbf{x} + w_0$) de mínimo error cuadrático medio
- k -NN

Se puede afirmar que:

- (a) Aplicar un procedimiento de normalización de variables que implique solamente una transformación lineal de las variables de entrada ($\mathbf{x}_k$) no tiene ningún efecto sobre el error cuadrático medio de test en el que incurre el modelo lineal.
 - ☐ Verdadero.
 - ☐ Falso.
- (b) Aplicar un procedimiento de normalización de variables que implique solamente una transformación lineal de las variables de entrada ($\mathbf{x}_k$) no tiene ningún efecto sobre el error cuadrático medio de test en el que incurre el k -NN para un valor fijo de k .
 - ☐ Verdadero.
 - ☐ Falso.
- (c) Para cualquier valor de k , el error cuadrático medio de test del k -NN será menor o igual que el del modelo de regresión lineal.
 - ☐ Verdadero.
 - ☐ Falso.
- (d) Asumiendo $k = K$, el error cuadrático medio de entrenamiento del k -NN será mayor o igual que el del modelo de regresión lineal.
 - ☐ Verdadero.
 - ☐ Falso.

- (10%) 2. Considere la resolución de un problema de clasificación binaria mediante regresión logística. Se desea realizar la estimación de máximo a posteriori de los pesos del modelo asumiendo una distribución a priori de los pesos de tipo Laplace:

$$p_{\mathbf{w}}(\mathbf{w}) = \frac{1}{(2C)^N} \exp\left(-\frac{1}{C}\|\mathbf{w}\|_1\right),$$

donde N es la dimension de $\mathbf{w}$, C es el parámetro de la distribución, y $\|\mathbf{w}\|_1$ es la norma L_1 de $\mathbf{w}$.

Se puede afirmar que:

- (a) Si $C \rightarrow \infty$, entonces $\hat{\mathbf{w}}_{\text{MAP}} \rightarrow 0$.
 - ☐ Verdadero.
 - ☐ Falso.
- (b) Si $C \rightarrow \infty$, entonces $\hat{\mathbf{w}}_{\text{MAP}} \rightarrow \infty$.
 - ☐ Verdadero.
 - ☐ Falso.
- (c) Si $C \rightarrow 0$, entonces $\hat{\mathbf{w}}_{\text{MAP}} \rightarrow 0$.
 - ☐ Verdadero.
 - ☐ Falso.
- (d) Si $C \rightarrow 0$, entonces $\hat{\mathbf{w}}_{\text{MAP}} \rightarrow \mathbf{w}_{\text{ML}}$.
 - ☐ Verdadero.
 - ☐ Falso.

- (10%) 3. Se dispone de una colección de documentos a los que se ha aplicado un pipeline completo de preprocesamiento. Cada documento se representa como una lista de tokens. El número de tokens diferentes observados en todos los documentos es V (tamaño del vocabulario).

Se sabe que la palabra *petate* aparece 7 veces en el primer documento, que dicho documento contiene un total de 21 tokens, y que dicha palabra aparece en un tercio de los documentos de la colección.

Se puede afirmar que:

- (a) La representación BoW del primer documento contiene en su componente correspondiente a *petate* el valor $7/V$.
 - ☐ Verdadero.
 - ☐ Falso.
- (b) La representación BoW del primer documento contiene en su componente correspondiente a *petate* el valor $1/3$.
 - ☐ Verdadero.
 - ☐ Falso.
- (c) La representación TFIDF del primer documento contiene en su componente correspondiente a *petate* el valor $\log(3)/3$.
 - ☐ Verdadero.
 - ☐ Falso.
- (d) La representación del primer documento correspondiente a un modelo LDA contiene al menos tantas componentes no nulas como tópicos tenga el modelo en los que palabra *petate* tenga un peso significativo.
 - ☐ Verdadero.
 - ☐ Falso.

- (25 %) 4. Considere el conjunto $\mathcal{D} = \{(\mathbf{x}_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^d$ y $s_k \in \mathbb{R}$. Se desea ajustar un modelo de regresión lineal según el modelo paramétrico

$$s = \mathbf{w}^\top \mathbf{x} + \varepsilon$$

con $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ y distribución a priori de pesos $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, v\mathbf{I})$.

Se sabe, además, que $\sum_k \mathbf{x}_k \mathbf{x}_k^\top = \mathbf{I}$ y $\sum_k \mathbf{x}_k s_k = \mathbf{1}$, siendo $\mathbf{1}$ el vector con todas sus componentes iguales a uno y longitud d .

- (a) Obtenga el estimador de máxima verosimilitud del vector de pesos, $\hat{\mathbf{w}}_{\text{ML}}$. Simplifique la expresión obtenida tanto como le sea posible, dejándola en función únicamente de σ_ε y v .

Suponga ahora que

$$\mathcal{D} = \left\{ \left(\begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, 1 \right), \left(\begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}, 0 \right) \right\} \quad (1)$$

- (b) Obtenga el estimador de máxima verosimilitud del vector de pesos, $\hat{\mathbf{w}}_{\text{MAP}}$. Simplifique la expresión obtenida tanto como le sea posible, dejándola en función únicamente de σ_ε y v .
- (c) Calcule la media predictiva de s , $\mathbb{E}\{\mathbf{w}^\top \mathbf{x} | \mathcal{D}\}$, de acuerdo al modelo propuesto.
- (d) Calcule la covarianza a posteriori de s , $\text{Cov}(s | \mathcal{D})$, de acuerdo al modelo propuesto. Justifique si el modelo muestra mayor confianza acerca de sus predicciones para ciertos valores de $\mathbf{x}$.

- (20 %) 5. Se desea aplicar cuantificación vectorial para reducir el tamaño de una matriz de datos $\mathbf{X}$ de tamaño $100\,000 \times 84$, cuyas componentes son floats. Se sabe además que cada float requiere para su representación 4 Bytes (B) de longitud.

Se aplica cuantificación vectorial para obtener una versión aproximada de dicha matriz $\tilde{\mathbf{X}}$, utilizando para ello un número K de centroides seleccionados mediante el algoritmo de agrupamiento K -medias.

Explique por qué la cuantificación vectorial permite un ahorro de memoria para el almacenamiento de la matriz de datos. Incluya en su respuesta los siguientes aspectos:

- (a) Una explicación de cómo se debería aplicar el algoritmo K -medias como parte del proceso de cuantificación vectorial.
- (b) Explique por qué resulta adecuado seleccionar los centroides utilizando un algoritmo de agrupamiento como K -medias en lugar de emplear alternativas más simples (e.g., selección aleatoria).
- (c) Calcule el ahorro obtenido en función del número de centroides K , explicando los aspectos que deben considerarse para la selección de dicho parámetro. Puede asumir en su respuesta que K es una potencia de 2.

- (25 %) 6. (a) Describa brevemente la arquitectura de una red neuronal de capa simple (single-layer neural network, SLNN) para clasificación binaria. Formule matemáticamente la relación de entrada-salida de la red. Es decir, la fórmula o fórmulas que determinen el valor de la decisión $\hat{y}$ para una entrada $\mathbf{x}$,

Considere ahora una SLNN para clasificación binaria en la que la función de activación logística ha sido reemplazada por una función de activación softplus, dada por

$$\text{softplus}(t) = \log(1 + \exp(t))$$

Se desea entrenar la red utilizando la función de pérdidas (*loss function*) dada por

$$\ell(y, q) = (y - q)^4$$

donde $y \in \{0, 1\}$ es la clase verdadera y q es la salida de la función de activación. Para ello, se desea minimizar el riesgo empírico

$$R = \sum_{k=0}^{K-1} \ell(y_k, q_k)$$

con respecto a los parámetros de la red, sobre un conjunto de K muestras de entrenamiento.

- (b) Determine la regla de aprendizaje por gradiente para los parámetros de la red, que minimice el riesgo empírico dado.
- (c) Dado que la función de activación no es de tipo probabilístico y la función de pérdidas tampoco es asimilable a la log-verosimilitud, no tenemos garantías de que, tras el entrenamiento, el valor de q proporcione un valor de probabilidad de la clase 1. Por tanto, la regla de decisión

$$q \underset{D=0}{\overset{D=1}{\gtrless}} \frac{1}{2}$$

podría ser subóptima. Para evitar este problema, se plantea el uso de un umbral μ ajustable

$$q \underset{D=0}{\overset{D=1}{\gtrless}} \mu$$

Proponga algún procedimiento para ajustar el valor de μ a partir de los datos de entrenamiento, de modo que se minimice la tasa de errores de clasificación.