

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de N muestras, $\mathcal{D} = \{(x_n, s_n)\}$, relativo a un problema de regresión unidimensional ($x_n, s_n \in \mathbb{R}$) en el que x representa la edad de una persona y s su altura. Para el diseño del estimador que predice s a partir de x se entrena un modelo k -NN, seleccionando el valor del parámetro k mediante validación cruzada con M folds.

Se puede afirmar que:

- (a) El número de estimadores que deben evaluarse en el proceso de validación cruzada crece con el valor de M .
☒ **Verdadero.** ☐ Falso.
- (b) El número de distancias que es suficiente evaluar al utilizar $M = 2$ es $N^2/2$.
☒ **Verdadero.** ☐ Falso.
- (c) El valor seleccionado para el parámetro k minimiza el MSE de entrenamiento promediado sobre las M particiones.
☐ Verdadero. ☒ **Falso.**

- (10 %) 2. Considere la resolución de un problema de clasificación logística con verosimilitud $p(s|\mathbf{x}, \mathbf{w})$ y función de log-verosimilitud negativa $\text{NLL}(\mathbf{w})$. Considere las asunciones habituales de independencia de las muestras de entrenamiento.

Se puede afirmar que:

- (a) La solución ML minimiza el error cuadrático medio sobre el conjunto de entrenamiento para cualquier $p(s|\mathbf{x}, \mathbf{w})$.
☐ Verdadero. ☒ **Falso.**
- (b) Una mala elección de la función de verosimilitud $p(s|\mathbf{x}, \mathbf{w})$ podría hacer que $\text{NLL}(\mathbf{w}) = \infty$, para cualquier $\mathbf{w}$.
☒ **Verdadero.** ☐ Falso.
- (c) La optimización por gradiente no puede emplearse cuando existe una solución analítica cerrada que minimice $\text{NLL}(\mathbf{w})$.
☐ Verdadero. ☒ **Falso.**
- (d) Si asumimos una distribución a priori para el vector de pesos $p(\mathbf{w})$, se verifica $\text{NLL}(\mathbf{w}_{\text{MAP}}) > \text{NLL}(\mathbf{w}_{\text{ML}})$, donde $\mathbf{w}_{\text{ML}}$ y $\mathbf{w}_{\text{MAP}}$ son, respectivamente la soluciones de máxima verosimilitud y de máximo a posteriori.
☐ Verdadero. ☒ **Falso.**

(10 %) 3. Se puede afirmar que:

- (a) LDA es un modelo de aprendizaje que requiere etiquetas de clase (tantas como tópicos deseados) para entrenar el modelo.
☐ Verdadero. ☒ **Falso.**
- (b) LDA asigna una distribución de probabilidad al vocabulario para cada tópico identificado en el corpus.
☒ **Verdadero.** ☐ Falso.
- (c) El modelo generativo de LDA asume que cada documento puede contener múltiples temas con diferentes pesos de importancia.
☒ **Verdadero.** ☐ Falso.
- (d) Considere que la distribución a priori de las representaciones vectoriales de los documentos es una Dirichlet simétrica con hiperparámetro α . Un valor alto de α favorece la asignación de un mayor número de temas a cada documento en el corpus.
☒ **Verdadero.** ☐ Falso.

(25 %) 4. Considere el conjunto $\{(x_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $x_k, s_k > 0$. Para la resolución del problema de regresión unidimensional se asume el siguiente modelo paramétrico

$$p(s|x, w) = \frac{(wx)^2 s \exp(-wxs)}{2}, \quad s, x, w > 0.$$

- (a) Suponiendo conocido w , determine el estimador MAP para este modelo, $\hat{s}_{\text{MAP}}$.
- (b) Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(w)$.
- (c) Calcule la regla de gradiente que permite aproximar la solución ML.
- (d) Calcule la regla de gradiente que permite aproximar la solución MAP de w asumiendo $p(w) = \exp(-w)$, $w > 0$.

Solution:

- (a) Debemos encontrar el valor de s que maximiza $p(s|x, w)$. Sabemos que $p(s|x, w) \rightarrow 0$ tanto para $s \rightarrow 0$ como $s \rightarrow \infty$. Como se trata de una función analítica positiva, el máximo debe obtenerse para un valor intermedio de s con derivada nula.

$$\frac{\partial p(s|x, w)}{\partial s} = \frac{(wx)^2}{2} (1 - swx) \exp(-wxs)$$

La solución MAP queda por tanto determinada por el único valor de s que anula la derivada anterior, i.e., $1 - \hat{s}_{\text{MAP}}wx = 0$. Por lo tanto:

$$\hat{s}_{\text{MAP}} = \frac{1}{wx}$$

(b)

$$\text{NLL}(w) = - \sum_{k=0}^{K-1} \log p(s_k|x_k, w) = K \log 2 - \sum_{k=0}^{K-1} 2 \log(wx_k) + \log(s_k) - wx_k s_k$$

(c)

$$w(n+1) = w(n) - \rho \frac{d\text{NLL}(w)}{dw} \Big|_{w=w(n)} = w(n) + \rho \left[\frac{2K}{w(n)} - \sum_{k=0}^{K-1} x_k s_k \right]$$


(d)

$$w(n+1) = w(n) - \rho \frac{d[\text{NLL}(w) + \log p(w)]}{dw} \Big|_{w=w(n)} = w(n) + \rho \left[1 + \frac{2K}{w(n)} - \sum_{k=0}^{K-1} x_k s_k \right]$$

- (25 %) 5. Explique cómo puede extenderse la red neuronal de una sola capa (SLN, single-layer neural network) para problemas de clasificación multiclase. Para ello:
- Represente gráficamente la arquitectura de la red. Suponga, para simplificar, entrada $\mathbf{x}$ de dimensión 4, y 3 clases.
 - Formule matemáticamente las ecuaciones que definen la relación entrada-salida de la red neuronal.
 - Si M es el número de clases y N la dimensión de la entrada, indique la dimensión del espacio de parámetros de la red (es decir, el número de parámetros ajustables).
 - Proponga una función de pérdidas (*loss function*) para el ajuste de los parámetros de la red a partir de un conjunto de datos de entrenamiento, que permita garantizar que las salidas blandas (soft-decisions) de la red sean estimaciones de las probabilidades de las clases.

Solution:

- (a) La figura muestra una NN multiclase genérica de una sola capa, para una entrada de dimensión 4096 y M clases



- (b)

$$\hat{\mathbf{y}} = \text{hardmax}(\mathbf{q})$$

siendo

$$\mathbf{q} = \text{softmax}(\mathbf{o})$$

y

$$\mathbf{o} = \mathbf{W}^T \mathbf{x} + \mathbf{b}$$

La función softmax está dada por:

$$q_i = \frac{\exp(o_i)}{\sum_{j=0}^{M-1} \exp(o_j)}$$

- (c) Los parámetros ajustables son la matriz $\mathbf{W}$ (de dimensión $N \times M$) y el vector $\mathbf{b}$ de dimensión M . Por tanto, la dimensión del espacio de parámetros es $(N + 1) \cdot M$.
- (d) Por ejemplo, la entropía cruzada:

$$\ell(\mathbf{q}, \mathbf{y}) = -\mathbf{y}^T \log(\mathbf{q})$$

- (20 %) 6. Explique los siguientes aspectos del algoritmo K-medias:
- (a) Distintas posibilidades para la inicialización de los centroides
 - (b) El proceso iterativo principal del algoritmo
 - (c) La convergencia del algoritmo y posibles criterios de parada
 - (d) Algún método para la selección del número de centros del algoritmo

Solution:

- (a) Por ejemplo:
 - Selección aleatoria
 - Primer centroide de manera aleatoria, resto tratando de maximizar la distancia a los ya seleccionados (k-means ++).
- (b)
 - Se asigna cada muestra al grupo caracterizado por el centroide más cercano
 - Se recalcula el centroide de cada grupo como la media de las muestras asignadas al grupo
- (c)
 - El algoritmo converge siempre, aunque no necesariamente a la solución que minimiza la función objetivo (i.e., el algoritmo para, pero puede no ser la mejor solución posible)
 - Posibles criterios de parada: por número de iteraciones, por disminución relativa de la función de distorsión global.
- (d) Por ejemplo:
 - Entrenar para distintos valores de K , y hacerlo de forma manual buscando el codo de la curva que muestra la distorsión global frente al valor de K .
 - Similar al anterior, pero conservando el valor de K que minimice la suma de la distorsión global con un término de penalización creciente con el valor de K .