

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de muestras de entrenamiento, $\mathcal{D} = \{(\mathbf{x}_n, s_n), n = 0, \dots, K-1\}$, relativo a un problema de regresión bidimensional (es decir, $\mathbf{x}_n \in \mathbb{R}^2$). Todas las muestras son diferentes ($\mathbf{x}_n \neq \mathbf{x}_m$, para todo $n \neq m$).

Supongamos que se aplica un algoritmo de regresión 1-NN y suponga que para cierta entrada $\mathbf{x}^*$, la predicción es $\hat{s}^*$.

Suponga ahora que se aplica sobre todos los datos cierta transformación $T(\mathbf{x})$, obteniéndose el dataset transformado $\mathcal{D}' = \{(\mathbf{z}_n, s_n), n = 0, \dots, K-1\}$, siendo $\mathbf{z}_n = T(\mathbf{x}_n)$. A continuación se aplica el mismo algoritmo, regresión 1-NN, pero con los datos de entrenamiento transformados.

Sea $\hat{t}^*$ la predicción del nuevo 1-NN para la entrada transformada $\mathbf{z}^* = T(\mathbf{x}^*)$.

Suponga que tanto $\mathbf{x}^*$ como $\mathbf{z}^*$, son muestras “regulares”, es decir que su vecino más próximo es único (no hay “empates”).

Indique para cuáles de las siguientes transformaciones se puede afirmar que $\hat{t}^* = \hat{s}^*$:

(a) $T(\mathbf{x}) = \mathbf{x} + \begin{bmatrix} 2 \\ 3 \end{bmatrix}$.

✓ Verdadero.

☐ Falso.

(b) $T(\mathbf{x}) = 3\mathbf{x}$.

✓ Verdadero.

☐ Falso.

(c) $T(\mathbf{x}) = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} \mathbf{x}$.

☐ Verdadero.

✓ Falso.

(d) $T(\mathbf{x}) = \begin{bmatrix} x_0^2 \\ x_1^2 \end{bmatrix}$.

☐ Verdadero.

✓ Falso.

- (10 %) 2. Considere la resolución de un problema de clasificación binaria unidimensional mediante regresión logística, en el que la estimación de la probabilidad de clase 1 se estima mediante:

$$P_{Y|X}(1|x, \mathbf{w}) = g(w_0 + w_1x + w_2x^2)$$

siendo $g()$ la función logística.

Se dispone de un conjunto de datos de entrenamiento $\mathcal{D} = \{(x_n, y_n), n = 0, \dots, K-1\}$, con $x_n \in \mathbb{R}$ e $y_n \in \{0, 1\}$.

Sean $\mathbf{w}_{\text{ML}}$ y $\mathbf{w}_{\text{MAP}}$ las soluciones óptimas de máxima verosimilitud y de máximo a posteriori, considerando en este caso una distribución a priori para $\mathbf{w}$ de tipo Gaussiana multidimensional.

Se puede afirmar que:

- (a) $P_{Y|X}(0|x, \mathbf{w}) = g[-(w_0 + w_1x + w_2x^2)]$

✓ Verdadero.

☐ Falso.

- (b) La log-verosimilitud negativa calculada sobre los datos de entrenamiento, verifica $\text{NLL}(\mathbf{w}_{\text{ML}}) \leq \text{NLL}(\mathbf{w}_{\text{MAP}})$.

✓ Verdadero.

☐ Falso.

- (c) Si se simplifica el modelo asumiendo $w_0 = w_2 = 0$, se puede obtener una solución analítica cerrada para $w_{1,\text{ML}}$

☐ Verdadero.

✓ Falso.

- (d) Si se simplifica el modelo asumiendo $w_1 = w_2 = 0$, se puede obtener una solución analítica cerrada para $w_{0,\text{ML}}$

✓ Verdadero.

☐ Falso.

- (10 %) 3. Se desea abordar una tarea de clasificación de reseñas de Goodreads con el objetivo de predecir el género del libro (poesía, fantasía, etc.) que se está reseñando. Para realizar pruebas, nos enfocaremos en las siguientes dos reseñas de entre las D disponibles en el dataset:

- R1: “Plot twists maintain reader’s **interest** till last page.”
- R2: “Economic report analyzes **interest** rate impact on markets.”

- (a) De forma general, se puede afirmar que la lematización permite eliminar variantes morfológicas de las palabras.

✓ Verdadero.

☐ Falso.

- (b) Tras aplicar un pipeline de preprocesamiento, las representaciones BoW de R1 y R2, denotadas como $\mathbf{w}_{R1}$ y $\mathbf{w}_{R2}$, respectivamente, permiten acceder a la componente correspondiente a la palabra “interest” en cada reseña mediante la indexación $\mathbf{w}_{Ri}^{\text{interest}}$. Se puede afirmar que $\mathbf{w}_{R1}^{\text{interest}} = \mathbf{w}_{R2}^{\text{interest}}$. Asuma que ninguna de las palabras presentes en R1 y R2 está en la lista de stopwords, y tampoco se han agrupado en n-gramas.

✓ Verdadero.

☐ Falso.

- (c) Para obtener embeddings Word2Vec ad-hoc para nuestro problema de clasificación, vamos a entrenar un modelo Word2Vec de tipo CBOW. Se puede afirmar que, si usamos Negative Sampling, el número de muestras negativas necesarias durante el entrenamiento va a ser mayor al que necesitaríamos si no usáramos Negative Sampling.

☐ Verdadero.

✓ Falso.

- (d) Se dispone de un modelo Transformer que utiliza un mecanismo de atención multi-head con un número de cabezas determinado, N capas de tipo encoder y N capas de tipo decoder. Considerando como embeddings de documento los obtenidos a la salida del último encoder del modelo, se puede afirmar que el embedding obtenido en el momento en que la entrada al modelo es la secuencia R2 es idéntico al que se obtendría si en ese mismo instante insertáramos la siguiente frase:

“Markets interest on analyzes economic report rate impact”.

☐ Verdadero.

☒ Falso.

- (25 %) 4. Considere el conjunto $\{(\mathbf{x}_k, s_k), k = 0, \dots, K-1\}$ de muestras independientes e idénticamente distribuidas, con $\mathbf{x}_k \in \mathbb{R}^d$ y $s_k \in \mathbb{R}$. Para la resolución del problema de regresión se asume una distribución de tipo Cauchy:

$$p(s|\mathbf{x}, \mathbf{w}) = \frac{1}{\pi} \left[\frac{\gamma}{\gamma^2 + (s - \mathbf{w}^\top \mathbf{x})^2} \right],$$

donde $\gamma > 0$ es un parámetro de escala.

- (a) Suponiendo conocido $\mathbf{w}$, determine el estimador MAP de s para una entrada $\mathbf{x}$, $\hat{s}_{\text{MAP}}$.
 (b) Determine una expresión para la log-verosimilitud negativa, $\text{NLL}(\mathbf{w})$.
 (c) Calcule la regla de gradiente que permite aproximar la solución ML.
 (d) Calcule la regla de gradiente que permite aproximar la solución MAP de $\mathbf{w}$ asumiendo $\mathbf{w} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{I})$.

Solution:

(a)

$$\hat{s}_{\text{MAP}} = \arg \max_s p(s|\mathbf{x}, \mathbf{w}) = \arg \min_s (s - \mathbf{w}^\top \mathbf{x})^2 = \mathbf{w}^\top \mathbf{x}$$

(b)

$$\begin{aligned} \text{NLL}(\mathbf{w}) &= - \sum_{k=0}^{K-1} \log \gamma - \log \pi - \log[\gamma^2 + (s_k - \mathbf{w}^\top \mathbf{x}_k)^2] \\ \text{NLL}(\mathbf{w}) &= -K \log \gamma + K \log \pi + \sum_{k=0}^{K-1} \log[\gamma^2 + (s_k - \mathbf{w}^\top \mathbf{x}_k)^2] \end{aligned}$$

(c)

$$\mathbf{w}_{n+1} = \mathbf{w}_n + \rho \sum_{k=0}^{K-1} \left[\frac{2(s_k - \mathbf{w}_n^\top \mathbf{x}_k) \mathbf{x}_k}{\gamma^2 + (s_k - \mathbf{w}_n^\top \mathbf{x}_k)^2} \right]$$

(d)

$$\mathbf{w}_{n+1} = (1 - \rho) \mathbf{w}_n + \rho \boldsymbol{\mu} + \rho \sum_{k=0}^{K-1} \left[\frac{2(s_k - \mathbf{w}_n^\top \mathbf{x}_k) \mathbf{x}_k}{\gamma^2 + (s_k - \mathbf{w}_n^\top \mathbf{x}_k)^2} \right]$$

- (25 %) 5. Se desea entrenar un perceptrón de tres capas (una capa de entrada, una capa oculta y una capa de salida) para resolver un problema de clasificación. Se debe elegir una función de activación para las neuronas de la capa oculta y de la capa de salida.

(a) Indique brevemente qué funciones de activación suelen utilizarse en redes neuronales. Preferentemente, indique su nombre, y su fórmula o una representación gráfica aproximada.

Se desea que el clasificador proporcione salidas que puedan interpretarse como valores de probabilidad.

Asimismo, se desea utilizar (en la medida de lo posible) funciones de activación que mitiguen el problema de desvanecimiento del gradiente (es decir, que las derivadas se hagan 0 para valores grandes de la entrada).

- (b) Discuta qué función o funciones de activación recomendaría para la capa oculta.
- (c) Discuta qué función o funciones de activación recomendaría para la capa de salida, si el clasificador es binario.
- (d) Discuta qué función o funciones de activación recomendaría para la capa de salida, si el clasificador es multiclase.

Solution:

- (a) Logística, ReLu, PreLu, softplus, etc. También, la función escalón, para la etapa de decisión. En problemas multiclase, también se utiliza la activación softmax y, para la decisión, hardmax.
- (b) Relu, Prelu o softplus. Su derivada no se hace cero para valores grandes de la entrada. Prelu también tiene pendiente constante y positiva para valores negativos de la entrada.
- (c) La función logística
- (d) Softmax.

- (20 %) 6. Considere la aplicación del algoritmo de agrupamiento K -medias sobre un conjunto de datos de entrenamiento $\mathcal{D} = \{\mathbf{x}_n, n = 0, \dots, L - 1\}$.

- (a) Describa los pasos principales del algoritmo.
- (b) ¿Cómo afecta la elección del número de clusters K en el resultado del algoritmo K -medias? Proponga alguna estrategia para elegir un valor adecuado de K .
- (c) Justifique por qué es habitual ejecutar varios entrenamientos del algoritmo con distintas inicializaciones, y cómo se selecciona a partir de dichas soluciones el agrupamiento final.

Solution:

[Consulte el notebook de teoría sobre Agrupamiento.]