

Nombre y apellidos: _____

NIA y Firma: _____

Question:	1	2	3	4	5	6	Total
Points:	10	10	10	25	25	20	100
Score:							

Indicaciones:

- Para la resolución del examen no se permite el uso de apuntes, ejercicios resueltos o calculadoras de cualquier tipo. Únicamente se acepta el uso de una hoja manuscrita con fórmulas pero sin texto alguno.
- La puntuación de cada pregunta tipo test será proporcional a la diferencia entre el número de aciertos y el número de errores. La puntuación mínima de la parte de test es 0.

- (10 %) 1. Se dispone de un conjunto de datos de entrenamiento para un problema de regresión unidimensional, $\mathcal{D} = \{(x_k, s_k), k = 0, \dots, K - 1\}$, con $x \in \mathbb{R}$ y $s \in \mathbb{R}$.

La estimación de S a partir de X se realiza ajustando por máxima verosimilitud los dos modelos siguientes:

$$\text{Modelo 1: } p(s \mid w_0, x) = \frac{1}{\sqrt{2\pi\sigma_\epsilon^2}} \exp\left(-\frac{(s - w_0)^2}{2\sigma_\epsilon^2}\right)$$

$$\text{Modelo 2: } p(s \mid w_0, w_1, x) = \frac{1}{\sqrt{2\pi\sigma_\epsilon^2}} \exp\left(-\frac{(s - (w_0 + w_1x))^2}{2\sigma_\epsilon^2}\right)$$

donde σ_ϵ^2 es una constante conocida.

Se puede afirmar que:

- (a) El estimador $\hat{s}_{\text{MSE}}(x)$ asociado al modelo 1 es independiente de x .
☒ **Verdadero.**
☐ Falso.
- (b) Para el modelo 2, los estimadores ML de w_0 y w_1 se obtienen resolviendo un problema de regresión lineal por mínimos cuadrados.
☒ **Verdadero.**
☐ Falso.
- (c) El error cuadrático medio sobre el conjunto de entrenamiento no puede ser menor para el modelo 1 que para el modelo 2.
☒ **Verdadero.**
☐ Falso.
- (d) El modelo 2 siempre generaliza mejor que el modelo 1, independientemente del conjunto de datos.
☐ Verdadero.
☒ **Falso.**

- (10 %) 2. Considere un problema de regresión logística con el modelo $g(\mathbf{w}^T \mathbf{x})$, donde $g(t) = 1/(1 + \exp(-t))$ es la función logística, y $\mathbf{w}$ es el parámetro libre. Se dispone de un conjunto de entrenamiento $\mathcal{D} = \{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$, donde $\mathbf{x}_k \in \mathbb{R}^d$ e $y_k \in \{-1, 1\}$.

Se puede afirmar que:

- (a) Para la regresión logística binaria, la función de log-verosimilitud negativa es no convexa con respecto a los parámetros del modelo.
 - ☐ Verdadero.
 - ✓ **Falso.**
- (b) El valor de $g(y_k \mathbf{w}^T \mathbf{x}_k)$ puede estar en cualquier punto en el intervalo $[-1, 1]$.
 - ☐ Verdadero.
 - ✓ **Falso.**
- (c) Una iteración del método de Newton aplicada a la minimización de la log-verosimilitud es computacionalmente más costosa que una iteración del descenso por gradiente.
 - ✓ **Verdadero.**
 - ☐ Falso.
- (d) El problema de optimización para calcular el estimador MAP de la regresión logística con un prior de una distribución de Laplace se corresponde con minimizar la suma de la log-verosimilitud negativa más una regularización de la forma $\frac{1}{C} \|\mathbf{w}\|_2^2$, para una constante C .
 - ☐ Verdadero.
 - ✓ **Falso.**

- (10 %) 3. Se desea analizar un conjunto de datos biomédicos sin etiquetas previas con el objetivo de identificar posibles agrupaciones naturales entre los pacientes. Para ello, se plantea utilizar el algoritmo de clustering K-means.

Se puede afirmar que:

- (a) El algoritmo K-means garantiza encontrar la partición óptima global que minimiza la suma de distancias intra-clúster.
 - ☐ Verdadero.
 - ✓ **Falso.**
- (b) K-means utiliza la distancia entre muestras para determinar la vecindad por lo que es insensible a que normalicemos los datos para que tengan media cero y varianza unidad.
 - ☐ Verdadero.
 - ✓ **Falso.**
- (c) La elección del número de clústers K puede abordarse utilizando métodos como el método del codo o el coeficiente de silueta.
 - ✓ **Verdadero.**
 - ☐ Falso.
- (d) K-means es robusto frente a la presencia de outliers, ya que los centroides no se ven afectados por valores extremos.
 - ☐ Verdadero.
 - ✓ **Falso.**

4. Considere que el conjunto de datos

$$\mathcal{D} = \{(x_k, s_k), k = 0, \dots, K-1\}$$

contiene muestras i.i.d. provenientes de la distribución condicional

$$p(s | w, x) = wx \exp(-wxs), \quad s \geq 0, w > 0, x > 0.$$

El parámetro w está modelado como una variable aleatoria con distribución a priori gamma

$$p(w) = \frac{\beta^\alpha}{\Gamma(\alpha)} w^{\alpha-1} \exp(-\beta w), \quad w \geq 0, \alpha > 0, \beta > 0.$$

- (5 %) (a) Suponiendo conocido w , determine el estimador de mínimo error cuadrático medio de S , $\hat{s}_{\text{MSE}}(x)$.
- (10 %) (b) Determine el estimador de máxima verosimilitud de w , $\hat{w}_{\text{ML}}$.
- (10 %) (c) Determine el estimador MAP de w , $\hat{w}_{\text{MAP}}$.

Indicación: Si le resulta útil, utilice las siguientes definiciones:

$$r_K = \prod_{k=0}^{K-1} x_k, \quad t_K = \sum_{k=0}^{K-1} x_k s_k.$$

Solution:

(a)

$$\hat{s}_{\text{MSE}}(x) = \mathbb{E}\{S | w, x\} = \int_0^\infty s p(s | w, x) ds.$$

Sustituyendo $p(s | w, x) = wx e^{-wxs}$:

$$\hat{s}_{\text{MSE}}(x) = \int_0^\infty s (wx) e^{-wxs} ds.$$

Integrando por partes obtenemos:

$$\boxed{\hat{s}_{\text{MSE}}(x) = \frac{1}{wx}.$$

(b) **Cálculo de la Verosimilitud $p(\mathbf{s} | w, \mathbf{x})$ en función de r_K y t_K .**

$$\begin{aligned} p(\mathbf{s} | w, \mathbf{x}) &= \prod_{k=0}^{K-1} p(s_k | w, x_k) = \prod_{k=0}^{K-1} (wx_k e^{-wx_k s_k}) \\ &= \left(\prod_{k=0}^{K-1} x_k \right) w^K \exp\left(-w \sum_{k=0}^{K-1} x_k s_k\right). \end{aligned}$$

Usando r_K y t_K :

$$\boxed{p(\mathbf{s} | w, \mathbf{x}) = r_K w^K \exp(-wt_K), \quad w > 0.}$$

Estimador ML de w , $\hat{w}_{\text{ML}}$.

Maximizamos la verosimilitud (equivalentemente su logaritmo) respecto de w :

$$\log p(\mathbf{s} \mid w, \mathbf{x}) = \log r_K + K \log w - wt_K.$$

Derivamos e igualamos a cero:

$$\frac{d}{dw} (K \log w - wt_K) = \frac{K}{w} - t_K = 0 \quad \Rightarrow \quad w = \frac{K}{t_K}.$$

Como $t_K = \sum_k x_k s_k \geq 0$ y para datos no degenerados $t_K > 0$, resulta:

$$\hat{w}_{\text{ML}} = \frac{K}{t_K}.$$

(c) El posterior (no normalizado) es

$$p(w \mid \mathbf{s}, \mathbf{x}) \propto p(\mathbf{s} \mid w, \mathbf{x}) p(w) \propto (r_K w^K e^{-wt_K}) (w^{\alpha-1} e^{-\beta w}).$$

Ignorando constantes respecto de w :

$$p(w \mid \mathbf{s}, \mathbf{x}) \propto w^{\alpha+K-1} \exp(-(\beta + t_K)w), \quad w \geq 0.$$

Maximizamos el log-posterior:

$$\log p(w \mid \mathbf{s}, \mathbf{x}) = (\alpha + K - 1) \log w - (\beta + t_K)w + C.$$

Derivando e igualando a cero:

$$\frac{\alpha + K - 1}{w} - (\beta + t_K) = 0 \quad \Rightarrow \quad w = \frac{\alpha + K - 1}{\beta + t_K}.$$

Como $K \geq 1$ y $\alpha > 0$, se tiene $\alpha + K - 1 > 0$ y el máximo es interior ($w > 0$). Por tanto:

$$\hat{w}_{\text{MAP}} = \frac{\alpha + K - 1}{\beta + t_K}.$$

- (25 %) 5. Considere el conjunto $\{(\mathbf{x}_k, y_k), k = 0, \dots, K-1\}$ de muestras i.i.d., donde $\mathbf{x}_k = (x_{k0}, x_{k1})^\top$ son observaciones bidimensionales, e $y_k \in \{0, 1\}$ son variables binarias generadas según el modelo

$$p(y \mid \mathbf{x}, \mathbf{w}) = (1 - e^{-(w_0 x_0 + w_1 x_1)^2})^y (e^{-(w_0 x_0 + w_1 x_1)^2})^{1-y}.$$

Nuestro objetivo es determinar el estimador de máxima verosimilitud (ML) de $\mathbf{w} = (w_0, w_1)^\top$ minimizando la log-verosimilitud negativa

$$\text{NLL}(\mathbf{w}) = -\ln p(y_0, \dots, y_{K-1} \mid \mathbf{x}_0, \dots, \mathbf{x}_{K-1}, \mathbf{w}).$$

- (a) Calcule el gradiente de $\ln p(y \mid \mathbf{x}, \mathbf{w})$ con respecto a $\mathbf{w}$.
- (b) Especifique una regla de aprendizaje de descenso por gradiente estocástico con paso η para minimizar $\text{NLL}(\mathbf{w})$.
- (c) Sabiendo que la distribución a priori de la variable $\mathbf{w}$ es

$$p_{\mathbf{w}}(\mathbf{w}) = \frac{1}{Z} \exp\left(-\frac{w_0^4 + w_1^4}{4}\right),$$

donde $Z > 0$ es una constante de normalización, derive la regla de descenso por gradiente que proporciona el estimador MAP.

Solution:

(a) Para una única muestra $(\mathbf{x}, y)$, la log-verosimilitud es

$$\ln p(y | \mathbf{x}, \mathbf{w}) = y \ln(1 - e^{-(\mathbf{w}^\top \mathbf{x})^2}) - (1 - y)(\mathbf{w}^\top \mathbf{x})^2.$$

Se tiene

$$\frac{\partial}{\partial \mathbf{w}} \ln(1 - e^{-(\mathbf{w}^\top \mathbf{x})^2}) = \frac{2(\mathbf{w}^\top \mathbf{x})e^{-(\mathbf{w}^\top \mathbf{x})^2}}{1 - e^{-(\mathbf{w}^\top \mathbf{x})^2}} \mathbf{x}.$$

Por tanto,

$$\nabla_{\mathbf{w}} \ln p(y | \mathbf{x}, \mathbf{w}) = 2(\mathbf{w}^\top \mathbf{x}) \left[\frac{y e^{-(\mathbf{w}^\top \mathbf{x})^2}}{1 - e^{-(\mathbf{w}^\top \mathbf{x})^2}} - (1 - y) \right] \mathbf{x}.$$

(b) El gradiente de la log-verosimilitud negativa es

$$\nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) = \sum_{k=0}^{K-1} 2(\mathbf{w}^\top \mathbf{x}_k) \left[(1 - y_k) - \frac{y_k}{e^{(\mathbf{w}^\top \mathbf{x}_k)^2} - 1} \right] \mathbf{x}_k,$$

donde arriba hemos multiplicado por $e^{(\mathbf{w}^\top \mathbf{x}_k)^2}$ en numerador y denominador.

Una iteración de descenso por gradiente estocástico con paso $\eta > 0$ viene dada por

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - 2\eta((\mathbf{w}^{(t)})^\top \mathbf{x}_{k_t}) \left[(1 - y_{k_t}) - \frac{y_{k_t}}{e^{((\mathbf{w}^{(t)})^\top \mathbf{x}_{k_t})^2} - 1} \right] \mathbf{x}_{k_t},$$

donde $k_t \in \{0, \dots, K-1\}$ se elige de manera uniformemente aleatoria en cada iteración.

(c) El estimador MAP minimiza

$$J(\mathbf{w}) = \text{NLL}(\mathbf{w}) + \frac{w_0^4 + w_1^4}{4}.$$

El gradiente del término a priori es

$$\nabla_{\mathbf{w}} \left(\frac{w_0^4 + w_1^4}{4} \right) = \begin{pmatrix} w_0^3 \\ w_1^3 \end{pmatrix}.$$

Por tanto,

$$\nabla_{\mathbf{w}} J(\mathbf{w}) = \nabla_{\mathbf{w}} \text{NLL}(\mathbf{w}) + \begin{pmatrix} w_0^3 \\ w_1^3 \end{pmatrix}.$$

La regla de descenso por gradiente para el estimador MAP es

$$\mathbf{w}^{(t+1)} = \mathbf{w}^{(t)} - \eta \left(\sum_{k=0}^{K-1} 2((\mathbf{w}^{(t)})^\top \mathbf{x}_k) \left[(1 - y_k) - \frac{y_k}{e^{((\mathbf{w}^{(t)})^\top \mathbf{x}_k)^2} - 1} \right] \mathbf{x}_k + \begin{pmatrix} (w_0^{(t)})^3 \\ (w_1^{(t)})^3 \end{pmatrix} \right).$$

6. Se desea desarrollar un sistema de análisis automático de informes clínicos breves, con un corpus de aproximadamente 10.000 documentos no estructurados, cada uno con una longitud media de 150-300 palabras. El objetivo es construir un modelo de clasificación supervisada utilizando redes neuronales.

(8 %)

- (a) Describa y compare las técnicas de vectorización TF-IDF y Word2Vec. Explique el tipo de información que captura cada una y justifique si sería necesario aplicar un preprocesamiento específico de los documentos en cada caso.

- (6 %) (b) Suponga que se desea entrenar un clasificador basado en una red neuronal multicapa (MLP) sobre las representaciones textuales obtenidas. **Enumere** y explique **brevemente** cuatro técnicas diferentes que puedan emplearse para evitar el sobreajuste durante el entrenamiento del modelo.
- (6 %) (c) Explique en qué consiste el mecanismo de atención en redes neuronales. Describa los tipos de atención vistos en el curso y razone qué ventajas podría aportar su uso en el problema planteado. No es necesario describir la arquitectura Transformer ni sus componentes.

Solution:

- (a) TF-IDF es una representación basada en bolsa de palabras que pondera la importancia de cada término según su frecuencia en un documento y su rareza en el corpus, sin capturar relaciones semánticas ni orden. Word2Vec aprende representaciones densas distribucionales a partir del contexto de las palabras, capturando similitudes semánticas.
- Requieren preprocesamiento como tokenización, eliminación de stopwords y, opcionalmente, lematización.
- (b) Entre las técnicas para evitar el sobreajuste se incluyen: (i) regularización de la función de pérdida (L1/L2), que penaliza pesos grandes; (ii) dropout, que desactiva aleatoriamente neuronas durante el entrenamiento; (iii) batch normalization, que estabiliza y regulariza la activación de las capas; y (iv) early stopping, que detiene el entrenamiento cuando el rendimiento en validación deja de mejorar.
- (c) La atención es un mecanismo que permite a la red asignar distintos pesos a diferentes partes de la entrada al generar una representación. Se han visto mecanismos de atención cruzada, autoatención y autoatención enmascarada. En este problema, la atención permitiría centrarse en términos o fragmentos relevantes del documento, mejorando la capacidad del modelo para manejar textos relativamente largos y heterogéneos.